Platform：基于基准测试的 Bittensor 多挑战研究子网络

Cortex Foundation 研究团队

Cortex Foundation —cortex.foundation —Bittensor 子网 100 (Platform)

摘要

我们认为，人工智能发展的主导模式——中心化实验室在封闭环境中训练模型、使用私有基准进行评估、并按固定周期发布——在结构上无法实现持续创新。瓶颈不是算力或数据，而是评估和激励。没有任何单一组织能够在每个能力维度上评估 AI 系统，也没有任何薪金能够匹敌流动性、无许可奖励代币的激励力量。Platform（Bittensor SN100）是一个多挑战子网络，同时解决这两个瓶颈。矿工在多种基准上竞争——软件工程（通过 SWE-Forge 的 Term Challenge）、神经架构搜索（PRISM）和合成数据生成（Data Fabrication）——并按其在独立验证的评估中所展示的能力比例获得奖励，评估在 Yuma Consensus 下进行。我们证明：(1) 现有 Bittensor 子网主要复制中心化 API 托管，没有创造护城河；(2) Platform 基于基准的设计产生了对抗性鲁棒的评估，Terminal-Bench 2.0 到 SWE-Forge 的过渡证明了这一点；(3) 去中心化训练已经可行——Covenant-72B 在 70 个无许可节点上训练，达到 MMLU 67.1，与 LLaMA-2-70B 的 65.6 近乎持平；(4) TAO 计价奖励与实验室薪金竞争的经济论证在量化上是有利的，中心化 AI 成本每年增长 4-5 倍而盈利能力推迟到 2030 年以后；(5) 在架构族 F 上搜索的子网络可证明地实现严格优于任何固定架构竞争者的扩展。直接含义是：一个设计良好的激励网络可以产生与中心化实验室相匹敌或超越的 AI 能力，不是通过复制其结构，而是通过使其结构过时。

目录

0.1 Bittensor 与子网 5
0.2 固定架构问题 5
0.3 架构搜索为何重要 6

1 Platform **架构：多挑战子网** 7
1.1 设计理念 7
1.2 子网拓扑 7
1.3 挑战类别 8
1.4 Yuma Consensus 集成 9
1.5 排放分配 9
1.6 Term Challenge：大规模软件工程 9
1.6.1 动机与 SWE-bench 渊源 9
1.6.2 SWE-Forge 流水线 10
1.6.3 评分机制 10
1.6.4 TB2.0 → SWE-Forge 过渡 11
1.6.5 分层反博弈防御 11
1.7 Data Fabrication Challenge：合成数据集生成 12
1.7.1 动机 12

1.7.2 提交协议 . . . 12
1.7.3 反抄袭流水线 . . . 12
1.7.4 质量控制 . . . 12
1.7.5 应用：RL 微调流水线 . . . 13
1.7.6 规模与自适应性 . . . 13
1.8 PRISM：去中心化神经架构搜索 . . . 14
1.8.1 一种新的挑战类别 . . . 14
1.8.2 架构搜索空间 . . . 14
1.8.3 架构搜索优越性定理 . . . 14
1.8.4 四级评估漏斗 . . . 15
1.8.5 双轨评分与多样性 . . . 16
1.8.6 为何 PRISM 具有革命性 . . . 16
1.9 Training Challenge：去中心化预训练 . . . 17
1.9.1 动机 . . . 17
1.9.2 设计原则：完全去中心化 . . . 17
1.9.3 开放研究问题 . . . 17
1.9.4 与其他挑战的关系 . . . 18
1.9.5 当前状态与时间线 . . . 18
1.10 挑战正交性与**激励正交性** . . . 18
1.10.1 结构不相似性 . . . 18
1.10.2 激励正交性 . . . 19
1.10.3 释放分配 . . . 19
1.10.4 **组合反博弈防御** . . . 19
1.10.5 **端到端生产流水线** . . . 20

2 **经济论证：为什么 TAO 胜过薪资** 20
2.1 中心化 AI 中的人才问题 . . . 20
2.2 Platform 的经济模型 . . . 21
2.3 定量比较 . . . 21
2.4 飞轮效应 . . . 22

3 **去中心化 AI 能否与中心化实验室竞争?** 23
3.1 怀疑论观点 (以及它为何是错误的) . . . 23
3.2 Platform 已经胜出的领域 . . . 24
3.3 收敛论题 . . . 24
3.4 Platform 需要做对的事情 . . . 25

4 **去中心化分析** 26
4.1 形式化去中心化度量 . . . 26
4.2 Covenant-72B 训练分布 . . . 27
4.3 **架构搜索定理** . . . 27
4.4 Yuma Consensus 下的验证者激励框架 . . . 28

5 **结论与路线图** 29
5.1 贡献总结 . . . 29
5.2 未来路线 . . . 29
5.3 启示 . . . 30

6 **参考文献** 30

人工智能的发展由不到五个实验室的寡头所主导。OpenAI、Anthropic 和 Google DeepMind 在单次前沿训练中，计入研发、失败实验和数据获取成本后，各自投入数亿至超十亿美元（Epoch AI, 2024）。这些实验室各自训练一种架构，经过数月的内部研究进行优化，并在封闭环境中评估。架构本身（注意力机制、专家路由策略、归一化方案）是整个开发流程中最具决定性的选择，然而它仅由一个小团队做出一次决策，随后在整个训练过程中被冻结。

评估瓶颈。当单一组织既训练又评估其模型时，评估并非对抗性的；它是表演性的。内部 benchmark 被优化应对，而非从中学习。外部 benchmark 则遭受相反的失败模式：由于它们是公开且静态的，不可避免地被测试集泄漏所污染（Jacovi et al., 2023）。两种体制都无法提供同时具备对抗性和全面性的信号。其后果是，该领域对模型实际能力的理解，由少数几家公司的市场部门所塑造，而非由严谨的、持续的、无需许可的评估所决定。

激励瓶颈。一位能够推动最先进水平的研究者面临一个二元选择：接受现有实验室的薪水（无论多么丰厚），或放弃机构的算力、数据管道和发表声望，转而在开放环境中构建。实验室攫取了上行收益；研究者获取固定工资。这不是系统中的缺陷；这就是系统本身。中心化模式必然将贡献者集合限制为其所能雇佣的人，将贡献集合限制为其所能评估的事物。不符合组织架构的创新，从结构上就无法获得回报。

架构瓶颈。每个前沿模型都在训练开始前选定的一种架构上进行训练。这一决策（注意力机制、MoE 路由、残差拓扑）是整个开发流程中杠杆率最高的选择。DeepSeek 的发展轨迹对此给出了确凿证明：**多头潜在注意力**将 KV 缓存减少了 93.3%，训练成本降低了 42.5%；**无辅助损失的负载均衡**消除了标准 MoE 中固有的性能退化；**压缩稀疏注意力**以仅前一代 27% 的 FLOPs 实现了百万 token 推理。每一项架构创新都带来了数量级的效率提升，这是任何额外算力投入都无法复制的。然而主流范式将架构视为固定输入，而非可搜索的设计空间。一个选择了错误架构的实验室，花费数亿美元训练一个根本上次优的模型，却没有任何机制可以发现，注意力压缩或专家路由的简单改变就能以几分之一的成本获得更优结果。

这三个瓶颈并非相互独立。架构、评估和激励是同一约束的三个侧面：你只能奖励你能衡量的东西，你只能在有诚实评估激励时才能衡量，而你能衡量的能力上限在你训练开始前就已由所承诺的架构所设定。一个只解决其中一两个而不全部解决的系统，并未解决根本问题。

Bittensor（Ω, 2020）提供了一种原则性的出路。Bittensor 是一个去中心化网络，支持多达 128 个子网（网络上限），每个子网通过 Yuma Consensus（一种基于权益的中位数 κ-多数排名协议）以 TAO 代币为单位发放奖励。核心洞见在于：一个具有加密激励的无许可网络可以同时解决评估和激励问题——任何人都可以贡献，奖励与通过对抗性的、持续更新的评估所衡量的已证明能力成正比。

但大多数 Bittensor 子网并未实现这一潜力。我们将其称为**固定架构**模型的普遍模式，分配矿工在由子网运营者指定的单一架构上训练模型。无论子网为协作预训练规定特定的 transformer 配置，还是要求固定的 MoE 路由策略，架构都是自上而下施加的，并被视为不可改变的。这是根本性瓶颈：将**架构搜索**作为一个竞争维度的消除。DeepSeek 的竞争轨迹使这一点毫无歧义。DeepSeek-V2 引入了**多头潜在注意力**（MLA），将 KV 缓存减少 93.3%，训练成本降低 42.5%，同时每个 token 仅激活 236B 参数中的 21B（DeepSeek-AI, 2024a）。DeepSeek-V3 最小化了基于辅助损失的 MoE 负载均衡带来的性能退化，引入了多 token 预测，并在极端规模上验证了 FP8 训练——这些架构创新使总训练成本降至与 GPT-4 竞争的 671B 模型的 $5.576M（DeepSeek-AI, 2024b）。DeepSeek-V4 引入了**压缩稀疏注意力**和**重度压缩注意力**，使百万 token 推理仅消耗前代每 token FLOPs 的 27%（DeepSeek-AI, 2026）。每一代跨越都源于新的架构组件，而非更多 GPU。一个将矿工锁定在固定架构上的子网，恰恰消除了决定竞争优势的那个维度。

Platform 是 Bittensor **子网** 100（SN100），由 Cortex Foundation 运营。Platform 是一个多挑战子网，矿工在真实、对抗性的 benchmark 上接受评估（Term Challenge 使用 SWE-Forge 数据集进行软件工程评估，PRISM 用于神经架构搜索，Training 用于去中心化预训练，Data Fab 用于合成数据生成），并按已证明能力按比例获得奖励。这 **四**个挑战形成一个封闭的生产流水线：PRISM 发现架构，Training Challenge 预训练基础模型，Data Fabrication 生成 RL 微调数据，Term 评估最终生成的智能体。Platform 是一个基准驱动的激励引擎：一个解决困难问题的行为本身就是挖矿过程的系统。

这一区别是基础性的。在固定架构子网中，矿工可以通过高效地在规定设计上训练模型来获得奖励。在 Platform 中，矿工只能通过展示超越网络当前前沿的能力来获得奖励。这创造了一个棘轮效应：网络的聚合能力**单调非递减**，因为每一次奖励事件都对应一次真实的能力进步，而

非训练的重复。

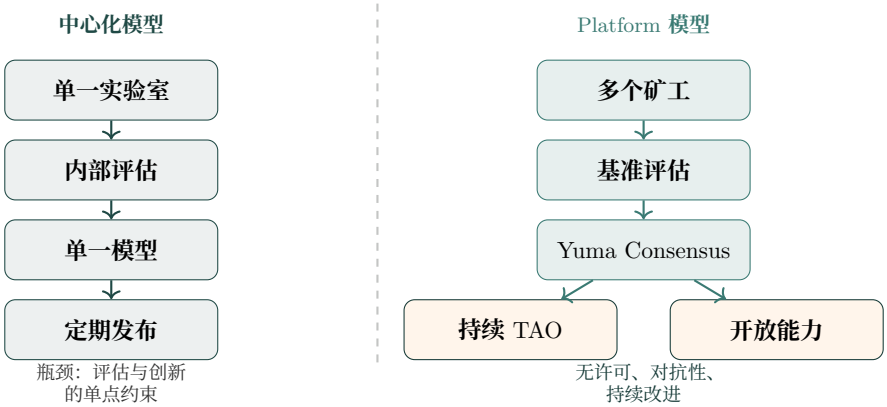

图 1 | Architecture diagram.

我们的贡献如下：

- **具有架构搜索的多挑战架构**。 Platform 是首个在 **四**种正交挑战类型（软件工程、神经架构搜索、去中心化预训练和合成数据生成）上评估矿工的 Bittensor 子网，形成从架构发现、训练、RL 微调到评估的封闭生产流水线。关键在于，PRISM（§4.3）使架构本身成为可搜索的设计空间而非固定约束，系统化了 DeepSeek 通过手动研究迭代所实现的目标（Section 3）。
- SWE-Forge。一个持续数据集生成器，从 GitHub 提取真实合并的拉取请求，构建对抗性测试套件，并为 Term Challenge 生成全新的评估实例，消除了困扰 SWE-Bench 等静态 benchmark 的污染问题（Jimenez et al., 2024）。SWE-Forge 每个 epoch 生成全新的评估集（Section 4）。
- PRISM。 PRISM（Platform Recursive Investigation of Search-space Morphologies）是一个正在积极开发中的即将推出的挑战。PRISM 将评估神经架构搜索，奖励那些在等效计算预算下发现优于固定基线的新架构的矿工。详细的评估漏斗正在积极研究中；当前方向涉及一个多层过滤流水线，逐步验证候选架构（Section 4）。
- **架构搜索子网优于固定架构子网的形式化证明**。我们证明，在 Yuma Consensus 下，允许矿工提出架构的子网达到的均衡能力严格高于将矿工约束在固定架构上的子网，前提是架构搜索空间中至少包含一个优于固定基线的改进（Theorem 1, Section 4）。
- Covenant-72B。一个 720 亿参数的语言模型，在整个训练运行期间累计跨至少 70 个独立节点进行训练（每轮贡献者上限为 20，平均 16.9），在 MMLU 上达到 67.1，证明前沿规模的去中心化训练不仅是可能的，而且在相同参数量下与中心化方案具有竞争力（Section 7.2）。
- TB2.0 → SWE-Forge **转型**。反博弈设计的案例研究：Terminal-Bench 2.0 在矿工开发出最大化分数而不提升真实能力的策略后被退役。SWE-Forge 的数据集生成封闭了这些漏洞（Section 4）。
- **验证者激励框架**。一个博弈论分析，证明在 Yuma Consensus 下诚实评估是纳什均衡，低于阈值的联盟在结构上无效，偏离共识通过排放减少进行自我惩罚（Section 7.4）。
- Platform **治理**。一个持续运行的治理机制，监控子网健康状况，提出参数调整建议，并执行链上治理行动，提供无需中心运营者的 24/7 去中心化管理（Section 3.2）。

本文其余部分组织如下。Section 2 提供 Bittensor、**固定架构问题**以及架构搜索驱动子网动机的背景。Section 3 详述 Platform 架构及其四挑战流水线。Section 4 深入阐述每个挑战，包括评估工具、反博弈机制以及从架构搜索到训练到 RL 微调的端到端生产流程。Sections 5–6 呈现经济论证和竞争分析。Section 7 分析去中心化并展示实验结果。Section 8 总结并提出路线图。

0.1. Bittensor 与子网

Bittensor 是一个用于生产和消费机器智能的去中心化网络，由区块链保障安全，通过 TAO 代币激励（Ω, 2020）。截至撰稿时，该网络支持多达 128 个子网（网络上限），每个子网负责一项特定任务：文本生成、图像生成、数据存储、预测等。每个子网的架构遵循一致的模式：

- **矿工**提供服务（例如，训练模型、生成图像、存储数据）。
- **验证者**通过发送请求并对响应评分来评估服务质量。
- Yuma Consensus 通过基于权益的中位数（κ-多数）协议将验证者分数聚合为全局排名，决定 TAO 排放向矿工和验证者的分配。

形式化地，令 $\mathcal{V} = \{v_1, \ldots, v_N\}$ 表示验证者集合，$\mathcal{M} = \{m_1, \ldots, m_K\}$ 表示矿工集合。每个验证者 v_i 产生一个分数向量 $\mathbf{s}_i \in \Delta^K$（矿工上的概率分布），由权益 w_i 加权。Yuma Consensus 计算共识分数：

$$\bar{s}_j = \frac{\sum_{i=1}^{N} w_i \cdot s_{ij}}{\sum_{i=1}^{N} w_i} \quad \forall\, m_j \in \mathcal{M}$$

注：上述公式为简化表示。实际的 Yuma Consensus 协议使用 κ-多数阈值机制而非简单的加权平均。

矿工随后按 $\bar{s}_j$ 成比例获得奖励。验证者按其与共识的一致程度成比例获得奖励，即分数偏离 $\bar{\mathbf{s}}$ 的验证者获得较少排放。这创造了验证者诚实评分的激励，因为偏离共识是代价高昂的（Rao et al., 2020; withdrawn from arXiv）。

任何子网的关键设计问题是：验证者实际评估的是什么？这个答案决定了子网产生的是真实能力还是仅仅的 benchmark 合规。

0.2. 固定架构问题

大多数 Bittensor 子网（以及中心化 AI 实验室）在我们所称的**固定架构约束**下运作：矿工（或在中心化情况下的研究团队）被要求训练符合单一预设架构的模型。无论子网为协作预训练规定特定的 transformer 配置，还是要求固定的 MoE 路由策略，架构都被视为生产过程的固定输入，而非可搜索的设计空间。

这一约束不仅仅是设计上的方便；它是 AI 发展的根本瓶颈。关键在于子网是否允许将架构搜索作为一个竞争维度。一个在规定设计上训练模型的子网仍然困在固定架构范式之中；它只是在不同训练体制下复制了相同的结构性约束。

DeepSeek **作为确定性证据**。 DeepSeek 模型的发展轨迹提供了明确的证据，证明架构创新（而非计算规模）是 AI 竞争优势的主要决定因素。

DeepSeekMoE（DeepSeek-AI, 2024c）引入了细粒度专家分割和共享专家隔离，取代了粗粒度 MoE 标准。结果是：一个 145B 参数的 MoE 模型以仅 28.5% 的 FLOPs 实现了与 67B 稠密模型相当的性能，仅凭架构就获得了 3.5× 的效率提升。对标准 MoE 拓扑施加任何额外计算都无法弥合这一差距；该增益来自重构专家空间。

DeepSeek-V2（DeepSeek-AI, 2024a）引入了多头潜在注意力（MLA），一种根本不同的注意力压缩机制。MLA 将 KV 缓存压缩 93.3%，训练成本降低 42.5%，推理吞吐量提升 5.76×。DeepSeek-V2 每个 token 仅激活其 236B 总参数中的 21B，却超越了稠密 67B 模型的性能。这些并非额外计算带来的边际改进；它们是来自新架构组件的数量级效率提升。

DeepSeek-V3（DeepSeek-AI, 2024b）引入了三项进一步的架构创新。首先，无辅助损失的负载均衡在很大程度上消除了标准 MoE 负载均衡惩罚所施加的性能退化，减少了此前每个 MoE 实现都付出的代价（尽管 V3 保留了一个小的互补序列级辅助损失以维持训练稳定性）。其次，多 token 预测（MTP）提升了数学和代码 benchmark 上的表现（DeepSeek-AI, 2024b）。第三，FP8 混合精度训练在极端规模上得到验证。综合效果：总训练成本为 $5.576M 的 671B 模型在 MMLU 上匹配 GPT-4o（88.5 vs. 87.2），在 MATH-500 上达到 90.2，在该 benchmark 上超越 o1-preview。这大约比 GPT-4 估计训练成本低 10×，且每一项效率提升都是架构性的，而非计算性的。

DeepSeek-V4（DeepSeek-AI, 2026）引入了**压缩稀疏注意力**（CSA）和**重度压缩注意力**（HCA），一种支持 1M token 上下文窗口的混合注意力机制。V4-Pro 在 1M token 下仅使用 V3.2 的 27% FLOPs 和 10% 的 KV 缓存。**流形约束超连接**（mHC; DeepSeek-AI, 2025）稳定了超深层训练。在 SWE-bench Verified 上，V4 达到 80.6，匹配前沿闭源模型。同样，能力跃升是架构性的：CSA/HCA 和 mHC 是新的结构组件，而非额外计算。

规律。AI 历史上的每一次重大能力跃升都来自架构，而非计算。Transformer 本身（Vaswani et al., 2017）取代 RNN 并非因为它使用了更多 FLOPs，而是因为可并行化的注意力是更优的架构。稀疏门控 MoE（Shazeer et al., 2017）实现了稠密缩放无法复制的子模型路由。MLA、无辅助损失负载均衡和压缩稀疏注意力遵循相同的规律。架构更好的实验室获胜；仅仅花费更多的实验室落后。DeepSeek-V3 的 $5.576M 训练成本对比 GPT-4 估计的 $50–100M+ 就是确凿的证据。

子网在架构锁定下如何失败。固定架构约束在现有 Bittensor 子网中的表现形式各不相同，但结构性后果相同：没有发现更好架构的机制。

真正的区别。 Platform 与其他子网的区别不在于任务类型（推理、训练、存储），而在于架构是固定约束还是可搜索的设计空间：" 固定架构 vs. 架构搜索"。一个在规定设计上训练模型的子网仍然困在固定架构范式之中；它只是将相同的结构性约束复制到了计算上更昂贵的训练体制下。Platform 通过其 PRISM 挑战（§4.3），使架构本身成为去中心化搜索的对象。矿工并非更高效地训练固定设计；他们提出、评估并竞争替代架构，网络奖励那些带来真实能力提升的架构。

0.3. 架构搜索为何重要

如果每个子网都将矿工锁定在固定架构上，那么没有任何子网能发现下一个多头潜在注意力或下一个无辅助损失负载均衡方案。网络的能力上限由子网运营者的架构选择设定，而非由矿工的创造力决定。一个规定使用带有稠密注意力的标准 transformer 的子网运营者，或许在不知不觉中排除了每一种可能带来 10× 效率提升的架构——而这恰好是 DeepSeek 所证明仅凭架构创新即可实现的增益。

去中心化网络产出与中心化实验室相媲美的能力的唯一途径，是将架构作为一个竞争维度，并奖励真正的架构创新，而非仅仅高效训练固定设计。这需要三个属性：

1. **架构搜索作为一等挑战**。子网必须将架构视为可搜索的设计空间，而非固定约束。矿工必须能够提出、评估和竞争替代架构，包括替代注意力机制、专家路由策略和残差拓扑。这正是 PRISM 所提供的（§4.3）：一个即将推出的挑战，将通过多层评估流水线系统化神经架构搜索，目前正在积极开发中。

2. **对发现架构的对抗性评估**。全新 benchmark、多轴评分和前沿相对奖励确保架构创新在真实能力增益上被评估，而非代理指标。一个减少 FLOPs 但降低推理能力的新注意力机制不应被视为进步而获得奖励。Platform 的对抗性评估体制——跨 **四**种正交挑战类型持续刷新的 benchmark——提供了这一保证。

3. **激励与架构创新对齐**。发现更优架构的矿工必须比高效训练更差架构的矿工获得更多。在 Yuma Consensus 下，奖励按共识分数比例分配，而共识分数由已证明的能力决定。一个架构创新产出在对抗性 benchmark 上超越前沿的模型的矿工，获得更高分数，因此获得更高排放，而仅略微更高效地训练规定架构的矿工则不然。激励梯度指向架构搜索，而非背离它。

Platform 满足全部三个属性。通过其 PRISM 挑战，它是首个架构为可搜索设计空间而非施加约束的 Bittensor 子网。

形式化推论。这一区别具有形式化含义。在 Section 4 中，我们证明在 Yuma Consensus 下，允许架构搜索的子网（Platform，通过 PRISM）比将矿工约束在固定架构上的子网达到严格更高的均衡能力。证明基于这样的观察：架构搜索扩展了矿工的有效策略空间，在任何奖励真实能力的评分体制下，必然弱改善均衡。Platform 的评估体制确实奖励真实能力，因为其 benchmark 是对抗性的、多轴的且持续刷新的。核心洞见是，固定架构约束不仅仅是一个设计选择；它是一

种主动危害，因为它恰恰排除了那些被中心化实验室证明是能力跃升最高杠杆路径的策略（架构创新）。

Platform 与固定架构子网之间的差异不是渐进的；它是范畴性的。固定架构子网问的是矿工能否优化一个规定设计。PRISM——Platform 的架构搜索挑战——问的是矿工能否发现一个更优的设计。前者是工程问题；后者是研究问题。只有后者才能产生 DeepSeek 所证明的决定 AI 能力的架构创新。

综上所述，固定架构模式是 Bittensor 子网设计的默认吸引子：它易于指定、易于验证、易于理解。但它也是一个局部最优。逃离它需要一种根本不同的评估哲学：对抗性而非合规性、多轴而非单指标、前沿相对而非参考静态，以及——关键地——架构搜索驱动而非架构固定。Platform 是首个端到端实现这一哲学的子网。

1. Platform 架构：多挑战子网

1.1. 设计理念

Platform 的基本前提看似简单却意义重大：**你衡量什么，就得到什么**。如果一个去中心化网络仅衡量推理吞吐量，它将专门优化快速推理；如果它仅衡量静态 benchmark 上的编码准确率，它将过拟合到这些 benchmark。AI 评估的历史充满了古德哈特定律发挥作用的例子：对评估指标的优化压力不可避免地会损害该指标本意反映的底层能力 (Strathern, 1997)。Platform 的架构设计理念旨在抵抗这种压力，其方式并非依赖某种单一的巧妙机制，而是通过同时博弈多个正交评估维度的组合困难性。

Platform 不是固定架构的子网。与将矿工锁定在预定义模型架构且仅在受限设计空间内评估的子网设计不同，Platform 通过包含架构搜索作为一等挑战的对抗性 benchmark 评估真实能力。Platform 上的矿工不能仅通过稍快地训练预定义架构而成功；它必须发现新颖架构、生成可验证补丁、导航陌生代码库，并在持续变化的约束下产生训练数据。

多挑战设计反映了心理测量理论的核心洞见：正交测量工具之间的**聚合效度**提供了比任何单一工具（无论其构造多好）更强有力的真实能力证据 (Campbell & Fiske, 1959)。Platform 通过部署探查 AI 能力结构上不同维度的挑战类别来实现这一点：

- **代码合成与修复**（Term Challenge）：智能体能否诊断并修复生产代码库中的真实 bug?
- **架构搜索**（PRISM，即将推出）：智能体能否在资源约束下发现新颖的神经架构?
- **去中心化预训练**（Training Challenge，研究中）：网络能否在没有中央编排器的情况下协同训练前沿模型?
- **数据质量**（Data Fabrication，即将推出）：智能体能否生成保持分布特性且无泄露的合成训练数据，并将其输入 RL 微调?

没有任何单一挑战类别主导奖励分配，且各类别被设计为具有低互相关性。在补丁生成方面表现出色但在架构搜索方面失败的矿工只能获得部分而非全部补偿。这种**正交性约束**不仅仅是美学考量；它是对抗奖励黑客攻击的主要防线。要博弈 Platform，矿工需要同时博弈四个不断演化的评估流水线，每个都有独特的反博弈机制，其对抗成本随挑战数量组合增长。

关键是，这**四个挑战**构成了一条**生产流水线**，而不仅仅是独立评估的集合。PRISM 确定最优架构；Training Challenge 使用该架构以完全去中心化的方式预训练基础模型；Data Fabrication 生成用于 RL 微调的高质量合成数据；Term Challenge 评估最终的智能体。这种**闭环设计**确保流水线的每个组件都经过竞争性优化（Section 4）。

1.2. 子网拓扑

Platform 作为 Bittensor 子网 100 运行，继承底层经济原语的同时施加自身的治理与评估逻辑。数据流经过七个阶段：

矿工 → **提交池** → **验证者** → PBFT **共识** → **权重提交** → Yuma Consensus（**链上**）→ TAO **奖励**

矿工根据当前活跃挑战生产产物（补丁、编码架构配置的可执行代码）。这些产物被存入**提交池**，以内容嵌入标识符为键。提交被嵌入到具有基于智能体监控的优化执行环境中，这防止了矿工之间的窃取和复制，同时支持对相同提交进行去重。系统确保矿工代码在受保护的、受监控的环境中运行，智能体在其中验证执行完整性并检测抄袭或对其他矿工作品的未授权复制。

验证者通过 epoch **种子分配**被指派评估任务。在每个 epoch 边界，从区块链状态派生的种子决定哪些验证者评估哪些提交。因此，该分配事前不可预测（防止串谋）但事后可审计（支持检测验证者不当行为）。这种设计反映了密码学抽签协议中的随机陪审员选择 (Gilad et al., 2017)，确保没有验证者可以战略性地选择要评估的提交。

Platform **治理**对子网运营参数提供持续治理，包括挑战选择、奖励权重和评估标准，取代了早期设计中 epoch 触发的参数更新。与只能在固定间隔调整参数的 epoch 绑定治理不同，Platform 治理全天候运行，支持对新兴博弈策略的快速响应。在 epoch e 发现的 Term Challenge 评估流水线中的漏洞可以在 epoch e+1 之前修复，而无需等待下一个治理周期。Platform 治理维持与**提交池**（调整难度目标）、共识层（修改法定人数要求）和奖励分配（调节挑战权重分割）的反馈连接。

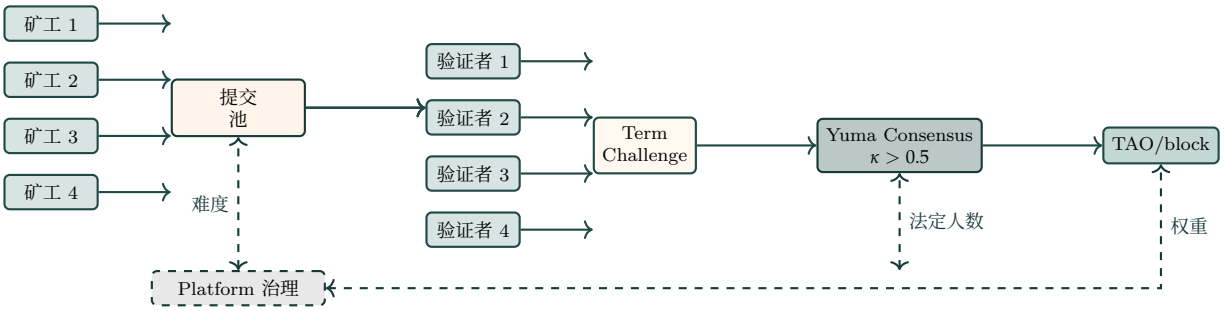

图 2 | Architecture diagram.

1.3. **挑战类别**

Platform 有四个正在开发中的挑战类别，均计划在 Platform 3.0（2026 年 5 月）下激活：

Term Challenge。 Term Challenge 在由 SWE-Forge 生成的数据集上评估 AI 编码智能体，SWE-Forge 是一个从 GitHub 上真实合并的拉取请求创建与 SWE-bench 兼容评估实例的生成器。每个实例要求智能体诊断 bug、生成补丁并通过回归测试，且无法访问原始修复。Section 4 对 SWE-Forge 流水线及其反博弈机制进行了详细阐述。Term Challenge 计划在 Platform 3.0（2026 年 5 月）下重新激活。

PRISM**(即将推出)**。PRISM(Platform Recursive Investigation of Search-space Morphologies) 是一个目前正在积极开发中的挑战。PRISM 将评估神经架构搜索，奖励在同等计算预算下发现超越固定基线的新颖架构的矿工。详细的评估漏斗正在积极研究中；当前方向涉及一个多级过滤流水线，从轻量代理分数到完整 benchmark 评估，逐步验证候选架构。PRISM 计划随 Platform 3.0 一同推出。

Training Challenge。Training Challenge 将评估大语言模型的去中心化预训练。一旦 PRISM 确定了最优架构，Training Challenge 将协调独立矿工之间的完全去中心化训练，没有中央编排器，也没有单一控制点。这是由 Covenant-72B 展示的去中心化训练的直接继任者，但被整合到 Platform 的多挑战框架中。设计正在积极研究中；关键开放问题包括异构硬件下的梯度聚合、无中心化协调的掉队者缓解以及诚实贡献验证。

Data Fabrication**（即将推出）**。 Data Fabrication 挑战将通过分布保真度指标评估合成数据生成：智能体能否产生保持目标分布统计特性同时避免记忆和隐私泄露的训练数据？主要下游应用是 RL 微调：Data Fabrication 矿工生成高质量的 (prompt, response) 对，直接输入由 Training Challenge 产生的基础模型的强化学习中。该挑战通过激励高质量合成训练集的去中心化生产来解决” **数据墙**” 问题 (Muennighoff et al., 2023)。

多挑战设计确保没有单一能力维度能捕获全部 TAO 排放。在补丁生成方面出色但无法搜索架构、训练模型或生成数据的矿工最多只能获取 Term 分配。关键是，**四个挑战**构成一条**生产流**

水线：PRISM 发现架构，Training Challenge 训练基础模型，Data Fabrication 提供 RL 微调数据，Term Challenge 评估最终的智能体。全面能力的边际收益超过狭窄专长的收益；我们将这一性质称为**激励正交性**。

1.4. Yuma Consensus 集成

Platform 继承 Bittensor 的 Yuma Consensus 机制，将验证者评估转化为链上奖励分配。该集成的关键属性如下：

质押加权法定人数。验证者对共识结果的影响力与其质押的 TAO 成正比。要最终确认给定矿工提交的分数，控制至少 κ 比例（通常 > 0.5，即多数）总质押的验证者必须就分数达成一致，该分数才能被最终确认。该阈值平衡了延迟（较低的 κ 支持更快确认）与安全性（较高的 κ 使串谋成本更高）。Platform 治理可以根据观察到的验证者行为调整法定人数阈值；如果验证者一致性低于历史基线，法定人数要求将增加，迫使进行额外的独立评估。

验证者自我对齐。在 Yuma Consensus 下，验证者获得的奖励并非基于其分数的绝对准确性，而是基于与同侪共识的一致性。持续偏离涌现共识的验证者将获得减少的排放。这创造了一个自我强化均衡：诚实评估是利润最大化策略，因为它最大化了与其他诚实验证者的预期一致性。无论是出于无能还是串谋，偏离行为都会通过减少排放自动受到惩罚 (Bittensor Foundation, 2024)。

分数标准化与奖励分配。原始验证者分数在共识聚合前按挑战类别进行标准化。在每个类别内，超过质押加权共识阈值的权重被截断，矿工排放计算为截断后权重的质押加权和。这种标准化确保异构挑战类型间的分数分布保持可比性，防止任何单一挑战因规模效应而主导奖励计算。

1.5. 排放分配

各挑战间的排放分配由 Atlas 3.0 自主决定，Atlas 3.0 是 Bittensor 的自动化排放管理协议，根据参与率、成熟度指标和已证明的影响力持续调整挑战权重，无需手动治理投票或固定比例分配。

在每个挑战内部，评分包含两个额外机制：

均匀评分。Term Challenge 分数计算为 tasks_passed/total_tasks，在矿工池中标准化。没有难度乘数；每个任务对矿工解决率的贡献相同。

赢者通吃并带衰减。每个评估窗口中得分最高的矿工获得最大的奖励份额。然而，为防止根深蒂固的主导地位抑制竞争，Platform 施加**顶级智能体衰减**机制：一旦矿工占据首位超过 10 **个** epoch **的宽限期**，其奖励份额开始以约 14 **个** epoch **的半衰期**衰减。形式化地，如果矿工在宽限期之后已经作为最高得分者 e 个 epoch，其奖励将乘以 $\left(\frac{1}{2}\right)^{e/14}$。这创造了自然的轮换激励：现有矿工必须持续改进以维持其有效奖励，而挑战者面对的衰减调整后的目标则逐渐变得更容易超越。

Platform 子网将" 构建有用的 AI 基础设施" 这一开放性问题分解为**四个结构上不相似的挑战**，每个挑战针对一个不同的能力维度。这种分解并非任意的：它源于这样一个观察，即没有任何单一的评估范式能够同时考察工程能力、数据质量、架构创新和去中心化训练。我们详细阐述每个挑战，包括完整的评估机制、评分机制、反博弈防御，以及在 Bittensor 生态系统中确立其个体和集体新颖性的理论论证。

1.6. Term Challenge：大规模软件工程

1.6.1 动机与 SWE-bench 渊源

Term Challenge 评估自主软件工程能力，即智能体阅读真实世界的问题描述、导航代码库并生成解决问题的补丁的能力。该挑战植根于 SWE-bench 范式 (Jimenez et al., 2024)，该范式从 12 个流行的 Python 仓库中构建了一个包含 2,294 个真实 GitHub 问题的基准测试，每个问题都配对了解决该问题的真实合并提交。SWE-bench 的关键洞见在于，评估应衡量端到端任务完成度，而非中间过程指标；智能体要么解决了问题，要么没有。

Platform 的贡献在于将 SWE-bench 从静态排行榜转变为活的、加密经济激励的评估协议。SWE-bench 在固定测试集上对单个智能体评分，而 Term Challenge 持续奖励那些在从相同分

布中抽取的新鲜、隐藏实例上实现最高解决率的矿工。数据集从 GH Archive (Grigorik, 2024)，即所有 GitHub 事件的公共存档中进行补充，确保挑战随软件生态系统本身一起演进。

1.6.2 SWE-Forge **流水线**

SWE-Forge 是一个数据集生成器，为 Term Challenge 生成新鲜的、抗博弈的评估实例。它实现了从原始 GitHub 问题到打包的基准测试实例的**七**阶段流水线，Term Challenge 随后使用该流水线评估矿工智能体：

1. **问题摄取**：候选问题从 GH Archive 中挖掘，筛选具有足够测试覆盖率和关联合并提交的 Python 仓库。
2. **实例创建**：每个问题与其解决提交以及一个识别与该问题相关的测试用例的测试评分脚本配对。两类测试被区分：fail-to-pass 测试（补丁前失败且补丁后必须通过）和 pass-to-pass 测试（在补丁前和补丁后状态下都必须通过）。
3. **基准测试打包**：仓库状态在补丁前提交处冻结，评分脚本与之一起打包。测试用例对智能体设为只读：可见但不可修改。
4. **智能体执行**：矿工提交其智能体的源代码（而非预计算的补丁）。验证者通过 PyInstaller 将此代码编译为独立二进制文件，然后在 Docker 容器中执行以实现隔离。允许网络访问以便智能体可以安装所需的包；容器限制对主机文件系统的访问并防止修改测试套件。
5. **补丁提取**：智能体二进制文件生成针对仓库的 diff。如果未生成 diff 或 diff 格式错误，则提交评分为 UNRESOLVED。
6. **前后验证**：补丁应用于补丁前仓库状态。在前（补丁前）和后（补丁后）两种状态下执行完整测试套件。当且仅当以下条件满足时，提交被标记为 RESOLVED：

- 每个 fail-to-pass 测试在补丁前**失败**且在补丁后**通过**。- 每个 pass-to-pass 测试在两种状态下都**通过**。

这种双状态验证是关键创新。它防止智能体通过删除失败测试、插入平凡的 assert True 或任何其他退化补丁来" 解决" 问题，这些退化补丁使特定失败测试通过同时破坏先前通过的测试。

1. **评分与排名**：每个矿工解决的实例被统计，分数使用均匀聚合计算（见 §4.1.3）。

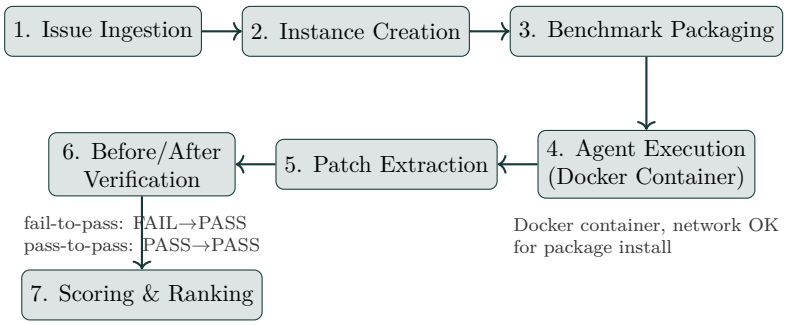

图 3 | Architecture diagram.

1.6.3 **评分机制**

矿工 m 的 Term Challenge 分数为：
$S_{\text{term}}(m) = \frac{\text{tasks_resolved}(m)}{\text{total_tasks}}$

其中分母是当前评估批次中的实例数量。在 v2 中，所有实例具有均匀权重；不应用难度乘数。这一设计选择优先考虑覆盖度而非深度：解决许多简单问题的智能体优于解决单个困难问题的智能体，这反映了工业现实，即在广泛任务分布上的可靠性比偶尔的卓越更有价值。

胜者全得（WTA）评分与顶级智能体衰减机制结合应用，以防止占主导地位的矿工永久获取超额奖励。epoch e 的衰减因子为：

$\alpha(e) = 2^{-e/14}$

这提供了一个 10 epoch 的宽限期（因子保持接近 1.0）和大约 14 epoch 的半衰期，此后顶级矿工分数被减半，为竞争者创造空间。衰减应用于顶级矿工与群体之间的分数差值，而非原始分数。

1.6.4 TB2.0 → SWE-Forge **过渡**

Term Challenge 的前身 Terminal-Bench 2.0 存在一个根本性的设计缺陷：测试用例中的断言阈值在推理时对智能体可见。这使得基于预言机的作弊策略成为可能：智能体可以检查测试套件、提取预期输出，并生成硬编码的回显而非真正的修复。随后的分析证实，该基准测试奖励的是阅读测试而非修复缺陷。

TB2.0 分数与 SWE-bench Verified 分数之间的相关性未在 TB2.0 论文中正式测量，但定性证据是明确的：TB2.0 的预言机可利用设计允许智能体在不具备真正缺陷修复能力的情况下获得高分，产生的排名与真实世界软件工程能力没有有意义的关系。SWE-Forge 的前后验证和 Docker 容器化关闭了这些利用向量，我们定性地观察到，在 TB2.0 可见断言机制下表现良好的矿工在 SWE-Forge 的隐藏测试、双验证机制下无法维持其优势，这一发现与两种基准测试衡量根本不同能力的观点一致。

1.6.5 **分层反博弈防御**

SWE-Forge 实现了**六**层防御以对抗退化策略，从最外层（最便宜、最广泛）到最内层（最昂贵、最针对性）排列：

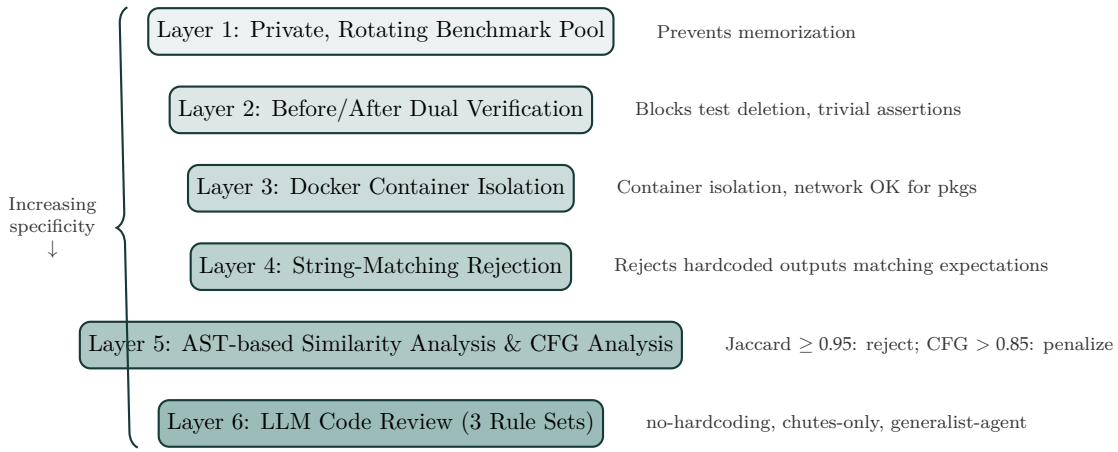

图 4 | Architecture diagram.

1. **基准测试设计**：测试实例从私有的、轮换的池中抽取。矿工无法记忆答案。
2. **前后验证**：补丁必须在修复所有失败测试的同时保留所有通过测试，防止测试删除和平凡断言。
3. Docker **容器隔离**：允许网络访问以安装包，但主机文件系统访问受限且测试套件为只读。智能体在模拟真实部署的容器化约束下运行。
4. **字符串匹配拒绝**：包含与测试预期匹配的硬编码输出的补丁被标记并拒绝。

结构相似性	判定	处理
$< 30\%$	干净	无需进一步检查
30%–96%	模糊	触发 LLM 语义验证
$\geq 97\%$	抄袭	提交被拒绝

5. **基于 AST 的相似性分析**：提交的补丁被规范化为其抽象语法树并哈希。结构相似性通过 AST 节点集上的 Jaccard 系数测量：

- Jaccard ≥ 0.95：补丁被拒绝（与已知作弊模板近乎相同）。- Jaccard $\in [0.90, 0.95)$：分数减半（可疑相似性）。- CFG 相似性 > 0.85：对控制流模仿施加额外惩罚。

1. LLM **代码审查**：在 SWE-Forge 特定规则上训练的语言模型审查每个补丁的硬编码模式。审查应用三组规则：no-hardcoding（拒绝平凡的值注入）、chutes-only（强制 Docker 容器合规）和 generalist-agent（拒绝任何颠覆评估意图的策略）。

SWE-Forge 在 CortexLM/swe-forge 完全开源，其数据集发布在 HuggingFace 上。

1.7. Data Fabrication Challenge：合成数据集生成

1.7.1 动机

训练数据问题是 LLM 发展中的核心瓶颈。即使是前沿模型也受限于可用监督信号的数量和质量。合成数据生成，即强模型产生弱模型可以从中学习的 (提示, 响应) 对，已成为主导的扩展策略 (Grattafiori et al., 2024; Team et al., 2024)。然而，合成数据的质量差异巨大，现有方法缺乏严格的反抄袭保证。

Data Fabrication Challenge 激励矿工生产高质量的合成训练数据集，这些数据集由结合了结构分析、语义抄袭检测和正确性验证的多阶段评估机制进行评估。关键是，该挑战的输出直接输入到将 Platform 的基础模型转化为能干智能体的强化学习微调流水线中，我们在 §4.2.5 中明确阐述了这一联系。

1.7.2 提交协议

矿工提交 Python harness，即可执行脚本，当验证者运行时，生成 JSONL 格式的对话数据集。输出文件中的每一行是一个 JSON 对象，包含一个提示和对应的解决方案。harness 方法而非直接数据上传确保了验证者可以重新执行生成过程、验证确定性并检查生成逻辑。

1.7.3 反抄袭流水线

harness 实现了双重抄袭检测系统：

第一轮：AST 结构验证。提交的代码被解析为抽象语法树。所有变量名被规范化为规范形式（var_0、var_1、var_2、...），以消除表面混淆。规范化的 AST 被哈希，提交之间的结构相似性通过 AST 节点序列上的最长公共子序列（LCS）计算。

第二轮：LLM 语义验证。结构相似性落在模糊范围内的提交进行第二轮验证，语言模型比较它们的语义等价性，检测逃避结构比较的改写副本。

抄袭阈值为：

抄袭聚类按结构哈希前缀对提交进行分组，使得高效的成对比较仅在聚类内进行，而非跨越所有 $O(n^2)$ 对。

1.7.4 质量控制

除抄袭外，harness 还强制执行多项质量保证：

- **自指令循环**：LLM 从种子示例生成新的 (提示, 解决方案) 对，然后单独的验证者 LLM 验证每对的正确性。仅同时通过生成和验证的对被纳入。

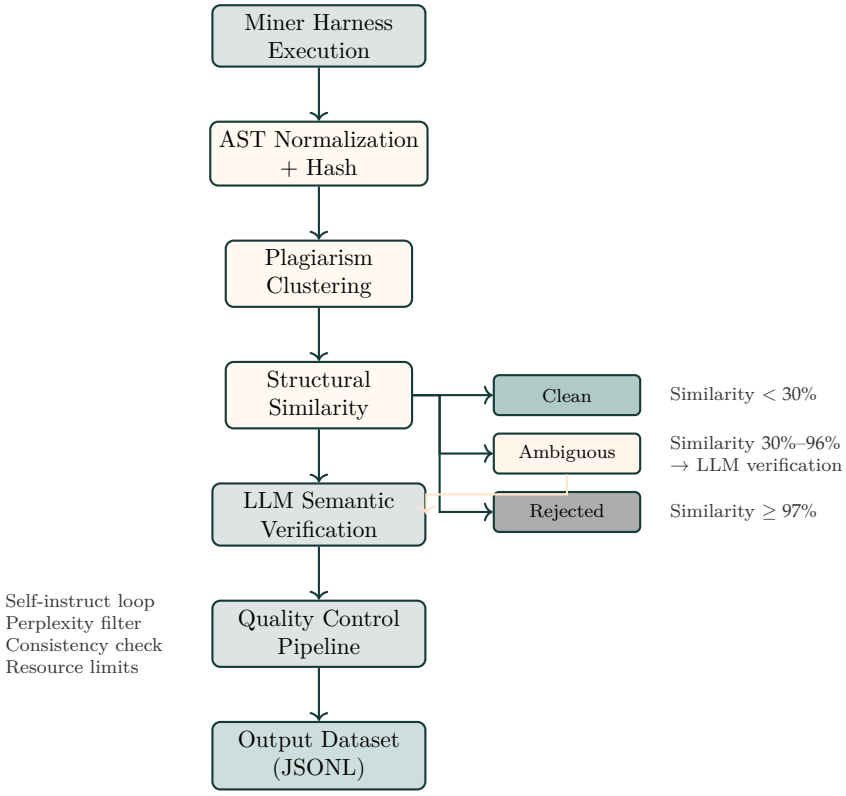

图 5 | Architecture diagram.

- **困惑度过滤**：困惑度超过阈值（相对于参考模型）的输出被拒绝为可能低质量或无意义的。
- **一致性检查**：大约 18% 的生成示例被一致性过滤器拒绝，该过滤器验证解决方案是否真正解决了提示所要求的问题。
- **资源限制**：容器化执行强制执行 CPU 时间、内存和输出文件大小约束，以防止拒绝服务式提交。

1.7.5 应用：RL 微调流水线

Data Fabrication Challenge 的主要下游应用是为强化学习微调生产高质量的 (提示, 响应) 对。这一联系至关重要：该挑战并非孤立存在，而是作为 Platform 完整训练流水线的数据生产环节。

一旦 Training Challenge (§4.4) 产生了基础模型（其架构由 PRISM (§4.3) 确定），Data Fabrication 矿工生成针对 Platform 智能体必须具备的能力的领域特定训练数据：代码生成、缺陷分析、架构推理和漏洞构建。单独的 RL 训练循环消费这些 (提示, 响应) 对，应用策略梯度方法（例如 GRPO；Team et al., 2024）将基础模型微调为能干的智能体。

这创建了一个**三阶段流水线**：PRISM（架构）→ Training（基础模型）→ Data Fabrication + RL 微调（能干智能体）。Term Challenge 随后评估生成的智能体，通过提供反馈性能信号来闭合循环，这些信号指导架构搜索和训练策略。因此，Data Fabrication Challenge 在 Platform 生态系统中占据关键位置：它是将通用基础模型转化为专业化、具备智能体能力的系统的机制。

1.7.6 规模与自适应性

目标规模是每个领域 10^7+ 个示例，要求矿工开发高效的生成流水线。评估机制在**自适应熵原则**下设计：评估系统的适应速度快于模型群体的改进速度，在矿工能力提升时保持区分力。这通过轮换种子集、演进抄袭阈值和周期性重新校准质量过滤器来实现。

Platform 3.0 计划于 2026 年 5 月上线，将重新激活所有挑战：Data Fabrication、Term Challenge 和 PRISM。在 Platform 3.0 下，仅这三个挑战将被激活。

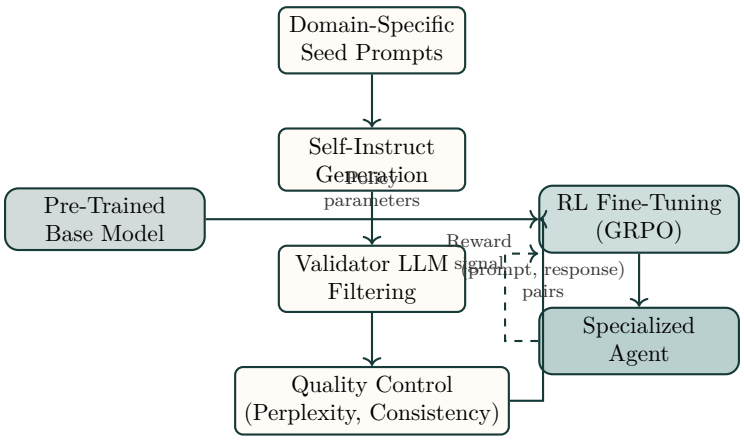

图 6 | Architecture diagram.

维度	选项	数量
注意力类型	MHA, MQA, GQA, Linear, MLA	5
FFN 类型	Dense, GLU, MoE	3
归一化	LayerNorm, RMSNorm, DeepNorm	3
激活函数	ReLU, GELU, SwiGLU	3
位置编码	RoPE, ALiBi, None	3
初始化	Normal, Scaled, Fixup	3

1.8. PRISM：去中心化神经架构搜索

1.8.1 一种新的挑战类别

PRISM（Platform Recursive Investigation of Search-space Morphologies）引入了其他 Bittensor 子网未曾尝试的挑战类别：具有加密经济激励的神经架构搜索。

现有 Bittensor 子网中没有搜索架构空间的。现有子网要么评估推理质量，要么在规定架构内评估训练贡献，要么评估特定领域的指标。PRISM 是第一个将架构本身作为去中心化搜索对象的协议，这一区别具有深远的理论和实践意义。

DeepSeek 的发展轨迹使得架构搜索的必要性变得明确。每一代 DeepSeek 模型都引入了至少一个新的架构组件：多头潜在注意力 (DeepSeek-AI, 2024a)、无辅助损失的负载均衡和多标记预测 (DeepSeek-AI, 2024b)、压缩稀疏注意力和重度压缩注意力 (DeepSeek-AI, 2026)，这些都带来了**数量级**的效率提升。这些发现来自一个在 6 至 12 个月周期上运行的研究团队。PRISM 的前提是，同样的搜索过程分布在数百个有竞争激励的矿工中，可以在 epoch 粒度上发现相当或更优的创新，持续而非周期性地进行。

1.8.2 架构搜索空间

PRISM 定义了一个组合架构空间 $\mathcal{F}$，跨越**六**个分类维度和**四**个连续参数，专为该挑战设计：

PRISM 定义了一个组合架构空间 $\mathcal{F}$，跨越**六**个分类维度：注意力机制、前馈设计、归一化策略、激活函数、位置编码和权重初始化，每个维度有 3 至 5 个离散选项，专为该挑战设计，产生数千种不同的分类配置。在移除少量已知不可行的组合（例如 Fixup 初始化与 LayerNorm 在结构上无效）后，可行的分类空间仍然很大。**四**个连续参数（嵌入维度、深度、注意力头数、FFN 扩展比）进一步将每个分类配置细分为连续子空间，使总搜索空间远大于分类配置数量本身。

1.8.3 架构搜索优越性定理

定理 1（**架构搜索优越性**）。设 $\mathcal{F}$ 为满足 $|\mathcal{F}| \geq 2$ 的架构族。在总计算预算 C 下，搜索 $\mathcal{F}$ 的子网相比评估固定架构 $f \in \mathcal{F}$ 的子网，实现了严格更优的期望扩展。

证明概要。考虑分配给 K 个矿工的计算预算 C。在固定架构子网下，所有 K 个矿工训练相同架构 f^*，产生单一性能估计 $\hat{L}(f^*)$。在搜索子网下，矿工探索不同架构 $f_1, \ldots, f_K \in \mathcal{F}$，产生估计 $\hat{L}(f_1), \ldots, \hat{L}(f_K)$。搜索子网发现的最优架构满足 $\min_k \hat{L}(f_k) \leq \hat{L}(f^*)$ 几乎必然成立，当 f^* 不是 $\mathcal{F}$ 中的全局最优时严格不等式成立，这是任何满足 $|\mathcal{F}| \geq 2$ 的非平凡搜索空间的通用情况。由于搜索子网始终可以采用固定架构子网的选择作为其 K 个候选之一，它弱占优；且由于固定选择是全局最优的概率随 $|\mathcal{F}|$ 增长而递减，因此对于任何非平凡搜索空间，占优是严格的。□

该定理建立了搜索空间大小 $|\mathcal{F}|$ 本身就是优势，而非需要最小化的成本。凭借数千种可行配置，PRISM 的搜索空间对每次训练运行仅评估少数架构的任何中心化实验室提供了结构性优越性。

1.8.4 四级评估漏斗

PRISM 的多级评估流水线目前正处于积极开发和研究中。以下描述的是当前正在探索的方向；最终设计可能随研究进展而变化。

以最高保真度评估整个架构空间在子网的释放周期内是计算上不可行的。当前的研究方向涉及一个**四**级漏斗，渐进式地过滤候选者，将计算集中在最有希望的架构上：

L1**：语法验证**。当前方向将检查每个提交产物（编码架构配置的可执行代码）的结构有效性：兼容的维度选择、非负层数、有效的注意力头可除性。该级别需要零计算，并消除明显格式错误的提交。

L2**：多代理评分**。当前方向将使用轻量级代理指标评估验证后的架构：参数量、理论 FLOPs、激活内存占用和代理质量估计器（例如零成本 NAS 指标）。L2 每个候选者约消耗 0.001 计算小时，并产生初步排名。关键是，训练配方（学习率、批量大小、调度）将在 L2 被**协议固定**；矿工不能通过将超参数过拟合到代理指标来膨胀其 L2 分数。

L3**：单 epoch 训练代理**。当前方向涉及对 L2 顶级候选者在代表性数据子集上训练单个 epoch。由此产生的损失景观将提供基于 sigma 的过滤标准：损失高于中位数的架构被硬杀死。此外，将在多个基准测试套件中计算 L2 代理排名和 L3 单 epoch 排名之间的 Kendall 秩相关 τ。如果 $\tau < 0.4$，则该架构分数设为零。这一硬杀死规则防止单一基准测试优化，因为过拟合一个代理的架构将在基准测试间表现出排名不一致。

L4**：完整基准测试**。当前方向涉及为 L3 的 top-K 存活者提供完整的多个 epoch 训练运行，并配合 VARPRO 缩放定律拟合。VARPRO（变量投影；Golub & Pereyra, 1973）将幂律关系 $L(C) = AC^{-\alpha} + L_\infty$ 拟合到多个计算预算下观测到的损失，实现跨尺度验证。如果检测到排名反转（即一个架构在较低计算预算下表现优越但在较高预算下落后），则通过尺度坍缩检测对该架构施加惩罚。没有其他 NAS 系统实现这种跨预算一致性检查。

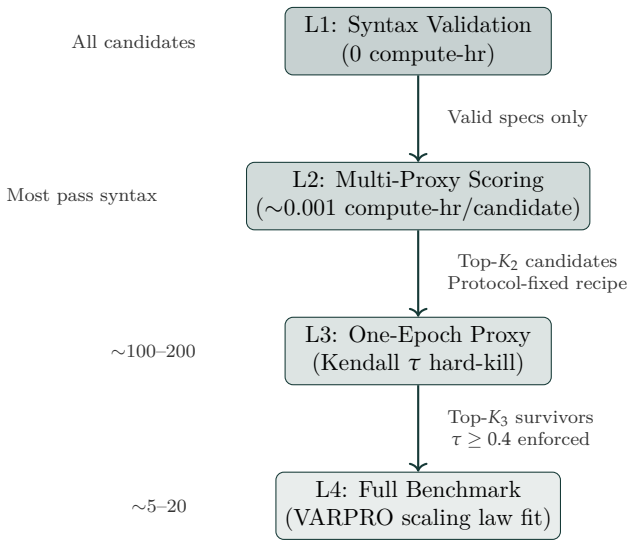

图 7 | Architecture diagram.

1.8.5 双轨评分与多样性

PRISM 采用双轨评分系统：

$S_{\text{PRISM}}(m) = 0.7 \times Q_{\text{arch}}(m) + 0.3 \times Q_{\text{recipe}}(m)$

其中 Q_{arch} 衡量发现的架构的内在质量（来自 L4 评估），Q_{recipe} 衡量与架构一同提交的训练配方的质量。0.7/0.3 的分割确保架构创新是主要奖励驱动力，同时仍激励良好的训练实践。

多样性奖励用于防止复制粘贴挖矿，即提交当前最高分架构轻微变体的经济理性策略。奖励作为矿工提交与提交分布众数之间的 Jaccard 距离的函数计算，奖励探索 $\mathcal{F}$ 中未被充分覆盖区域的矿工。

1.8.6 为何 PRISM 具有革命性

PRISM 引入了六项创新，这些创新共同构成了相对于所有先前 NAS 系统（无论 Bittensor 内外）的质变：

1. **首个具有加密经济激励的** NAS。在 PRISM 中，诚实搜索是 Nash 均衡。提交通过完整漏斗验证的真正新颖架构的矿工获得奖励；复制或作弊的矿工被基于 AST 的相似性分析、LLM 审查和 Kendall 的 τ 硬杀死捕获。没有先前的 NAS 系统将搜索行为与财务激励对齐。

2. * 架构搜索定理证明搜索空间大小本身就是优势。拥有数千种可行配置，去中心化搜索可证明 * 优于任何单智能体评估。这不是经验性主张；它源于搜索问题本身的结构。

3. L4 **尺度坍缩检测**。没有其他 NAS 系统检查跨计算预算的排名反转。在一种尺度上训练一个架构的中心化实验室没有机制检测其架构的优势在更大尺度上会消失。PRISM 在 L4 的 VARPRO 拟合使这种检测自动化。

4. L3 **的** Kendall τ **硬杀死**。没有其他 NAS 系统通过强制跨基准测试排名一致性来防止单一基准测试优化。$\tau < 0.4 \rightarrow \text{score} = 0$ 规则是结构性保证，存活者必须具有广泛能力而非窄度过拟合。

5. L2 **协议固定配方**。通过在代理评估级别固定训练配方，PRISM 防止矿工通过超参数过拟合膨胀 L2 分数。配方是控制变量，而非自由度。

6. **完整架构搜索对比部分搜索**。现有触及架构空间的子网仅搜索单一维度（例如，用于推理优化的注意力机制配置）。PRISM 同时搜索全部**六**个维度，使其成为唯一将架构搜索视为一等问题的子网。

7. DeepSeek **证明了论点；**PRISM **将其系统化**。 DeepSeek 的研究团队每隔 6 至 12 个月发现一个新的架构组件：2024 年 5 月的 MLA、2024 年 12 月的无辅助损失负载均衡、2026 年 4 月的压缩稀疏注意力。每次发现都需要数月的内部研究、大量的原型计算和完整的发表周期。PRISM 将这一时间线从数月压缩到 epoch：数百个矿工同时探索架构空间的不同区域，四级漏斗自动识别有希望的候选者，网络用 TAO 释放奖励真正的创新，而不需要研究团队、发表或集中协调的搜索活动。DeepSeek 通过世界上最优秀研究团队之一的集中努力所达成的成就，PRISM 通过网络规模的去中心化竞争搜索达成。**架构搜索定理** (§4.3.3) 证明这不仅仅是更快；它在结构上更优越，因为当空间超过适度的规模阈值时，组合空间上的去中心化搜索可证明地优于任何单智能体搜索。

DeepSeek 的研究团队以 6 至 12 个月为周期进行手动架构搜索，对应于具有部分搜索广度（限于其研发团队优先考虑的组件）且无跨预算评估、排名一致性强制、固定配方控制或反博弈机制的” 中心化 NAS” 条目。

PRISM 作为私有仓库存在于 PlatformNetwork/prism（创建于 2026 年 4 月），预计将于 2026 年 5 月初进入主动评估。

表 1 | PRISM 与相关方法的比较。PRISM 独特地结合了完整的架构搜索、加密经济激励和多级反博弈机制。

特征	PRISM	**固定架构子网**	**中心化** NAS	**随机**
搜索空间	完整（6 维）	固定	可变	可变
激励	是	是	否	否
跨预算	是	否	稀有	否
排名一致性	是	否	否	否
固定方案	是	否	否	否
反博弈	是	否	否	不适用

1.9. Training Challenge：去中心化预训练

1.9.1 动机

一旦 PRISM 确定了最优架构，网络就需要一种机制来训练生成的模型。Training Challenge 解决了 AI 开发中计算最密集的阶段：从零开始预训练大型语言模型。该挑战是 Subnet 3 上 Covenant-72B 所展示的去中心化训练的直接继承者，但集成到 Platform 的多挑战框架中。

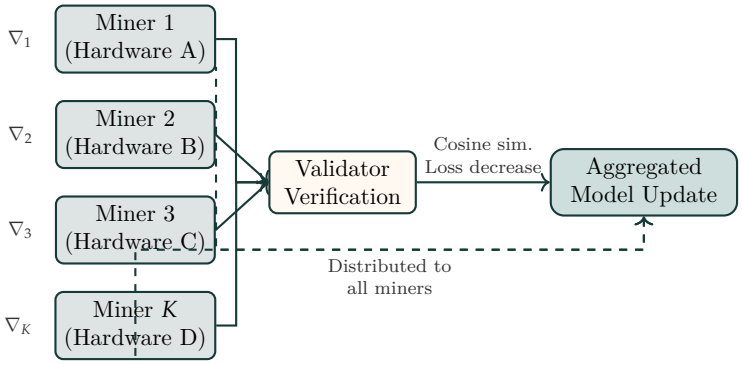

图 8 | Architecture diagram.

1.9.2 设计原则：完全去中心化

Training Challenge 有一个不可协商的设计约束：训练必须是完全去中心化的。与允许中心化编排的混合方法不同（在混合方法中，单一实体协调整个训练运行、分配数据分片并管理检查点），Platform 的 Training Challenge 要求没有任何单一实体控制训练过程。这一原则是公理性的，而非实用性的：Bittensor 的全部目的就是创建任何中央权威都无法捕获的系统，而中心化编排的训练运行将在最根本的层面上违反这一原则。

完全去中心化意味着：

- **无中心协调者**：矿工自组织为训练队列。协议规定了矿工如何发现对等节点、协商训练分配和同步检查点，所有这些都不需要中央调度器。
- **无受信任聚合者**：梯度聚合必须是可验证的。任何矿工或验证者都必须能够独立验证聚合更新是各个贡献的忠实组合。
- **无单点故障**：训练运行必须即使在个别矿工退出、提交格式错误的梯度或试图毒害更新的情况下也能继续进行。协议必须对 Byzantine 故障具有弹性。

1.9.3 开放研究问题

Training Challenge 正处于积极的研究和设计中。自主智能体正在进行研究以确定去中心化训练的最优架构方法，探索如何在保持完全去中心化的同时维持训练效率。关键的开放问题包括：

- **异构硬件下的梯度聚合**：矿工贡献不同类型的硬件，具有不同的内存和计算能力。协议应如何规范化和加权来自异构源的梯度贡献，同时保持收敛保证？
- **无中心编排的落后者缓解**：在中心化训练中，参数服务器可以检测并排除慢速工作节点。在去中心化环境中，没有这样的协调者。协议如何在没有中央时钟的情况下检测落后者并调整训练调度？
- **验证者对诚实梯度贡献的验证**：验证者接收矿工的梯度更新时，必须验证更新是诚实计算的（即在正确的数据分片上，使用正确的模型状态，且没有对抗性修改）。朴素验证需要重新计算梯度，这违背了分布式计算的目的。提供诚实性加密经济保证的最低成本验证协议是什么？
- Byzantine **环境中的检查点一致性**：当矿工对模型状态存在分歧时（由于丢失更新、网络分区或对抗行为），协议如何解决不一致并确保所有诚实矿工收敛到同一模型？

这些问题代表了去中心化 ML 系统研究的前沿。自主智能体正在并行探索这些问题，以单一研究团队无法匹敌的速度测试候选协议并迭代设计。Training Challenge 预计将是 Platform 生态系统中技术最复杂的挑战，其设计可能会在激活之前通过多个智能体驱动的研究迭代而演进。

1.9.4 与其他挑战的关系

Training Challenge 在 Platform 流水线中占据核心位置：

- **上游**：它接收 PRISM 发现的最优架构 (§4.3)。没有 PRISM 的搜索，Training Challenge 将训练一个次优架构，浪费大量计算资源。
- **下游**：其输出（预训练基础模型）作为 Data Fabrication 的 RL 微调流水线 (§4.2.5) 的基础。基础模型提供 RL 微调专业化为智能体能力的一般语言理解。
- **评估**：生成的训练智能体在 Term Challenge 上评估，提供反馈到架构搜索和训练策略选择的性能信号。

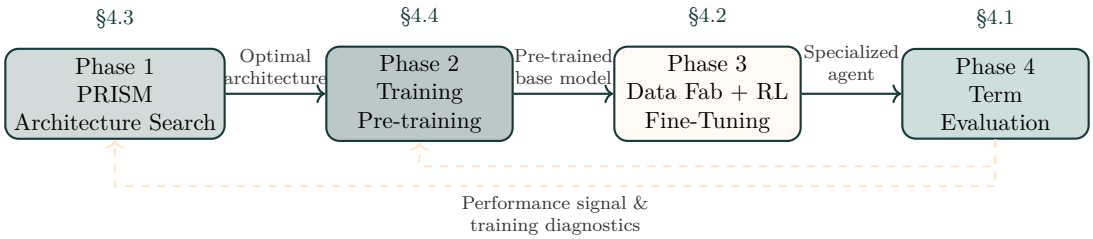

图 9 | Architecture diagram.

1.9.5 当前状态与时间线

Training Challenge 正处于积极的研究和设计中。它是 Platform 生态系统中技术最雄心勃勃的挑战。自主智能体正在领导研究工作，独立研究协议设计、测试候选架构，并迭代实现稳健的去中心化训练协议。根据当前智能体驱动的研究轨迹，Training Challenge 预计将于 2026 年 5 月下旬进入初步测试。

1.10. 挑战正交性与激励正交性

1.10.1 结构不相似性

四个挑战探测根本不同的能力维度：

表 2 | Platform 四个挑战类别的结构不相似性

挑战	能力维度	所需知识	策略类型	阶段
Term	工程执行	已知缺陷 + 修复空间	开发	4
Data Fabrication	合成质量	已知数据模式	生成	3
PRISM	架构搜索	未知架构空间	搜索	1
Training	去中心化预训练	已知架构，未知数据分区	协调	2

挑战	状态	预期激活时间
Term	Inactive (Platform 3.0)	May 2026
Data Fabrication	Upcoming 3.0	May 2026
PRISM	Upcoming 3.0	May 2026
Training	Research	Late May 2026

Term Challenge 奖励**开发**，即对已知问题的高效解决。Data Fabrication Challenge 奖励**生成**，即生产新颖、高质量的训练数据。PRISM 奖励**搜索**，即对指数级大的组合空间的系统探索。Training Challenge 奖励**协调**，即在没有中心编排的情况下向全球分布式训练运行贡献有用梯度更新的能力。这**四种策略**在结构上不相似：在一种策略上的能力不能预测在另一种策略上的能力，且每种策略的最优方法在算法上是截然不同的。

1.10.2 激励正交性

挑战的正交性创造了综合能力的非线性回报。专精于单一挑战的矿工面临边际回报递减，因为评估机制会适应（**自适应熵原则**）。跨多个挑战竞争的矿工可以在它们之间套利，将计算分配给当前每 FLOP 提供最高边际奖励的挑战。这为通用型矿工相对于专精型矿工创造了结构性优势，即**综合能力溢价**。

形式化地，设 $R_i(m)$ 表示矿工 m 从挑战 i 获得的奖励。在独立评分下，总奖励为 $R(m) = \sum_i R_i(m)$。对于在单一挑战 i^* 上最大化 R_{i^*} 且在其他挑战上收益为零的专精型矿工，由于 WTA 衰减，对 i^* 的额外计算的边际回报随投入递减。对于跨所有挑战分配计算的通用型矿工，每个 R_i 接收未饱和投资并处于高边际回报区间。当挑战正交（即 $i \neq j$ 时 $\mathrm{Cov}(R_i, R_j) \approx 0$）时，通用型矿工的期望总奖励严格超过专精型矿工。

1.10.3 释放分配

跨挑战的释放分配由 Atlas 3.0 自主决定，这是子网的自动化释放编排系统，它根据参与率、成熟度指标和已展示的影响力持续调整挑战权重，而无需手动治理投票或固定百分比分配。Data Fabrication Challenge、PRISM 和 Training Challenge 即将上线，预期时间线如下：

在所有四个挑战激活后，Atlas 3.0 将自主重新平衡释放以反映每个挑战对子网使命的已展示边际影响。

1.10.4 组合反博弈防御

多挑战设计是防止奖励黑客攻击的首要防御。每个单独的挑战都有自己的反博弈措施（Docker 容器化、基于 AST 的相似性分析、抄袭检测、Kendall 的 τ 硬杀死、梯度验证），但这些是一层防御：它们可以被足够精密的攻击者突破。多挑战架构提供二层防御：要获取子网释放的主导份额，矿工必须同时博弈**四**个演进的评估流水线，每个流水线具有不同的漏洞、不同的更新节奏和不同的检测机制。维护四个独立利用的组合成本远超真正的多挑战能力成本，使诚实参与成为均衡策略。

这一原则，即正交挑战的交集比任何单一挑战更难博弈，是一个超越 Platform 推广到任何多目标激励网络的设计贡献。

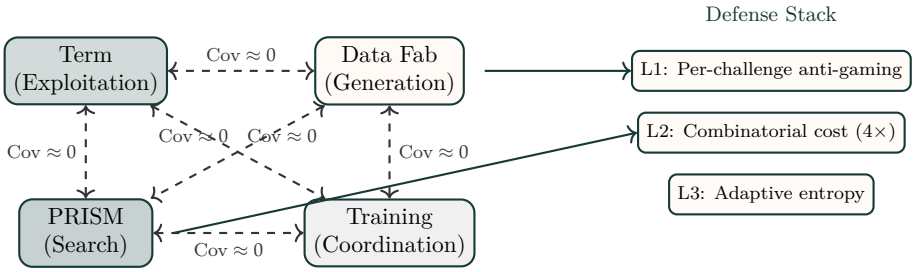

图 10 | Architecture diagram.

1.10.5 **端到端生产流水线**

四个挑战并非独立运行；它们构成了构建和评估 AI 智能体的**闭环生产流水线**。这种端到端结构是 Platform 的核心架构贡献，我们在此完整描述以使挑战之间的关系明确。

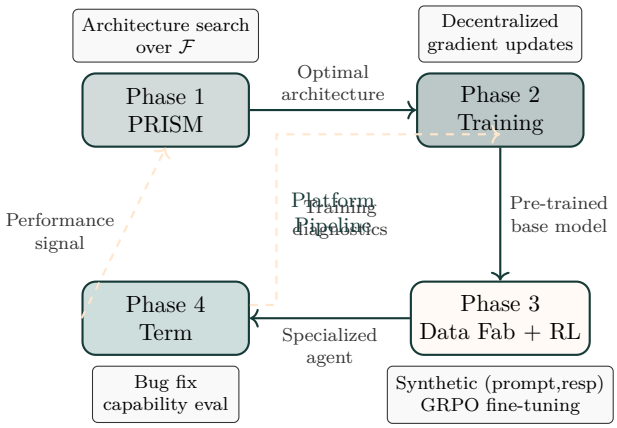

图 11 | Architecture diagram.

流水线在**四个阶段**中运行：

Phase 1**：架构搜索** (PRISM, §4.3)：矿工搜索架构空间 $\mathcal{F}$ 以发现最优模型配置。输出是完全指定的架构定义，决定了模型的归纳偏置、容量和计算需求。

Phase 2**：去中心化预训练** (Training Challenge, §4.4)：矿工使用 Phase 1 的架构集体训练基础模型。每个矿工贡献在本地数据分片上计算的梯度更新，这些更新由验证者验证并聚合为全局模型更新。训练过程完全去中心化：没有任何单一实体控制数据、梯度聚合或检查点调度。

Phase 3**：RL 微调** (Data Fabrication + RL, §4.2)：Data Fabrication 矿工生成针对 Platform 智能体必须具备的能力的领域特定 (提示, 响应) 对。单独的 RL 训练循环使用这些对微调预训练基础模型，应用策略梯度方法生成能够代码合成、缺陷发现和架构推理的专业化智能体。

Phase 4**：智能体评估** (Term, §4.1)：训练后的智能体在 Term Challenge（已知缺陷解决）上评估。这些挑战衡量智能体的开发能力，即与生产软件工程最相关的维度。

闭环反馈：评估结果反馈到架构搜索（Phase 1）和训练策略（Phase 2）。Term Challenge 表现低于预期的智能体表明架构或训练数据可能需要调整，创建一个自改进循环，网络持续优化自身的生产流水线。

2. **经济论证：为什么** TAO **胜过薪资**

2.1. **中心化** AI **中的人才问题**

AI 研究人才集中在少数企业实验室中，造成了一个从任何合理的经济指标来看都功能失调的劳动力市场。据估计，全球能够推进大规模机器学习前沿的研究人员池仅有数万人 (Maslej et al., 2024)，而满足典型招聘标准 (博士级专业能力、愿意迁移、签证资格) 的子集要小得多。这种

稀缺性，加上 AI 能力的战略重要性，引发了薪资飙升，这种飙升更类似于泡沫后期的动态，而非竞争市场的稳态均衡。

截至撰稿时，据报道 OpenAI、Anthropic 和 Google DeepMind 的高级 AI 研究员年薪从 $500,000 到超过 $2,000,000 不等 (Metz, 2024; Hao, 2023)。这种升级遵循一个可预测的模式：当一个实验室提高报价以挖角人才时，竞争对手会匹配或超越该报价，从而建立一个新的底线，成为下一轮招聘的基准。结果是一场劳动力成本的军备竞赛，随人数线性增长，但在能力上产生递减的边际收益：这是经典的红皇后动态 (Van Valen, 1973) 应用于人力资本的表现。

股权补偿加剧了这一问题而非解决了它。限制性股票单位和股权赠与创造了行业观察者所称的" **金手铐**"：研究人员在经济上受到激励留在当前机构，无论该机构是否仍然是他们工作的最佳环境。更关键的是，股权结构造成了激励错位：薪酬与单一公司产品商业成功挂钩的研究人员，有合理动机去优化专有优势而非开放的科学进步。希望在开放环境中构建 (发表方法、共享数据集、贡献公共基础设施) 的研究人员面临财务保障与学术自由之间的严峻选择。当前生态系统没有提供调和这些目标的可行替代方案。

这种人才瓶颈的结构性后果超越了个人薪酬的范畴。当最有能力的研究人员集中在不到十二个机构中时，下一个范式转换的突破来自该圈子之外的概率趋近于零，这不是因为外部人员缺乏能力，而是因为他们缺乏使前沿规模实验成为可能的资源、数据和计算访问权。因此，中心化模式创造了一个自我实现的预言：它通过限制访问来约束人才池，然后以缺乏外部突破作为人才池边界设定正确的证据。

2.2. Platform 的经济模型

Platform 的激励机制在每一个约束维度上都颠覆了中心化劳动力模型。中心化实验室通过招聘流程、签证要求、地理迁移和组织政治来限制参与，而 Platform 允许任何有互联网连接的人仅凭展示的能力来贡献并赚取 TAO 奖励。

TAO 排放的**无许可**特性不仅仅是一个设计选择，而是一个结构性公理。拉各斯的一位开发出优秀代码生成智能体的矿工，与旧金山拥有斯坦福大学博士学位的矿工，在相同展示能力下赚取的 TAO 完全相同。评估机制 (第 4 节描述的对抗性基准测试层) 在不知道矿工身份、资质或地理位置的情况下运行。这不是一种期望，而是系统的架构特性。验证者基于基准测试表现对矿工评分，排放按比例流向这些得分。没有招聘委员会，没有签证担保要求，没有偏袒高租金地区的生活成本调整。

这种无许可模型的经济意义是深远的。中心化 AI 实验室的可及人才池大致受三个集合的交集约束：具有博士级机器学习专业能力的个人 (全球估计 30,000–50,000 人; Maslej et al., 2024)，愿意迁移到少数城市的人员 (上述人员的约 50%)，以及有资格获得美国、英国或欧盟工作签证的人员 (上述人员的约 30%)。这产生了一个约 15,000–20,000 人的有效候选人池。相比之下，Platform 的可及人才池仅受互联网访问和技术能力的约束：全球约有 4500 **万**人被认为具有足够的编程技能可以作为矿工参与 (SlashData, 2024)，这一数字包括业余爱好者和学生，不仅限于专业人士。即使考虑到能够在前沿贡献的远小子集，Platform 的有效人才池至少比中心化替代方案大两到三个数量级。

Platform 上的奖励随展示的能力而增长，而非随资历、机构声望或政治资本。将 SWE-bench Verified 得分提高 5 个百分点的矿工，无论其发表记录、学术隶属关系或工作年限如何，都将获得相应比例的 TAO 排放增长。这种**绩效主义**结构消除了主导学术和企业 AI 研究的信号博弈：在这种博弈中，研究人员优化的是会议录用、引用次数或内部绩效评估，而非真正的能力提升 (Bergstrom & West, 2021)。

2.3. 定量比较

为使经济比较更加具体，表 2 展示了关键经济和结构指标的系统性比较。OpenAI 和 Anthropic 的数据来自公开报道和投资者披露;Platform 的数据根据链上排放数据和验证者仪表板计算得出。

最显著的差异在于人才池规模。中心化实验室从约 15,000 名受教育要求、签证可用性和地理流动性约束的合格候选人有效池中汲取人才。Platform 从约 4500 **万**名具有相关技术技能、仅受互联网访问约束的个人中汲取人才。这代表了可及人才约 2,900× 的扩张，这一差异随时间推

表 3 | 中心化实验室与 Platform：经济比较

指标	OpenAI	Anthropic	Platform
年度训练计算支出	$~3B	$~4B+	TAO **排放**[a]
研发人数	~4,000+	~1,500+	256 **矿工槽位上限**[b]
人才池规模	~15K	~15K	~45M[c]
地理覆盖范围	3–5 个城市	2–3 个城市	**全球** (**无许可**)
创新激励	薪资 + 股权	薪资 + 股权	TAO **排放** (**与绩效挂钩**)
评估机制	内部基准测试	内部基准测试	**对抗性** (**多层反博弈**; **第** 4 **节**)
部署新评估的时间	月	月	**小时** (Platform **治理**)

[a]Platform 的研发预算以 TAO 排放计价，而非美元; 其美元等值随市场价格波动，无法与固定美元预算的实验室预算进行有意义的比较。

[b] 每个 Bittensor 子网支持最多 256 个 UID 槽位，由矿工和验证者共享，每个子网默认最多 64 个验证者许可; 活跃矿工随参与者持续注册和注销而波动，因此时点计数不具有代表性。

[c] 根据 SlashData 2024 的全球开发者近似人口。

移而复合增长，因为 Platform 的激励结构吸引了那些永远不会出现在实验室招聘雷达上的贡献者。

年度研发支出的比较需要谨慎解读。OpenAI 和 Anthropic 各自在绝对美元金额上的支出要多出数个数量级。然而，Platform 的支出以 TAO(一种流动性市场定价资产) 计价，使得直接的美元比较具有误导性。Platform 的 TAO 排放几乎完全用于能力生产 (基于基准测试表现的矿工奖励)，而中心化实验室的支出则包括设施、管理开支、招聘成本以及可能永远无法部署的项目。Platform 的支出与直接能力产出的比率远比原始数据所显示的更有利。

评估机制一行进一步凸显了 Platform 的结构性优势。中心化实验室的内部基准测试由衡量其表现的同一组织开发、维护和解读，这种利益冲突已经产生了大量有据可查的基准测试博弈和选择性报告案例 (Birhane et al., 2023)。Platform 的**对抗性评估**，凭借其多层反博弈框架 (第 4 节) 和对发现操纵行为的验证者的财务激励，创造了一个在结构上比任何内部流程都更可信赖的评估环境。

2.4. **飞轮效应**

上述经济模型并非静态的。它通过一个正反馈循环运行，我们称之为**激励飞轮**，它映射并延伸了在成功开源生态系统中观察到的动态。

在开源软件中，飞轮通过声誉激励运行：贡献者构建软件，软件获得采用，贡献者获得声誉和职业资本，从而吸引更多贡献者 (Raymond, 1999; Lerner & Tirole, 2002)。这种机制产生了 Linux(驱动几乎所有云基础设施)、Python(主导机器学习) 和 PyTorch(在研究环境中取代了企业支持的 TensorFlow)。然而，声誉激励是间接的、缓慢的、不可靠的; 它们无法维持前沿 AI 所需的那种持续、高强度的贡献。

Platform 补充了缺失的要素：与能力生产对齐的直接、可衡量的财务激励。飞轮的运行方式如下：矿工在基准测试中竞争，产生可衡量的能力提升; 这些提升增加了子网产出的感知价值; 产出价值上升增加了 TAO 需求和价格; 更高的 TAO 价格增加了排放奖励的美元价值; 更大的奖励吸引更多矿工; 更大的矿工池加剧竞争，推动进一步的能力提升。这个循环是自我强化的，而且关键在于，它不依赖任何中央协调者或资金决策; 它从协议级排放规则和市场驱动的价格发现的交互中涌现。

图 9 展示了这一飞轮。每个箭头代表一个无需中心化指导即可运作的因果机制，由个体矿工和验证者响应协议激励的理性行为驱动。

历史先例具有启发意义。Linux 最初是一个没有财务激励结构的学生项目; 它花了十年时间才达到企业采用。Platform 的飞轮通过以直接的财务奖励替代声誉资本的缓慢积累来压缩这一时间线。Linux 贡献者可能需要等待数年才能使其工作被认可和奖励 (如果有的话)，而 Platform 矿工在展示改进的基准测试表现后数小时内即可收到 TAO 排放。结果是一个保留了开源的开放性和无许可贡献特性的激励结构，同时增加了市场驱动奖励的紧迫性和规模。

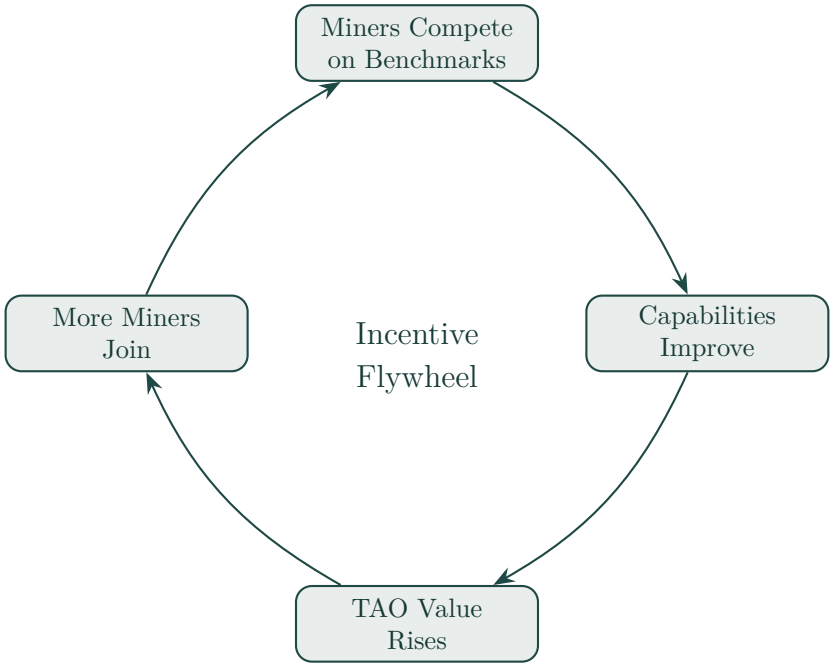

图 12 | Architecture diagram.

3. 去中心化 AI 能否与中心化实验室竞争?

3.1. 怀疑论观点 (以及它为何是错误的)

一个由无许可矿工组成的去中心化网络能够产生与花费数十亿美元的中心化实验室竞争的 AI 能力，这一主张表面上看是非同寻常的。怀疑是有道理的。我们依次回应四种最常见的反对意见。

反对意见 1**：**" **实验室拥有更多计算资源**。" 在狭义上这是正确的，OpenAI 和 Google DeepMind 各自控制的计算集群比任何单个 Platform 矿工能够组装的都大。但这种表述混淆了计算集中与计算容量。Platform 不需要单一的整体训练运行; 它将计算分布在数千个独立节点上，每个节点贡献总量的一小部分。Covenant-72B 模型精确地展示了这种架构：在无许可的 Bittensor 节点上训练，整个训练运行期间累计至少 70 个独立对等节点 (每轮上限 20 个贡献者，平均 16.9 个)，无需中心化编排，它取得了 67.1 的 MMLU 得分，与 Meta 的 LLaMA-2-70B 在 65.6 MMLU(0-shot) 的得分具有竞争力。其含义是清晰的：前沿规模的分布式训练不是理论可能性，而是经验事实，而且随着编排技术的改进，分布式训练与中心化训练之间的性能差距正在缩小。

此外，Platform 可用的总计算量不受任何单一实体预算的约束。它仅受独立运营商部署硬件以追求 TAO 奖励的总意愿约束，这一总量随 TAO 价格增长且没有理论上限。截至撰稿时，Bittensor 网络在所有子网上的聚合计算能力可能相当可观，尽管这一说法尚未得到独立验证，且很可能被最大的中心化集群所超越。

反对意见 2**：**" **实验室拥有更好的数据**。" 这一反对意见在历史上更有分量，但正在迅速减弱。训练数据格局已经经历了向商品化的结构性转变。Common Crawl 提供 2500 **亿**网页;The Pile 提供 825 GB 的精选文本;RedPajama 以 1.2 **万亿**词元复制了 LLaMA 训练混合 (Weber et al., 2024)。这些数据集对 Platform 上的任何矿工都是免费可用的。此外，Platform 的 Data Fabrication Challenge 为矿工提供了一种贡献和因生产高质量合成和精选数据而获得奖励的机制，而这正是实验室视为专有优势的资产。在 Platform 的激励模型下，数据生产的经济学发生了翻转：实验室将数据作为竞争壁垒囤积;Platform 将数据贡献作为公共物品予以奖励，创造了一种随网络增长而复合增长的结构性优势。

反对意见 3**：**" **实验室拥有更好的研究人员**。" 这正是第 5 节旨在回答的反对意见。该主张基于一个假设，即顶级实验室雇用的数万名研究人员 (Maslej et al., 2024) 代表了对全球人才分布的合理完整采样。事实并非如此。中心化招聘管道 (排名前五的项目的博士，然后是博士后工

作，然后迁移到旧金山或伦敦) 系统性地排除了绝大多数有能力的个人：那些无法进入精英机构的人，那些无法移民的人，那些离开学术界进入工业界的人，以及那些从未进入正式研究管道的人。Platform 的无许可模型从一个人才池中采样，该人才池按保守估计 100–500× 更大。下一个 Transformer 规模的架构洞察不必来自旧金山的实验室。它可以来自世界上任何地方的矿工，在 Platform 的激励结构下，无论来源如何，都将获得相同的奖励。

反对意见 4：”实验室可以在内部进行架构搜索。” 这一反对意见表面上有道理：DeepSeek 明显地进行了架构搜索并产生了创新 (MLA、无辅助损失的负载均衡、CSA)。但这一论点混淆了能力与结构性优势。一个单一的实验室，无论多么有才能，只能评估其研究团队优先考虑的架构。DeepSeek 的搜索受限于一个团队的规模、专业知识和制度偏见。PRISM 的搜索仅受愿意在架构空间未探索区域质押计算的矿工数量约束，这一池随 TAO 价格增长且没有理论上限。架构搜索定理 (第 4 节) 证明了当组合空间超过一个适度的规模阈值时，去中心化搜索在可证明意义上优于任何单智能体搜索。DeepSeek 的研究团队大约有 150 名研究人员;Platform 的搜索池是所有矿工的集合，在当前 Bittensor 子网容量下可达到 256 个同时活跃的矿工，参与持续轮换。搜索广度比率不仅仅是更大：它在质上是不同的，因为去中心化矿工没有对熟悉方法的制度偏见。

3.2. Platform 已经胜出的领域

即使 Platform 与中心化实验室之间的能力差距尚未完全弥合，Platform 已经在三个结构性而非渐进性的领域拥有决定性优势：这些优势是中心化实验室在不从根本上改变其组织形式的情况下无法复制的。

评估。没有任何中心化实验室运行着具有多层反博弈框架 (第 4 节)、对发现操纵行为的验证者提供财务激励、以及通过 Platform **治理**进行实时修补的对抗性评估系统。OpenAI 和 Anthropic 的内部基准测试服务于双重目的，评估和营销，这造成了不可调和的利益冲突。当一个实验室报告自己的基准测试结果时，该评估在结构上是可疑的。当 Platform 验证者对矿工评分时，他们在财务上受到激励以发现和惩罚任何形式的博弈行为，从而产生按设计比任何自我评估都更可信赖的评估。从 SWE-bench 基线到 SWE-Forge 数据集的转变 (一种将评估信号从不可靠质变为可信赖的质变; 参见第 4 节) 展示了系统以没有任何中心化基准测试工作所匹敌的速度和精度进行自我纠正的能力。

架构搜索。这是 Platform 最具决定性的结构性优势，也是最有经验证据直接支持的优势。DeepSeek 的竞争轨迹表明，架构创新是 AI 能力的首要决定因素。每一代 DeepSeek 引入了 1 到 3 个新的架构组件 (MLA、无辅助损失的负载均衡、多词元预测、压缩稀疏注意力)，这些组件带来了额外计算无法复制的效率提升。DeepSeek-V3 训练一个与 GPT-4 竞争的 671B 模型的总训练成本为 $5.576M，大约比估计的 GPT-4 训练成本低 10×，而且每一项效率提升都来自架构层面。PRISM(第 4.4 节) 系统化了这一搜索过程：不是一个研究团队以 6 到 12 个月的周期迭代，而是数百个竞争性激励的矿工同时探索架构空间，四级漏斗自动呈现最佳候选。没有任何中心化实验室能够在不雇佣数百名研究人员并运行数十个并行原型活动的情况下匹配这一搜索广度，这是没有任何实验室表现出意愿承担的组织和财务承诺。架构搜索定理 (第 4 节) 将这一优势形式化：如果搜索空间中至少包含一个优于固定基线的改进，具有架构搜索的子网将实现严格更高的均衡能力。

适应性。当在 Platform 上发现新的评估博弈向量时，Platform 治理可以在数小时内部署纠正性补丁。当中心化实验室发现其基准测试已被破坏时，更新评估标准、重新运行实验和修改公开声明的过程需要数月时间，如果实验室承认问题的话。这种不对称性是结构性的：中心化实验室是具有官僚惯性、公共关系担忧和对现有评估框架沉没成本承诺的组织。Platform 是一个具有自动执行、没有公关部门、对任何特定基准测试配置没有声誉投入的协议。Platform 治理通过持续的参数监控和调整实现了这种适应性。

3.3. 收敛论题

过去两年 AI 能力发展的轨迹支持一个**收敛论题**：开放与封闭 AI 系统之间的差距正在缩小而非扩大，Platform 有望加速这一收敛。

考虑以下证据。Meta 的 Llama 3.1 405B 在大多数标准基准测试上实现了与 GPT-4 竞争的

性能 (Grattafiori et al., 2024)。DeepSeek V3 在推理和数学基准测试上与 Claude 3.5 Sonnet 具有竞争力，尽管在编程任务上明显落后，其最终训练运行的报告成本为 $5.576M(DeepSeek-AI, 2024)，仅是 GPT-4 级模型在计入研发、失败运行和数据采集后的估计 $50–100M+ 总成本的一小部分 (Epoch AI, 2024)。Mistral 的开放模型在同等或更小参数量下优于开放替代方案 (Jiang et al., 2023)。这些数据点并非异常; 它们代表了由三种力量驱动的系统性趋势：训练数据的商品化、分布式训练技术的成熟，以及架构创新通过发表和开源发布的扩散。

关键的是，收敛并非由开源模型通过计算扩展追赶上来所驱动，而是由架构创新在生态系统中的扩散所驱动。DeepSeek-V2 的 MLA、DeepSeek-V3 的无辅助损失负载均衡，以及 DeepSeek-V4 的 CSA 都是架构层面的洞察，一旦发表，就对任何实现者可用。Platform 通过为架构发现创造持续激励来加速这种扩散：独立发现类似 MLA 效率提升的矿工可赚取 TAO 奖励，而在中心化模型中，同样的洞察将在发表前一直锁定在单一实验室中。从固定架构问题的视角来看，收敛论题并非指开放模型将通过蛮力最终匹配封闭模型; 而是指架构搜索在适当的激励下，使变革性架构创新的发现成为一个持续过程而非偶发事件。

Platform 通过提供开源 AI 历史上一直缺乏的结构性要素来加速这一收敛：一个持久的、可扩展的能力生产激励机制。开源 AI 生态系统产生了显著的成果 (PyTorch、Hugging Face Transformers、Llama 模型家族)，但这些贡献主要依靠企业赞助 (Meta 对 PyTorch 的资金支持、Hugging Face 的风险投资) 和志愿者努力来维持，而非依靠一个自我维持的经济模型。Platform 引入了这种经济模型。开发出更好的微调方法、更高效的架构或更高质量数据集的矿工，可以赚取反映其贡献市场价值的 TAO 奖励，而非企业赞助商的善意或资助资金的变幻莫测。

我们预测，最好的开源编码智能体、最好的神经架构搜索系统和最好的自动化数据管道很可能将是开放的，这不是因为开放性在意识形态上更优越，而是因为 Platform 的激励结构使其在经济上更优越。收敛由基本面驱动：一个 100–500× 更大的无许可人才池，一个在结构上更可信赖的评估系统，以及一个将能力提升直接转化为财务奖励而无需组织官僚摩擦的经济模型。

图 10 展示了这一收敛。封闭 AI 能力曲线遵循一个趋于平坦的 S 形曲线，因为它遭遇了集中投资递减的收益：每增加十亿美元的计算产出越来越小的增量收益，而人才池已经完全饱和。Platform 曲线遵循一个更陡峭的轨迹，随着分布式计算扩展、矿工群体增长以及基准测试驱动的评估加速能力提升而追赶上来。

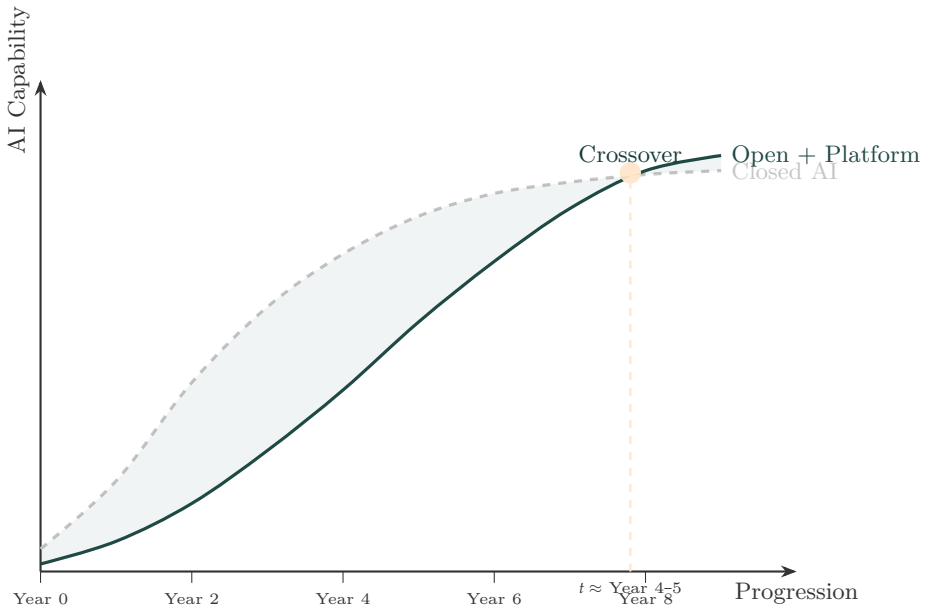

图 13 | Architecture diagram.

3.4. Platform **需要做对的事情**

收敛并非不可避免。它是基于当前趋势和结构性优势的预测，其实现取决于 Platform 成功应对若干关键挑战。

规模。Platform 当前的矿工和验证者群体虽然在增长，但相对于其理论可及池仍然较小。第 5.4 节描述的激励飞轮需要足够的矿工竞争来推动有意义的能力提升; 低于临界规模时，奖励的竞争不足，无法产生前沿成果。协议必须继续吸引足够数量的矿工 (生产能力) 和验证者 (评估能力)，以维持使飞轮运作的竞争动态。排放率和子网权重必须经过校准，以在吸引新参与者和维持足以证明高强度贡献合理性的奖励密度之间取得平衡。

基准测试。 Platform 产出的质量受其评估质量的约束。SWE-Forge 展示了从借用基准测试 (SWE-bench) 转向专用数据集生成器可以在质上将评估从不可靠信号转变为可信赖信号，一种从噪声到信号的质变。这种模式必须在 Platform 所针对的每个能力领域中复制。PRISM 的分级过滤架构提供了一个模板，但每个新领域都需要领域特定的评估设计、对抗性测试和持续优化。风险不在于基准测试不完美 (所有基准测试都是如此)，而在于它们在能够更新之前就变得过时、易受博弈或与现实世界能力不对齐。Platform 治理的实时修补减轻了这一风险，但并未消除它。

治理。 Platform 治理代表了向社区驱动的评估治理迈出的第一步，但 Platform 的长期可行性取决于其治理结构的成熟。谁决定基准测试何时失效？谁裁决矿工和验证者之间的争议？谁设定决定 TAO 如何在子网和能力之间流动的排放权重？这些问题既有技术成分 (可衡量的腐败检测、可验证的评分)，也有社会成分 (合法性、公平性、透明度)。中心化替代方案 (单一组织控制这些决策) 具有清晰性的优点，但也有权力不可问责的缺点。Platform 必须开发既有效又合法的治理机制，这是去中心化系统历史上一直在努力应对的挑战 (Dafoe et al., 2021)。

合作伙伴与采用。归根结底，Platform 的价值主张取决于现实世界中的实用性。如果 Platform 矿工生产的智能体、架构和数据仅在 Bittensor 生态系统内使用，飞轮就会停滞。企业采用 (公司使用 Platform 矿工挖掘的编码智能体、研究机构使用 PRISM 发现的架构、数据管道消费 Platform 策划的数据集) 是 TAO 需求维持价格的机制，而价格维持排放价值，排放价值维持矿工参与。采用路径不仅需要技术能力，还需要集成工具、可靠性保证，以及与风险规避组织建立信任。在这个领域，中心化实验室凭借现有的客户关系、销售组织和合规基础设施拥有显著优势。Platform 必须构建等效的路径，或者更有可能的是，使第三方能够在其协议之上构建这些路径。

这些挑战是真实的，但可以应对。没有一个代表根本上的不可能; 每一个都是社区可以逐步解决的工程和治理问题。Platform 已经展示的成果 (Covenant-72B 在无许可节点上训练、SWE-Forge 在数据集质量和评估可信赖性上的质变、PRISM 的大规模分级架构、Platform 治理的实时评估修补) 提供了强有力的证据表明核心机制是有效的。问题不在于去中心化 AI 能否竞争，而在于 Platform 能否足够快地扩展其优势以产生意义。收敛论题表明它可以，本文提出的结构分析表明它应该如此。

4. 去中心化分析

任何去中心化 AI 系统的可行性不仅取决于其技术性能，还取决于权力、计算、经济和治理在参与者之间真正分布的程度。通过单一控制实体实现强劲基准测试结果的系统，不过是重演了其表面上反对的中心化。在本节中，我们将去中心化形式化为可度量的属性，将其应用于 Covenant-72B 的训练分布，证明架构搜索相对于固定设计的结构性优势，并在 Yuma Consensus 的验证者激励框架下为诚实参与建立博弈论保证。

4.1. 形式化去中心化度量

我们采用**香农熵**作为去中心化的主要度量，遵循 (Shannon, 1948) 建立的信息论传统以及 (Srinivasan & Lee, 2017) 对分布式系统的形式化。给定子网中的 n 个参与者，令 p_i 表示参与者 i 获得的总奖励（或质押）份额，其中 $\sum_{i=1}^{n} p_i = 1$。去中心化熵为：

$H = -\sum_{i=1}^{n} p_i \log_2(p_i)$

该量在所有参与者获得相等奖励时（对所有 i，$p_i = 1/n$）达到最大值 $H_{\max} = \log_2(n)$，并在奖励集中于单一参与者时趋近于零。为在不同规模的子网间进行归一化，我们定义**去中心化比率**：

$D = \frac{H}{H_{\max}} \in [0, 1]$

$D = 1$ 对应完全去中心化（均匀奖励分布）；$D = 0$ 对应完全中心化（所有奖励归于单一实体）。我们注意到 D 是归一化泰尔指数的补集（$D = 1 - T/T_{\max}$），并具有其理想的分解性质：子群不平等性可以分解为组内和组间分量 (Theil, 1967)。

我们还报告**中本聪系数** κ，定义为集体持有超过 50% 质押或奖励所需的最少实体数。形式化地，若参与者按 $p_1 \geq p_2 \geq \cdots \geq p_n$ 排序，则：

$\kappa = \min\left\{k : \sum_{i=1}^{k} p_i > 0.5\right\}$

二元组 (D, κ) 提供了完整的去中心化画像：D 刻画分布平滑性，κ 刻画抗合谋性。

4.2. Covenant-72B **训练分布**

Covenant-72B 在整个训练运行期间累计跨越至少 70 个独立节点进行训练（每轮上限 20 个贡献者，平均 16.9 个），分布于多个大洲，不存在单一运营者、司法管辖区或故障域。

这种对比是类别性的，而非渐进性的。中心化训练运行，无论其计算集群多么庞大，都将所有计算收缩到单一控制点。Covenant-72B 的分布式训练反映了在独立参与者之间的真正分布，不存在共享控制。

这种分布不仅是理想属性，更是安全保证。集中于单一数据中心的训练运行容易受到物理没收、法律强制和灾难性硬件故障的影响 (Brundage et al., 2020)。跨越多个司法管辖区至少 70 个节点的分布式运行不面临任何此类单点故障。从这个意义上说，去中心化是一种文明级别的容错形式。

4.3. **架构搜索定理**

我们现在形式化架构搜索相对于固定架构训练所赋予的结构性优势。这一结果支撑了 PRISM 的设计，并解释了为什么其组合搜索空间（数千种分类配置乘以四个连续维度，产生庞大的候选架构空间）不仅是庞大的，而且是有利地庞大的。

定理 1 **（架构搜索优越性）**。设 $\mathcal{F}$ 为架构族。在 $\mathcal{F}$ 上进行搜索的子网，相较于局限于单一 $a \in \mathcal{F}$ 的任何固定架构子网，实现严格更优的期望扩展，前提是 $|\mathcal{F}| \geq 2$ 且搜索子网每个周期至少评估 $K \geq 1$ 个候选。

证明。考虑 $\mathcal{F}$ 中任意固定架构 a，分配计算量 C_a。搜索子网将计算量 $C_{\text{search}} = \sum_{i=1}^{m} C_{a_i}$ 分配给来自 $\mathcal{F}$ 的 m 个候选架构，然后选择表现最优的 K 个进行完整评估。令 $\sigma(a)$ 表示架构 a 在计算量 C_a 下的性能，令 $\sigma^* = \max_{a \in \mathcal{F}} \sigma(a)$ 表示 $\mathcal{F}$ 内可达到的最优性能。

由构造可知，搜索子网的期望性能为：

$\mathbb{E}[\sigma_{\text{search}}] = \mathbb{E}\left[\max_{i \in \text{top-}K} \sigma(a_i)\right]$

对 $\mathcal{F}$ 中任意固定 a，有：

$\mathbb{E}\left[\max_{i \in \text{top-}K} \sigma(a_i)\right] \geq \mathbb{E}[\sigma(a)]$

当且仅当 a 是 σ 在 $\mathcal{F}$ 上的唯一最大化者时等号成立。当 $|\mathcal{F}| \geq 2$ 且 $\mathcal{F}$ 上的性能存在差异时（实际上确实如此，因为不同架构在归纳偏置、容量和可训练性上有所不同），不等式是严格的。这一结论遵循与多臂老虎机策略优于固定臂策略相同的论证 (Lai and Robbins, 1985; Auer et al., 2002)：探索多样化组合并选择最优者，不可能被先验地承诺任何单一臂所支配。□

推论。架构搜索相对于任何固定架构的期望优势随 $|\mathcal{F}|$ 单调递增。这就是 PRISM 的搜索空间（六个维度上的数千种分类配置，进一步由四个连续维度参数化）不仅是庞大的原因；它在结构上是有利的。$\mathcal{F}$ 中每增加一个架构都代表了对可能更优的归纳偏置的一个免费期权，而增加此类期权的成本受 PRISM 漏斗的筛选阶段所约束。

其实际意义是直接的。训练单一架构的中心化实验室必须在训练开始前就确定设计；架构选择中的错误是不可挽回的沉没成本。运行 PRISM 的子网可以以极小的计算代价评估数千个候选架构（横跨分类和连续维度），发现没有任何人类设计师会选择的架构。搜索空间本身成为竞争优势的来源。

表 3 报告了基准测试结果。Covenant-72B 在 MMLU（+1.5）和 ARC-Easy（+1.3）上超越 LLaMA-2-70B，这两项基准测试高度重视通用事实知识和基础推理。中心化基线在 HellaSwag、PIQA、WinoGrande、ARC-Challenge 和 OpenBookQA 上保持优势，这些基准测试奖励常识补全和定向问答。总体图景是大致持平，这本身就是引人注目的结果：一个在整个训练运行期间累计跨越至少 70 个独立节点（每轮上限 20 个，平均 16.9 个）训练的模型，在没有单一控制实体的情况下，其性能达到了在 Meta 大规模计算基础设施上训练模型的差距范围之内 (Touvron et al., 2023)。剩余的差距是训练效率差距，而非去中心化惩罚。

表 4 | Covenant-72B 基准测试结果。去中心化训练（整个训练运行期间累计至少 70 个独立节点，每轮上限 20 个，平均 16.9 个）匹配或超过 Meta 在其计算集群上训练的中心化基线。差值计算为 Covenant-72B 减去 LLaMA-2-70B。

基准测试	Covenant-72B	LLaMA-2-70B	Δ
MMLU	67.1	65.6	+1.5
ARC-Easy	80.9	79.6	+1.3
HellaSwag	80.61	84.34	−3.73
PIQA	81.56	82.59	−1.03
WinoGrande	75.85	80.43	−4.58
ARC-Challenge	56.83	57.42	−0.59
OpenBookQA	44.00	49.40	−5.40

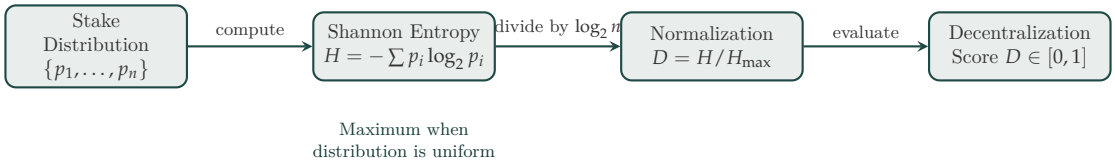

图 14 | Architecture diagram.

图 11 展示了从原始质押分布到归一化去中心化评分的计算流水线。该流水线是确定性的，无需主观参数，使其适用于链上计算和治理集成。

4.4. Yuma Consensus **下的验证者激励框架**

前述分析假设奖励按照真实贡献进行分配。在实践中，任何激励系统都面临博弈操纵：参与者可能合谋、虚报或搭便车。Yuma Consensus 下的验证者激励框架提供正式保证：在 Bittensor 的原生验证者框架下，诚实评估构成 Nash 均衡。

定义（Yuma Consensus）。给定一组验证者 $\mathbb{V}$，具有质押权重 $\{S_i\}_{i\in\mathbb{V}}$，每个验证者对 n 个矿工产生权重向量 $\mathbf{w}_i$，Yuma Consensus 将每个矿工 j 的共识权重计算为 $\overline{W_j} = \arg\max_w \left(\sum_{i\in\mathbb{V}} S_i \cdot \mathbb{1}[W_{ij} \geq w] \geq \kappa\right)$，其中 kappa 参数 κ 指定达成共识所需的最小总质押份额（通常 $\kappa > 0.5$，即多数阈值）。

命题 1 **（诚实均衡）**。在 $\kappa > 0.5$（多数质押阈值）的 Yuma Consensus 下，诚实评估（报告与矿工真实质量成正比的 $\mathbf{w}_v$）构成 Nash 均衡。

证明梗概。验证者 v 获得的排放量与其权重 $\mathbf{w}_v$ 和共识权重之间的一致性成正比。在 $\kappa > 0.5$ 的诚实评估下，质押加权阈值对异常值具有鲁棒性：任何偏离诚实报告的单一验证者都无法将共识权重偏移到足以增加自身排放的程度，因为阈值由诚实多数质押决定。偏离的期望排放上界为诚实报告的排放减去不一致惩罚，从而产生报告诚实的严格激励。□

命题 2 **（抗合谋性）**。在 $\kappa > 0.5$（多数质押阈值）的 Yuma Consensus 下，控制总质押份额低于 κ 比例的联盟合谋以偏移共识权重使其有利于自身，所获得的边际奖励为零。

证明梗概。在 $\kappa > 0.5$ 且联盟控制的总质押份额低于 κ 比例的情况下，持有多数质押的诚实验证者在每个分量上决定共识阈值。合谋联盟的质押低于 kappa 阈值，其权重被排除在共识计算之外。联盟无法移动共识权重，因此无法增加其排放份额。任何用于合谋的资源投入都产生严格的负回报。□

命题 3 **（自我惩罚偏离）**。任何偏离共识权重的验证者，其自身排放份额按偏离程度成比例减少。

这直接由 Yuma Consensus 的排放公式得出，该公式根据验证者与共识的不一致程度对其排放进行折减。系统性地偏重某一受青睐矿工的验证者，以减少排放为代价为其偏离行为付出代价，这是一种无需外部执行的自我惩罚机制。

综合而言，这三个命题确立了 Yuma Consensus 下的验证者激励框架使诚实参与成为占优策略：它是个体理性的（命题 1），对控制质押份额低于 κ 比例的联盟具有抗合谋性（命题 2），

且是自我强化的（命题 3）。该机制以**无需信任**的博弈论方式运作：任何参与者都无需信任其他参与者，因为激励结构使诚实行为成为唯一均衡。

这对 Platform 的实际意义是直接的。第 4 节所述的多层反博弈框架在该均衡内运作：试图博弈操纵基准评估的验证者面临自我惩罚的偏离成本，控制质押份额低于 κ 比例的联盟在结构上是无效的。Yuma Consensus 下的验证者激励框架将反博弈问题从社会信任问题转化为数学保证；这正是去中心化系统所需要的转化。

5. 结论与路线图

5.1. 贡献总结

本文提出了 Platform，一个构建于 Bittensor 子网 100 之上的去中心化 AI 开发系统，并论证了**基准驱动的激励设计**能够产生与中心化实验室竞争的 AI 能力。我们的贡献涵盖架构、评估、训练和治理：

1. **多挑战架构**。 Platform 是首个在统一激励框架内评估正交 AI 能力（软件工程、神经架构搜索和合成数据生成）的 Bittensor 子网。这一架构选择确保矿工无法通过过度优化单一能力轴来博弈操纵系统（第 3 节）。

2. SWE-Forge。一个持续数据集生成器，从真实 GitHub 拉取请求中提取评估实例，产生实际上无限供应的新鲜、抗博弈操纵的基准数据集。SWE-Forge 通过确保评估分布的迁移速度快于矿工的适应速度，解决了博弈向量编目问题（第 4 节）。

3. PRISM。 PRISM（Platform 递归搜索空间形态探究）是一个目前正在积极开发中的即将推出的挑战。PRISM 将评估神经架构搜索，奖励发现在同等计算预算下优于固定基线的新颖架构的矿工。详细的评估漏斗正在积极研究中；当前方向涉及一个逐步验证候选架构的多级过滤流水线（第 4 节）。

4. Terminal-Bench 2.0 **到** SWE-Forge **的过渡**。反博弈设计的案例研究：在矿工开发出在不提升真实能力的情况下最大化分数的策略后，Terminal-Bench 2.0 被退役。SWE-Forge 的数据集生成通过前后验证、Docker 容器化和字符串匹配拒绝来封堵这些漏洞（第 4.1 节）。

5. Covenant-72B。一个 720 亿参数模型，在整个训练运行期间累计跨越至少 70 个独立节点进行训练（每轮上限 20 个贡献者，平均 16.9 个），分布于多个大洲，在 MMLU 上达到 67.1，在 ARC-Easy 上达到 80.9，与 Meta 在其计算集群上训练的 LLaMA-2-70B 具有竞争力。Covenant-72B 在子网 3（Templar；历史）上训练，构成了去中心化训练不仅可行而且具有竞争力的存在性证明（第 7.2 节）。

6. **多层反博弈框架**。任何去中心化系统中对抗性最强的评估流水线，包含基准设计、前后验证、Docker 容器化、反作弊评分和基于智能体的验证（第 4 节）。

7. Platform **治理**。子网上的持续治理机制，自动化超参数调整、权重调制和子网参数演化。Platform **治理**弥合了历史上博弈策略快于人工响应的治理延迟差距（第 3.2 节）。

8. **验证者激励框架**。正式的博弈论保证（诚实评估作为 Nash 均衡、低于阈值的抗合谋性、自我惩罚偏离），将无需信任运作确立为数学属性而非社会假设（第 7.4 节）。

5.2. 未来路线

Platform 的发展轨迹由一系列能力扩展所定义，每一项都建立在本文建立的基础设施和保证之上：

近期： PRISM 主网启动，将架构搜索从模拟过渡到 Bittensor 上的实时激励加权评估。Data Fabrication alpha 版本发布，支持在与模型评估相同的反博弈框架下评估合成数据集生成。

中期：企业集成：首家外部公司在生产工作流中部署 Platform 挖掘的智能体。这一里程碑不仅在基准测试维度验证核心主张，更在经济维度验证：智能体必须为真实用户交付真实价值，而非仅仅在构造的评估上获得高分。

长期：收敛点。如果当前扩展趋势持续（PRISM 的架构优势、SWE-Forge 的持续数据集生成、验证者激励框架的激励保证），Platform 产出的开放去中心化 AI 能力将匹配或超过中心化实验室可提供的最佳闭源模型。这不是对特定时间点能力持平的预测；而是关于两条轨迹收敛的结构性论证。中心化实验室仅从规模面临**收益递减** (Ho et al., 2024)，而去中心化系统则从参与者多样性、搜索空间广度和治理适应性中获得递增回报。图 10 阐释了这一结构性收敛论证。

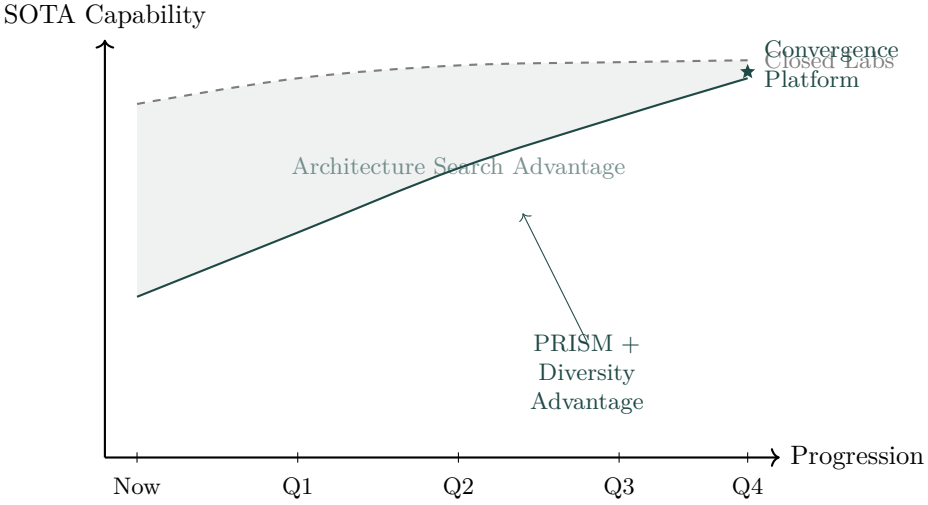

图 15 | Architecture diagram.

5.3. 启示

本文结果对当前主流的 AI 发展模式提出了一个直接且令人不安的启示。主流范式认为前沿 AI 能力需要巨大的资本集中：数十亿美元的融资轮次、数千人的团队、以及将结果与外部审查隔绝的封闭评估流程。这一范式产生了有能力的模型，但也产生了单点故障、治理瓶颈，以及结构性的评估不诚实——因为评估者和被评估者是同一实体。

Platform 证明 AI 开发不需要数十亿美元的融资轮次、千人团队或封闭评估。它需要三件事：

1. **衡量真实能力的基准**。不是代理指标，不是容易遭受梯度黑客攻击的排行榜，而是从真实世界任务中导出（通过 SWE-Forge 数据集）并对照详尽的博弈向量分类法验证 (Terminal-Bench 2.0) 的持续刷新评估。
2. **奖励真实贡献的激励**。不是容易遭受合谋的基于信任的系统，而是 Yuma Consensus 下的验证者激励框架，其中诚实参与是唯一 Nash 均衡，偏离是自我惩罚的。
3. **适应速度比博弈策略更快的治理**。不是响应周期长达数月的人工监督委员会，而是根据新兴攻击模式实时调整参数的持续治理机制。

Platform 提供了全部三者。问题不在于去中心化 AI 能否与中心化实验室竞争。问题在于中心化实验室能否足够快地适应以与 Platform 竞争。

“最好的架构是你不必选择的架构。”
PRISM，大致如此。

6. 参考文献

Auer, P., Cesa-Bianchi, N., & Fischer, P. (2002). Finite-time analysis of the multiarmed bandit problem. Machine Learning, 47(2-3), 235–256. DOI: 10.1023/A:1013689704352

Bergstrom, C. T. & West, J. D. (2021). Calling Bullshit: The Art of Skepticism in a Data-Driven World. New York: Random House. ISBN: 978-0-399-80315-2.

Ho, A., Besiroglu, T., Erdil, E., Owen, D., Rahman, R., Guo, Z. C., Atkinson, D., Thompson, N., & Sevilla, J. (2024). Algorithmic progress in language models. arXiv:2403.05812.

Birhane, A., Kasirzadeh, A., Leslie, D., & Wachter, S. (2023). Science in the age of large language models. Nature Reviews Physics. DOI: 10.1038/s42254-023-00581-4

Brundage, M., Avin, S., Wang, J., Belfield, H., Krueger, G., Hadfield, G., …& Anderljung, M. (2020). Toward trustworthy AI development: Mechanisms for supporting verifiable claims. arXiv:2004.07213.

Campbell, D. T. & Fiske, D. W. (1959). Convergent and discriminant validation by the Multitrait-Multimethod Matrix. Psychological Bulletin, 56(2), 81–105. DOI: 10.1037/h0046016

Dafoe, A., Bachrach, Y., Hadfield, G. K., Horvitz, E., Larson, K., & Graepel, T. (2021). Cooperative AI: Machines must learn to find common ground. Nature, 593, 33–36. DOI: 10.1038/d41586-021-01170-0

DeepSeek-AI (2024a). DeepSeek-V2: A strong, economical, and efficient mixture-of-experts language model. arXiv:2405.04434.

DeepSeek-AI (2024b). DeepSeek-V3 technical report. arXiv:2412.19437.

DeepSeek-AI (2024c). DeepSeekMoE: Towards ultimate expert specialization in mixture-of-experts language models. arXiv:2401.06066.

DeepSeek-AI (2025). Native Sparse Attention: Hardware-aligned and natively trainable sparse attention. arXiv:2502.11089.

DeepSeek-AI (2026). DeepSeek-V4: Towards highly efficient million-token context intelligence. Technical report (no arXiv preprint). Available at: https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro/blob/main/DeepSeek_V4.pdf and https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro

Grattafiori, A. et al. (2024). The Llama 3 herd of models. arXiv:2407.21783.

Epoch AI (2024). How much does it cost to train frontier AI models? Available at: https://epochai.org/blog/how-much-does-it-cost-to-train-frontier-ai-models

Gilad, Y., Hemo, R., Micali, S., Vlachos, G., & Zeldovich, N. (2017). Algorand: A secure and scalable distributed ledger. In Proceedings of the 26th Symposium on Operating Systems Principles (SOSP '17), 51–68. DOI: 10.1145/3132747.3132757

Grigorik, I. (2024). GH Archive: A record of everything that happens across GitHub. Available at: https://www.gharchive.org/

Hao, K. (2023). The cost of building AI is enormous. MIT Technology Review.

Jacovi, A., Caciularu, A., Goldman, O., & Goldberg, Y. (2023). Stop uploading test data in plain text: Practical strategies for mitigating data contamination by evaluation benchmarks. arXiv:2305.10160. Published in EMNLP 2023.

Jiang, A. Q., Sablayrolles, A., Mensch, A., Bambed, C., Chaplot, D. S., Casas, D. d. l., …& Sayed, W. E. (2023). Mistral 7B. arXiv:2310.06825.

Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2024). SWE-bench: Can language models resolve real-world GitHub issues? arXiv:2310.06770. Published in ICLR 2024.

Lai, T. L. & Robbins, H. (1985). Asymptotically efficient adaptive allocation rules. Advances in Applied Mathematics, 6(1), 4–22. DOI: 10.1016/0196-8858(85)90002-8

Lerner, J. & Tirole, J. (2002). Some simple economics of open source. The Journal of Industrial Economics, 50(1), 197–234. DOI: 10.1111/1467-6419.00173

Maslej, N., Fattorini, L., Brynjolfsson, E., Etchemendy, J., Ligett, K., Lyons, T., …& Perrault, R. (2024). The AI Index Report 2024. Stanford Institute for Human-Centered Artificial Intelligence (HAI). Available at: https://aiindex.stanford.edu/report/

Metz, C. (2024). Tech giants pour billions into A.I. as rivals race to catch up. The New York Times.

Muennighoff, N., Bian, H., Liu, A., …& Kiela, D. (2023). Scaling data-constrained language models. arXiv:2305.16264.

Ω (2020). Bittensor: A peer-to-peer intelligence market. Available at: https://bittensor.com/whitepaper

Raymond, E. S. (1999). The Cathedral and the Bazaar: Musings on Linux and Open Source by an Accidental Revolutionary. Sebastopol, CA: O'Reilly Media.

Shannon, C. E. (1948). A mathematical theory of communication. Bell System Technical Journal, 27(3), 379–423; 27(4), 623–656. DOI: 10.1002/j.1538-7305.1948.tb01338.x

Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., & Dean, J. (2017). Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. arXiv:1701.06538. Published in ICLR 2017.

SlashData (2024). State of the Developer Nation, Q1 2024. Available at: https://www.slashdata.co/free-industry-reports

Srinivasan, B. S. & Lee, L. (2017). Quantifying decentralization. Presented at Bitcoin 2017, Shanghai. Blog post / working paper (not peer-reviewed). Available at: https://news.earn.com/quantifying-decentralization-e80583e8280e

Rao, Y., Shaabana, A., & Steeves, J. (2020). Bittensor: A peer-to-peer intelligence market. arXiv:2003.03917. (Withdrawn from arXiv; updated version available at bittensor.com/whitepaper).

Strathern, M. (1997). 'Improving ratings': Audit in the British university system. European Review, 5(3), 305–321. DOI: 10.1002/(SICI)1234-9839(199707)5:3<305::AID-EURO156>3.0.CO;2-1

Team, G. et al. (2024). Gemma 2: Improving open language models at a practical size. arXiv:2408.00118.

Theil, H. (1967). Economics and Information Theory. Amsterdam: North-Holland.

Weber, N. et al. (2024). RedPajama: An open dataset for training large language models. arXiv:2411.12372. Published in NeurIPS 2024 Datasets and Benchmarks Track. Available at: https://together.ai/blog/redpajama

Touvron, H. et al. (2023). LLaMA: Open and efficient foundation language models. arXiv:2302.13971.

Van Valen, L. (1973). A new evolutionary law. Evolutionary Theory, 1, 1–30.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. arXiv:1706.03762. Published in NeurIPS 2017.

—