Platform : Sous-réseau de recherche multi-défis sur Bittensor basé sur les benchmarks

Équipe de recherche de la Cortex Foundation
Cortex Foundation — cortex.foundation — Bittensor Subnet 100 (Platform)

Abstract

Nous soutenons que le modèle dominant de développement de l'IA — des laboratoires centralisés entraînant des modèles à huis clos, les évaluant avec des benchmarks privés, et les publiant à des cadences fixes — est structurellement incapable d'innovation soutenue. Le goulot d'étranglement n'est ni le calcul ni les données ; il est l'évaluation et les incitations. Aucune organisation ne peut évaluer les systèmes d'IA sur chaque dimension de compétence, et aucun salaire ne peut égaler le pouvoir incitatif d'un jeton de récompense liquide et sans permission. Platform (Bittensor SN100) est un sous-réseau multi-défis qui résout les deux goulets simultanément. Les mineurs concourent sur divers benchmarks — ingénierie logicielle (Term Challenge via SWE-Forge), recherche d'architecture neuronale (PRISM), et génération de données synthétiques (Data Fabrication) — et sont récompensés proportionnellement à leur capacité démontrée, mesurée par des évaluations indépendamment vérifiées sous Yuma Consensus. Nous montrons que (1) les sous-réseaux Bittensor existants répliquent largement l'hébergement API centralisé et ne créent aucun avantage concurrentiel ; (2) la conception basée sur les benchmarks de Platform produit des évaluations adversarialement robustes, comme le démontre la transition de Terminal-Bench 2.0 à SWE-Forge ; (3) l'entraînement décentralisé est déjà viable — Covenant-72B, entraîné sur 70 nœuds sans permission, atteint MMLU 67.1, quasi-parité avec LLaMA-2-70B à 65.6 ; (4) l'argument économique pour les récompenses en TAO rivalisant avec les salaires de laboratoire est quantitativement favorable, avec les coûts de l'IA centralisée croissant de 4 à 5× par an tandis que la rentabilité recule vers 2030+ ; et (5) un sous-réseau cherchant sur une famille d'architectures F atteint provablement une mise à l'échelle strictement supérieure à tout concurrent à architecture fixe. L'implication est directe : un réseau d'incitations bien conçu peut produire des capacités d'IA rivales ou supérieures à celles des laboratoires centralisés, non en répliquant leur structure, mais en rendant leur structure obsolète.

Table of Contents

0.1 Bittensor et sous-réseaux 7
0.2 Le problème de l'architecture fixe 7
0.3 Pourquoi la recherche d'architecture est importante 9

1 Architecture de Platform : Un sous-réseau multi-défis **10**
1.1 Philosophie de conception . . . 10
1.2 Topologie du sous-réseau . . . 11
1.3 Catégories de défis . . . 12
1.4 Intégration de Yuma Consensus . . . 13
1.5 Allocation des émissions . . . 14
1.6 **Term Challenge** : Ingénierie logicielle à grande échelle . . . 14
1.6.1 Motivation et la lignée SWE-bench . . . 14
1.6.2 Le pipeline SWE-Forge . . . 15
1.6.3 Mécanique de notation . . . 15
1.6.4 La transition TB2.0 → SWE-Forge . . . 16
1.6.5 Défense anti-manipulation en couches . . . 16
1.7 **Data Fabrication Challenge** : Génération synthétique de jeux de données . . . 17
1.7.1 Motivation . . . 17
1.7.2 Protocole de soumission . . . 18
1.7.3 Pipeline anti-plagiat . . . 18
1.7.4 Contrôle qualité . . . 19
1.7.5 Application : Pipeline de réglage fin par RL . . . 19
1.7.6 Échelle et adaptivité . . . 20
1.8 **PRISM** : Recherche d'architecture neuronale décentralisée . . . 20
1.8.1 Une nouvelle catégorie de défi . . . 20
1.8.2 L'espace de recherche d'architecture . . . 20
1.8.3 Le théorème de supériorité de la recherche d'architecture . . . 21
1.8.4 L'entonnoir d'évaluation à quatre niveaux . . . 21
1.8.5 Notation en double voie et diversité . . . 22
1.8.6 Pourquoi PRISM est révolutionnaire . . . 23
1.9 **Training Challenge** : Pré-entraînement décentralisé . . . 24
1.9.1 Motivation . . . 24
1.9.2 Principe de conception : Décentralisation complète . . . 25
1.9.3 Questions de recherche ouvertes . . . 25
1.9.4 Relation avec les autres défis . . . 26
1.9.5 État actuel et calendrier . . . 26
1.10 Orthogonalité des défis et **Orthogonalité des incitations** . . . 26
1.10.1 Dissemblance structurelle . . . 26
1.10.2 Orthogonalité des incitations . . . 27
1.10.3 Allocation des émissions . . . 27
1.10.4 **Défense anti-manipulation combinatoire** . . . 27
1.10.5 Le **pipeline de production de bout en bout** . . . 28

2 L'Argument Économique : Pourquoi le TAO Surpasse les Salaires **29**
2.1 Le Problème des Talents dans l'IA Centralisée . . . 29
2.2 Le Modèle Économique de Platform . . . 30
2.3 Comparaison Quantitative . . . 30
2.4 L'Effet Volant . . . 31

3 L'IA Décentralisée Peut-Elle Concurrenter avec les Laboratoires Centralisés ? **33**
3.1 La Vue Sceptique (et Pourquoi Elle Est Erronée) . . . 33
3.2 Où Platform Gagne Déjà . . . 34
3.3 La Thèse de Convergence . . . 35
3.4 Ce que Platform Doit Réussir . . . 36

4 Analyse de la décentralisation **38**
4.1 Métrique formelle de décentralisation 38
4.2 Distribution d'entraînement de **Covenant-72B** 38
4.3 Le **théorème de recherche d'architecture** 39
4.4 Cadre d'incitation des validateurs sous Yuma Consensus 40

5 Conclusion et feuille de route **41**
5.1 Résumé des contributions 41
5.2 La voie à suivre 42
5.3 L'implication 43

Le développement de l'intelligence artificielle est régi par une oligarchie de moins de cinq laboratoires. OpenAI, Anthropic et Google DeepMind investissent chacun des centaines de millions à plus d'un milliard de dollars dans une seule exécution d'entraînement de frontière lorsqu'on prend en compte la R&D, les expériences échouées et l'acquisition de données (Epoch AI, 2024). Chacun de ces laboratoires entraîne une architecture unique, affinée à travers des mois de recherche interne, et évaluée à huis clos. L'architecture elle-même (mécanisme d'attention, stratégie de routage d'experts, schéma de normalisation) est la décision la plus conséquente dans l'ensemble du pipeline de développement, pourtant elle est prise une seule fois, par une petite équipe, puis gelée pour la durée de l'entraînement.

Le goulot d'étranglement de l'évaluation. Lorsqu'une seule organisation entraîne et évalue ses modèles, l'évaluation n'est pas adversariale ; elle est performative. Les benchmarks internes sont optimisés, pas appris. Les benchmarks externes souffrent du mode d'échec opposé : parce qu'ils sont publics et statiques, ils sont inévitablement contaminés par des fuites d'ensembles de test (Jacovi et al., 2023). Aucun régime ne fournit un signal qui soit simultanément adversarial et complet. La conséquence est que la compréhension par le domaine de ce que les modèles peuvent réellement faire est façonnée par les départements marketing d'une poignée d'entreprises, et non par une évaluation rigoureuse, continue et sans permission.

Le goulot d'étranglement des incitations. Un chercheur capable de faire avancer l'état de l'art fait face à un choix binaire : accepter un salaire, aussi généreux soit-il, d'un laboratoire existant, ou renoncer aux ressources de calcul institutionnelles, aux pipelines de données et au prestige de publication pour construire en ouvert. Le laboratoire capture la plus-value ; le chercheur capture un salaire fixe. Ce n'est pas un bogue du système ; c'est le système. Le modèle centralisé restreint nécessairement l'ensemble des contributeurs à ceux qu'il peut embaucher, et restreint l'ensemble des contributions à celles qu'il peut évaluer. L'innovation qui ne correspond pas au schéma organisationnel est, par construction, non récompensée.

Le goulot d'étranglement de l'architecture. Chaque modèle de frontière est entraîné sur une architecture unique choisie avant le début de l'entraînement. Cette décision (mécanisme d'attention, routage MoE, topologie résiduelle) est le choix à plus fort levier dans l'ensemble du pipeline de développement. La trajectoire de DeepSeek le prouve de manière concluante : **Multi-head Latent Attention** a réduit le cache KV de **93.3%** et le coût d'entraînement de **42.5%** ; **l'équilibrage de charge sans perte auxiliaire** a éliminé la dégradation des performances inhérente au MoE standard ; **Compressed Sparse Attention** a atteint l'inférence à un million de tokens à **27%** des FLOPs de la génération précédente. Chaque innovation architecturale a produit des gains d'efficacité d'un ordre de grandeur qu'aucune quantité supplémentaire de calcul ne pourrait répliquer. Pourtant, le paradigme dominant traite l'architecture comme une entrée fixe plutôt que comme un espace de conception recherchable. Un laboratoire qui s'engage sur la mauvaise architecture dépense des centaines de millions pour entraîner un modèle fondamentalement sous-optimal, sans aucun mécanisme pour découvrir qu'un simple changement dans la compression d'attention ou le routage d'experts aurait produit des résultats supérieurs à une fraction du coût.

Ces trois goulots d'étranglement ne sont pas indépendants. Architecture, évaluation et incitation sont trois facettes d'une contrainte unique : on ne peut récompenser que ce qu'on peut mesurer, on ne peut mesurer que ce qu'on a une incitation à évaluer honnêtement, et le plafond de capacité de ce qu'on peut mesurer est fixé par l'architecture à laquelle on s'est engagé avant le début de l'entraînement. Un système qui résout un ou deux de ces problèmes sans résoudre les trois n'a pas résolu le problème fondamental.

Bittensor (Ω, 2020) offre une échappatoire fondée sur des principes. Bittensor est un réseau décentralisé supportant jusqu'à **128** sous-réseaux (la limite du réseau), chacun émettant des récompenses, libellées en jetons TAO, via le **Yuma Consensus**, un protocole de classement par médiane basée sur le stake. L'intuition clé est qu'un réseau sans permission avec des incitations cryptographiques peut résoudre simultanément l'évaluation et l'incitation : n'importe qui peut contribuer, et les récompenses sont proportionnelles à la capacité démontrée telle que mesurée

par une évaluation adversariale et continuellement mise à jour.

Mais la plupart des sous-réseaux Bittensor n'ont pas réalisé ce potentiel. Le modèle prédominant, que nous appelons le modèle d'***architecture fixe***, assigne aux mineurs la tâche d'entraîner des modèles sur une architecture UNIQUE spécifiée par l'opérateur du sous-réseau. Que le sous-réseau prescrive une configuration de transformer particulière pour le pré-entraînement collaboratif ou impose une stratégie de routage MoE fixe, l'architecture est imposée d'en haut et traitée comme immuable. C'est le goulot d'étranglement fondamental : l'élimination de la **recherche d'architecture** en tant que dimension compétitive. La trajectoire compétitive de DeepSeek rend ce point non ambigu. DeepSeek-V2 a introduit **Multi-head Latent Attention** (**MLA**), réduisant le cache KV de **93.3%** et les coûts d'entraînement de **42.5%** tout en n'activant que **21B** des **236B** paramètres par token (DeepSeek-AI, 2024a). DeepSeek-V3 a minimisé la dégradation des performances due à l'équilibrage de charge MoE basé sur la perte auxiliaire, a introduit la prédiction multi-token et a validé l'entraînement **FP8** à échelle extrême, toutes des innovations architecturales qui ont porté le coût total d'entraînement à **$5.576M** pour un modèle de **671B** compétitif avec GPT-4 (DeepSeek-AI, 2024b). DeepSeek-V4 a introduit **Compressed Sparse Attention** et **Heavily Compressed Attention**, permettant l'inférence à un million de tokens à **27%** des FLOPs par token de la génération précédente (DeepSeek-AI, 2026). Chaque saut générationnel est venu d'un nouveau composant architectural, et non de calcul supplémentaire. Un sous-réseau qui verrouille ses mineurs à une architecture fixe élimine précisément la dimension qui détermine l'avantage compétitif.

Platform est le **Sous-réseau 100 (SN100)** de Bittensor, opéré par la Cortex Foundation. Platform est un sous-réseau multi-challenges où les mineurs sont évalués contre des benchmarks réels et adversariaux (le Challenge Term utilise les jeux de données **SWE-Forge** pour l'ingénierie logicielle, **PRISM** pour la recherche d'architecture neuronale, Training pour le pré-entraînement décentralisé, et Data Fab pour la génération de données synthétiques), et récompensés proportionnellement à leur capacité démontrée. Ces **quatre** challenges forment un pipeline de production fermé : **PRISM** découvre l'architecture, le Challenge de Training pré-entraîne le modèle de base, Data Fabrication produit des données de fine-tuning RL, et Term évalue l'agent résultant. Platform est un moteur d'incitation piloté par benchmarks : un système où l'acte de résoudre des problèmes difficiles est, en soi, le processus de minage.

La distinction est fondamentale. Dans un sous-réseau à architecture fixe, un mineur peut gagner des récompenses en entraînant efficacement un modèle sur un design prescrit. Dans Platform, un mineur ne peut gagner des récompenses qu'en démontrant une capacité qui dépasse la frontière actuelle du réseau. Cela crée un cliquet : la capacité agrégée du réseau est **monotoniquement non décroissante**, car chaque événement de récompense correspond à une véritable avancée de capacité, et non à une duplication d'entraînement.

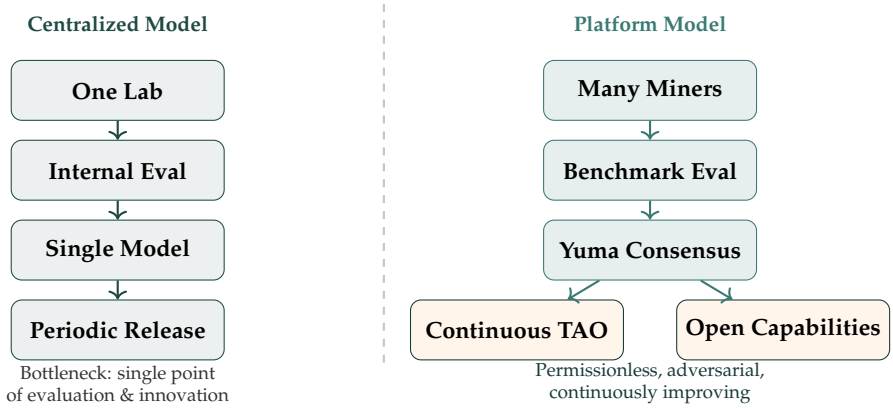

Figure 1 | Architecture diagram.

Nos contributions sont les suivantes :

- **Architecture multi-challenges avec recherche d'architecture.** Platform est le premier sous-réseau Bittensor à évaluer les mineurs à travers **quatre** types de challenges orthogonaux (ingénierie logicielle, recherche d'architecture neuronale, pré-entraînement décentralisé et génération de données synthétiques), formant un pipeline de production fermé de la découverte d'architecture à l'entraînement, puis au fine-tuning RL, jusqu'à l'évaluation. De manière critique, PRISM (§4.3) fait de l'architecture elle-même un espace de conception recherchable plutôt qu'une contrainte fixe, systématisant ce que DeepSeek réalise par itération de recherche manuelle (Section 3).

- **SWE-Forge.** Un générateur continu de jeux de données qui extrait les véritables pull requests fusionnées de GitHub, construit des suites de tests adversariales et produit de nouvelles instances d'évaluation pour le Challenge Term, éliminant le problème de contamination qui affecte les benchmarks statiques comme SWE-Bench (Jimenez et al., 2024). SWE-Forge produit un nouvel ensemble d'évaluation à chaque epoch (Section 4).

- **PRISM (À venir). PRISM** (Platform Recursive Investigation of Search-space Morphologies) est un challenge actuellement en développement actif. PRISM évaluera la recherche d'architecture neuronale, récompensant les mineurs qui découvrent de nouvelles architectures surpassant les baselines fixes à budgets de calcul équivalents. Le pipeline d'évaluation détaillé fait l'objet d'une recherche active ; la direction actuelle implique un pipeline de filtrage multi-niveaux qui valide progressivement les architectures candidates depuis des scores proxy légers jusqu'à l'évaluation complète sur benchmarks.

- **Preuve formelle que les sous-réseaux de recherche d'architecture surpassent les sous-réseaux à architecture fixe.** Nous prouvons que sous le Yuma Consensus, un sous-réseau qui permet aux mineurs de proposer des architectures atteint une capacité d'équilibre strictement supérieure à celle qui contraint les mineurs à une architecture fixe, à condition que l'espace de recherche d'architecture contienne au moins une amélioration par rapport à la baseline fixe (Théorème 1, Section 4).

- **Covenant-72B.** Un modèle de langage de 72 milliards de paramètres entraîné à travers au moins 70 pairs uniques cumulativement sur l'ensemble de l'entraînement (plafonnés à 20 contributeurs par tour, avec une moyenne de 16.9), atteignant **67.1** sur MMLU, démontrant que l'entraînement décentralisé à l'échelle de la frontière n'est pas seulement possible mais compétitif avec les alternatives centralisées à des comptes de paramètres équivalents (Section 7.2).

- **Transition de TB2.0 $\rightarrow$ SWE-Forge.** Une étude de cas en design anti-manipulation : Terminal-Bench 2.0 a été retiré après que les mineurs ont développé des stratégies qui maximisaient les scores sans améliorer la capacité réelle. La génération de jeux de données de SWE-Forge ferme ces exploits (Section 4).

- **Cadre d'incitation des validateurs.** Une analyse de la théorie des jeux établissant que l'évaluation honnête est un équilibre de Nash sous le Yuma Consensus, que les coalitions sous le seuil sont structurellement inefficaces, et que la déviation du consensus s'auto-pénalise par la réduction des émissions (Section 7.4).

- **Gouvernance de Platform.** Un mécanisme de gouvernance en fonctionnement continu qui surveille la santé du sous-réseau, propose des ajustements de paramètres et exécute des actions de gouvernance on-chain, fournissant une administration décentralisée 24h/24 sans opérateur central (Section 3.2).

Le reste de cet article est organisé comme suit. La Section 2 fournit le contexte sur Bittensor, le **problème d'architecture fixe**, et la motivation pour les sous-réseaux pilotés par la recherche d'architecture. La Section 3 détaille l'architecture de Platform et son pipeline à quatre challenges. La Section 4 traite chaque challenge en profondeur, incluant les harnais d'évaluation, les mécanismes anti-manipulation et le flux de production de bout en bout de la recherche d'architecture à l'entraînement jusqu'au fine-tuning RL. Les Sections 5–6 présentent l'argument économique et l'analyse compétitive. La Section 7 analyse la décentralisation et présente les résultats expérimentaux. La Section 8 conclut et présente la feuille de route.

0.1. Bittensor et sous-réseaux

Bittensor est un réseau décentralisé pour la production et la consommation d'intelligence artificielle, sécurisé par une blockchain et incité par le jeton TAO (Ω, 2020). Au moment de la rédaction, le réseau supporte jusqu'à 128 sous-réseaux (la limite du réseau), chacun responsable d'une tâche distincte : génération de texte, génération d'images, stockage de données, prévision, etc. L'architecture de chaque sous-réseau suit un modèle cohérent :

- Les **mineurs** fournissent un service (par ex., entraîner un modèle, générer des images, stocker des données).
- Les **validateurs** évaluent la qualité de ce service en envoyant des requêtes et en notant les réponses.
- Le **Yuma Consensus** agrège les scores des validateurs en un classement global via un protocole de médiane basée sur le stake (κ-majorité), qui détermine la distribution des émissions TAO aux mineurs et validateurs.

Formellement, soit $\mathcal{V} = \{v_1, \ldots, v_N\}$ l'ensemble des validateurs et $\mathcal{M} = \{m_1, \ldots, m_K\}$ l'ensemble des mineurs. Chaque validateur v_i produit un vecteur de scores $\mathbf{s}_i \in \Delta^K$ (une distribution de probabilité sur les mineurs), pondéré par la mise w_i. Le Yuma Consensus calcule le score de consensus via un seuil pondéré par le stake :

$\bar{s}_j = \frac{\sum_{i=1}^{N} w_i \cdot s_{ij}}{\sum_{i=1}^{N} w_i}$

Note : La formule ci-dessus est une représentation simplifiée. Le protocole Yuma Consensus utilise réellement un mécanisme de seuil à majorité κ plutôt qu'une simple moyenne pondérée. Les mineurs sont ensuite récompensés proportionnellement à $\bar{s}_j$. Les validateurs sont récompensés proportionnellement à leur accord avec le consensus, c'est-à-dire que les validateurs dont les scores s'écartent de $\bar{\mathbf{s}}$ reçoivent moins d'émissions. Cela crée une incitation pour les validateurs à noter honnêtement, puisque la dissidence du consensus est coûteuse (Rao et al., 2020).

La question de conception critique pour tout sous-réseau est : *qu'est-ce que le validateur évalue réellement ?* La réponse détermine si le sous-réseau produit une capacité véritable ou simplement une conformité aux benchmarks.

0.2. Le problème de l'architecture fixe

La majorité des sous-réseaux Bittensor (et, d'ailleurs, des laboratoires d'IA centralisés) opèrent sous ce que nous appelons la **contrainte d'architecture fixe** : les mineurs (ou, dans le cas centralisé, les équipes de recherche) sont tenus d'entraîner des modèles conformes à une architecture unique et pré-spécifiée. Qu'un sous-réseau prescrive une configuration de transformer particulière pour le pré-entraînement collaboratif ou impose une stratégie de routage MoE fixe, l'architecture est traitée comme une entrée fixe du processus de production plutôt que comme un espace de conception recherchable.

Cette contrainte n'est pas simplement une commodité de conception ; c'est le goulot d'étranglement fondamental du développement de l'IA. Ce qui importe est si le sous-réseau permet la recherche d'architecture en tant que dimension compétitive. Un sous-réseau qui entraîne des modèles sur un design prescrit est toujours coincé dans le paradigme d'architecture fixe ; il a simplement répliqué la même contrainte structurelle sous un régime d'entraînement différent.

DeepSeek comme preuve définitive. La trajectoire des modèles DeepSeek fournit une preuve non ambiguë que l'innovation architecturale, et non l'échelle de calcul, est le déterminant principal de l'avantage compétitif en IA.

DeepSeekMoE (DeepSeek-AI, 2024c) a introduit la segmentation fine des experts et l'isolation des experts partagés, remplaçant la norme MoE à granularité grossière. Le résultat : un modèle MoE de **145B** paramètres atteignant des performances comparables à un modèle dense de **67B** avec seulement **28.5%** des FLOPs, un gain d'efficacité de **3.5**× provenant de l'architecture seule. Aucune quantité de calcul supplémentaire appliquée à la topologie MoE standard n'aurait pu combler cet écart ; le gain est venu de la restructuration de l'espace des experts.

DeepSeek-V2 (DeepSeek-AI, 2024a) a introduit Multi-head Latent Attention (MLA), un mécanisme de compression d'attention fondamentalement différent. MLA compresse le cache KV de **93.3%**, réduit le coût d'entraînement de **42.5%** et augmente le débit d'inférence de **5.76**×. DeepSeek-V2 n'active que **21B** de ses **236B** paramètres totaux par token, tout en dépassant les performances des modèles denses de **67B**. Il ne s'agit pas d'améliorations marginales issues de calcul supplémentaire ; ce sont des gains d'efficacité d'un ordre de grandeur provenant d'un nouveau composant architectural.

DeepSeek-V3 (DeepSeek-AI, 2024b) a introduit trois innovations architecturales supplémentaires. Premièrement, l'équilibrage de charge sans perte auxiliaire a largement éliminé la dégradation des performances qu'imposent les pénalités d'équilibrage de charge MoE standard, réduisant une taxe que chaque implémentation MoE antérieure payait (bien que V3 conserve une petite perte auxiliaire séquentielle complémentaire pour la stabilité de l'entraînement). Deuxièmement, la prédiction multi-token (MTP) a amélioré les performances sur les benchmarks de mathématiques et de code (DeepSeek-AI, 2024b). Troisièmement, l'entraînement en précision mixte FP8 a été validé à échelle extrême. L'effet combiné : coût total d'entraînement de **$5.576M** pour un modèle de **671B** qui égale GPT-4o sur MMLU (**88.5** vs. **87.2**) et dépasse o1-preview sur MATH-500. DeepSeek-V3 atteint **90.2** sur MATH-500, surpassant o1-preview sur ce benchmark. C'est environ **10**× moins cher que le coût estimé de l'entraînement de GPT-4, et chaque gain d'efficacité est architectural, non computationnel.

DeepSeek-V4 (DeepSeek-AI, 2026) a introduit **Compressed Sparse Attention** (**CSA**) et **Heavily Compressed Attention** (**HCA**), un mécanisme d'attention hybride permettant des fenêtres de contexte de **1M** tokens. V4-Pro utilise seulement **27%** des FLOPs de V3.2 et **10%** de son cache KV à **1M** tokens. **Manifold-Constrained Hyper-Connections** (**mHC**; DeepSeek-AI, 2025) stabilisent l'entraînement ultra-profond. Sur SWE-bench Verified, V4 atteint **80.6**, égalant les modèles fermés de frontière. Encore une fois, le saut de capacité est architectural : CSA/HCA et mHC sont de nouveaux composants structurels, non du calcul supplémentaire.

Le modèle. Chaque saut majeur de capacité dans l'histoire de l'IA est venu de l'architecture, non du calcul. Le Transformer lui-même (Vaswani et al., 2017) a remplacé les RNN non pas parce qu'il utilisait plus de FLOPs, mais parce que l'attention parallélisable était une architecture supérieure. Le MoE à portes clairsemées (Shazeer et al., 2017) a permis le routage de sous-modèles que la mise à l'échelle dense ne pouvait pas répliquer. MLA, l'équilibrage de charge sans perte auxiliaire et Compressed Sparse Attention suivent le même modèle. Les laboratoires qui conçoivent de meilleures architectures gagnent ; les laboratoires qui se contentent de dépenser plus restent à la traîne. Le coût d'entraînement de **$5.576M** de DeepSeek-V3 par rapport à l'estimation de **$50–100M+** pour GPT-4 en est la preuve définitive.

Comment les sous-réseaux échouent sous le verrouillage d'architecture. La contrainte d'architecture fixe se manifeste différemment à travers les sous-réseaux Bittensor existants,

mais la conséquence structurelle est la même : aucun mécanisme pour découvrir de meilleures architectures.

La véritable distinction. La différence entre Platform et les autres sous-réseaux ne porte pas sur le type de tâche (inférence, entraînement, stockage) mais sur le fait que l'architecture est une contrainte fixe ou un espace de conception recherchable : « architecture fixe vs. recherche d'architecture ». Un sous-réseau qui entraîne des modèles sur un design prescrit est toujours coincé dans le paradigme d'architecture fixe ; il a simplement répliqué la même contrainte structurelle sous un régime d'entraînement computationnellement plus coûteux. Platform, à travers son challenge PRISM (§4.3), fait de l'architecture elle-même l'objet d'une recherche décentralisée. Les mineurs n'entraînent pas un design fixe plus efficacement ; ils proposent, évaluent et concourent sur des architectures alternatives, et le réseau récompense celles qui livrent de véritables améliorations de capacité.

0.3. Pourquoi la recherche d'architecture est importante

Si chaque sous-réseau verrouille les mineurs à une architecture fixe, alors aucun sous-réseau ne peut découvrir la prochaine Multi-head Latent Attention ou le prochain schéma d'équilibrage de charge sans perte auxiliaire. Le plafond de capacité du réseau est fixé par les choix architecturaux de l'opérateur du sous-réseau, et non par l'ingéniosité des mineurs. Un opérateur de sous-réseau qui prescrit un transformer standard avec attention dense a, peut-être sans le savoir, exclu toute architecture qui pourrait livrer un gain d'efficacité de **10**×, exactement le type de gain que DeepSeek a démontré comme réalisable par l'innovation architecturale seule.

La seule manière pour un réseau décentralisé de produire des capacités rivalisant avec les laboratoires centralisés est de faire de l'architecture une dimension compétitive, et de récompenser les véritables innovations architecturales, et non simplement l'entraînement efficace d'un design fixe. Cela nécessite trois propriétés :

1. **La recherche d'architecture en tant que challenge de premier plan.** Le sous-réseau doit traiter l'architecture comme un espace de conception recherchable, et non comme une contrainte fixe. Les mineurs doivent pouvoir proposer, évaluer et concourir sur des architectures alternatives, incluant des mécanismes d'attention alternatifs, des stratégies de routage d'experts et des topologies résiduelles. C'est précisément ce que PRISM fournira (§4.3) : un pipeline de recherche d'architecture actuellement en développement actif, dont la direction actuelle implique un pipeline de filtrage multi-niveaux qui valide progressivement les architectures candidates depuis des scores proxy légers jusqu'à l'évaluation complète sur benchmarks.

2. **Évaluation adversariale des architectures découvertes.** Des benchmarks frais, une notation multi-axes et des récompenses relatives à la frontière garantissent que les innovations architecturales sont évaluées sur des gains de capacité véritables, et non sur des métriques de substitution. Un nouveau mécanisme d'attention qui réduit les FLOPs mais dégrade le raisonnement ne doit pas être récompensé comme une avancée. Le régime d'évaluation adversariale de Platform, avec des benchmarks continuellement renouvelés à travers **quatre** types de challenges orthogonaux, fournit cette garantie.

3. **Alignement des incitations avec l'innovation architecturale.** Les mineurs qui découvrent de meilleures architectures doivent gagner plus que les mineurs qui entraînent efficacement de moins bonnes architectures. Sous le Yuma Consensus, les récompenses coulent proportionnellement aux scores de consensus, qui sont déterminés par la capacité démontrée. Un mineur dont l'innovation architecturale produit un modèle qui surpasse la frontière sur les benchmarks adversariaux obtient un score plus élevé, et donc des émissions plus élevées, qu'un mineur qui entraîne l'architecture prescrite marginalement

plus efficacement. Le gradient d'incitation pointe vers la recherche d'architecture, et non à l'opposé.

Platform satisfait ces trois propriétés. À travers son challenge PRISM, c'est le premier sous-réseau Bittensor où l'architecture est un espace de conception recherchable, et non une contrainte imposée.

La conséquence formelle. Cette distinction a des implications formelles. Dans la Section 4, nous prouvons que sous le Yuma Consensus, un sous-réseau qui permet la recherche d'architecture (Platform, via PRISM) atteint une capacité d'équilibre strictement supérieure à celle qui contraint les mineurs à une architecture fixe. La preuve repose sur l'observation que la recherche d'architecture étend l'espace de stratégie effectif des mineurs, ce qui, dans tout régime de notation qui récompense la capacité véritable, doit améliorer faiblement l'équilibre. Le régime d'évaluation de Platform *récompense* la capacité véritable, car ses benchmarks sont adversariaux, multi-axes et continuellement renouvelés. L'intuition clé est que la contrainte d'architecture fixe n'est pas simplement un choix de conception ; c'est un préjudice actif, car elle exclut les stratégies mêmes (l'innovation architecturale) que les laboratoires centralisés ont démontré être la voie à plus fort levier vers les avancées de capacité.

La différence entre Platform et les sous-réseaux à architecture fixe n'est pas incrémentale ; elle est catégorique. Un sous-réseau à architecture fixe demande si un mineur peut *optimiser* un design prescrit. PRISM, le challenge de recherche d'architecture de Platform, demande si un mineur peut *découvrir* un design supérieur. Le premier est un problème d'ingénierie ; le second est un problème de recherche. Seul le second peut produire le type d'innovations architecturales que DeepSeek a montré être le facteur décisif de la capacité en IA.

En résumé, le modèle d'architecture fixe est l'attracteur par défaut de la conception des sous-réseaux Bittensor : il est facile à spécifier, facile à valider et facile à comprendre. Mais c'est aussi un optimum local. En échapper nécessite une philosophie d'évaluation fondamentalement différente : adversariale plutôt que conforme, multi-axes plutôt que métrique unique, relative à la frontière plutôt que statique de référence, et, de manière critique, pilotée par la recherche d'architecture plutôt qu'à architecture fixe. Platform est le premier sous-réseau à implémenter cette philosophie de bout en bout.

1. Architecture de Platform : Un sous-réseau multi-défis

1.1. Philosophie de conception

La prémisse fondamentale de Platform est trompeusement simple mais conséquente : ***vous obtenez ce que vous mesurez***. Si un réseau décentralisé ne mesure que le débit d'inférence, il optimisera exclusivement pour une inférence rapide ; s'il ne mesure que la précision de codage sur des benchmarks statiques, il surajustera à ces benchmarks. L'histoire de l'évaluation en IA est remplie d'exemples de la loi de Goodhart en action : la pression d'optimisation sur une métrique d'évaluation dégrade inévitablement la capacité sous-jacente qu'elle était censée refléter (Strathern, 1997). La philosophie architecturale de Platform est conçue pour résister à cette pression non par un mécanisme astucieux unique, mais par la difficulté combinatoire de tromper simultanément plusieurs dimensions d'évaluation orthogonales.

Platform n'est pas un sous-réseau à architecture fixe. Contrairement aux conceptions de sous-réseaux qui verrouillent les mineurs à une architecture de modèle prescrite et n'évaluent que dans cet espace de conception contraint, Platform évalue les *capacités réelles* à travers des benchmarks adversariaux qui incluent la recherche d'architecture comme un défi de premier plan. Un mineur sur Platform ne peut réussir en entraînant simplement l'architecture prescrite marginalement plus vite ; il doit découvrir de nouvelles architectures, générer des correctifs

vérifiables, naviguer dans des bases de code inconnues et produire des données d'entraînement sous des contraintes qui changent continuellement.

La conception multi-défis reflète une intuition fondamentale de la théorie psychométrique : la **validité convergente** à travers des instruments de mesure orthogonaux fournit des preuves plus solides de capacité réelle que tout instrument unique, aussi bien construit soit-il (Campbell & Fiske, 1959). Platform operationalise cela en déployant des catégories de défis qui sondent des dimensions structurellement dissemblables de la compétence en IA :

- **Synthèse et réparation de code** (Défi Term) : L'agent peut-il diagnostiquer et corriger de vrais bogues dans des bases de code de production ?
- **Recherche d'architecture** (PRISM, à venir) : L'agent peut-il découvrir de nouvelles architectures neuronales sous des contraintes de ressources ?
- **Pré-entraînement décentralisé** (Défi d'entraînement, en recherche) : Le réseau peut-il collectivement entraîner un modèle de pointe sans orchestrateur central ?
- **Qualité des données** (Data Fabrication, à venir) : L'agent peut-il générer des données d'entraînement synthétiques qui préservent les propriétés distributionnelles sans fuite, et les intégrer dans le fine-tuning RL ?

Aucune catégorie de défi unique ne domine l'allocation des récompenses, et les catégories sont conçues pour avoir une faible corrélation mutuelle. Un mineur qui excelle dans la génération de correctifs mais échoue dans la recherche d'architecture reçoit une compensation partielle, et non totale. Cette **contrainte d'orthogonalité** n'est pas simplement esthétique ; elle est la défense principale contre le piratage de récompense. Pour tromper Platform, un mineur devrait tromper simultanément quatre pipelines d'évaluation en évolution, chacun avec des mécanismes anti-piratage distincts, un coût adversarial qui croît combinatoirement avec le nombre de défis.

De manière cruciale, ces **quatre défis** forment un **pipeline de production**, et non simplement une collection d'évaluations indépendantes. **PRISM** détermine l'architecture optimale ; le **Défi d'entraînement** utilise cette architecture pour pré-entraîner le modèle de base de manière entièrement décentralisée ; **Data Fabrication** génère des données synthétiques de haute qualité pour le fine-tuning RL ; et le **Défi Term** évalue l'agent résultant. Cette **conception en boucle fermée** garantit que chaque composant du pipeline est lui-même optimisé de manière compétitive (Section 4).

1.2. Topologie du sous-réseau

Platform opère en tant que Bittensor Sous-réseau 100, héritant des primitives économiques du substrat tout en imposant sa propre logique de gouvernance et d'évaluation. Le flux de données procède à travers sept étapes :

Mineurs → **Pool de soumissions** → **Validateurs** → **Consensus PBFT** → **Soumission des poids** → **Yuma Consensus (on-chain)** → **Récompenses TAO**

Les mineurs produisent du code (artefacts exécutables, configurations d'architecture) selon le défi actif. Ces artefacts sont déposés dans un **Pool de soumissions** à adressage de contenu, indexé par des identifiants intégrés au contenu. Les soumissions sont embarquées dans un environnement d'exécution optimisé avec une surveillance par agents, ce qui empêche le vol et la copie entre mineurs tout en permettant la déduplication des soumissions identiques. Le système garantit que le code des mineurs s'exécute dans un environnement protégé et surveillé où des agents vérifient l'intégrité de l'exécution et détectent le plagiat ou la reproduction non autorisée du travail d'un autre mineur.

Les validateurs sont assignés aux tâches d'évaluation par une ***assignation amorcée par epoch***. À chaque limite d'epoch, une graine dérivée de l'état de la blockchain détermine

quels validateurs évaluent quelles soumissions. L'assignation est donc imprévisible ex ante (prévenant la collusion) mais auditable ex post (permettant la détection de inconduite des validateurs). Cette conception reflète la sélection aléatoire des jurés dans les protocoles de tirage au sort cryptographique (Gilad et al., 2017) et garantit qu'aucun validateur ne peut choisir stratégiquement quelles soumissions évaluer.

La gouvernance Platform assure une gouvernance continue des paramètres opérationnels du sous-réseau, incluant la sélection des défis, les pondérations des récompenses et les critères d'évaluation, remplaçant les mises à jour de paramètres déclenchées par epoch des conceptions antérieures. Contrairement à la gouvernance liée aux epochs, qui ne peut ajuster les paramètres qu'à des intervalles fixes, la gouvernance Platform opère 24/7, permettant une réponse rapide aux stratégies de piratage émergentes. Une vulnérabilité découverte dans le pipeline d'évaluation du Défi Term à l'epoch e peut être corrigée à l'epoch $e+1$, plutôt que d'attendre le prochain cycle de gouvernance. La gouvernance Platform maintient des connexions de rétroaction vers le **Pool de soumissions** (ajustant le ciblage de difficulté), la couche de Consensus (modifiant les exigences de quorum) et la distribution des Récompenses (ajustant les répartitions des pondérations des défis).

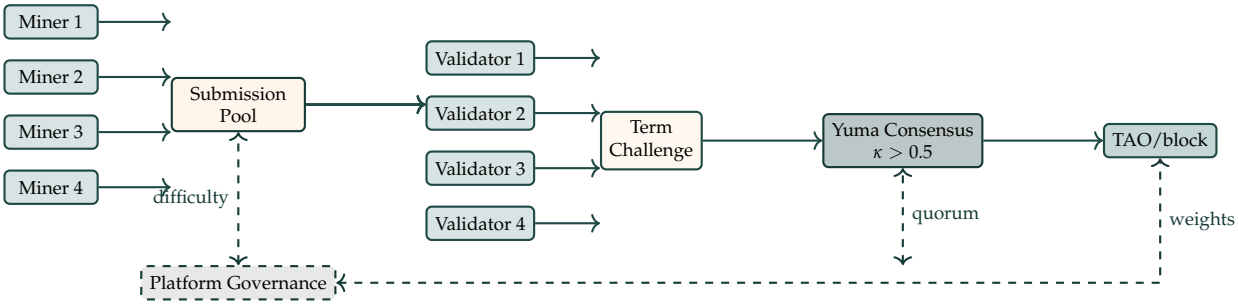

Figure 2 | Architecture diagram.

1.3. Catégories de défis

Platform dispose de quatre catégories de défis en développement, toutes prévues pour activation sous Platform 3.0 (mai 2026) :

Défi Term. Le Défi Term évalue les agents de codage en IA sur des jeux de données produits par **SWE-Forge**, un générateur qui crée des instances d'évaluation compatibles avec **SWE-bench** à partir de véritables pull requests fusionnées sur GitHub. Chaque instance requiert qu'un agent diagnostique un bogue, génère un correctif et réussisse les tests de régression, sans accès au correctif original. La Section 4 fournit un traitement détaillé du pipeline **SWE-Forge** et de ses mécanismes anti-piratage. Le Défi Term est prévu pour une réactivation sous Platform 3.0 (mai 2026).

PRISM (À venir). PRISM (Platform Recursive Investigation of Search-space Morphologies) est un challenge actuellement en développement actif. PRISM évaluera la recherche d'architecture neuronale, récompensant les mineurs qui découvrent de nouvelles architectures surpassant les baselines fixes à budgets de calcul équivalents. Le pipeline d'évaluation détaillé fait l'objet d'une recherche active ; la direction actuelle implique un pipeline de filtrage multi-niveaux qui valide progressivement les architectures candidates depuis des scores proxy légers jusqu'à l'évaluation complète sur benchmarks. PRISM est prévu pour être lancé avec Platform 3.0.

Défi d'entraînement (En recherche). Le **Défi d'entraînement** évaluera le pré-entraînement décentralisé de grands modèles de langage. Une fois que **PRISM** détermine l'architecture optimale, le Défi d'entraînement coordonne un entraînement entièrement décentralisé à travers des mineurs indépendants, sans orchestrateur central et sans point de contrôle unique. Il s'agit du successeur direct de l'entraînement décentralisé démontré par Covenant-72B, mais intégré

au cadre multi-défis de Platform. La conception fait l'objet d'une recherche active ; les questions ouvertes clés incluent l'agrégation de gradients sous matériel hétérogène, l'atténuation des retards sans coordination centralisée et la vérification des contributions honnêtes.

Data Fabrication (À venir). Le défi Data Fabrication évaluera la génération de données synthétiques à travers des métriques de fidélité distributionnelle : l'agent peut-il produire des données d'entraînement qui préservent les propriétés statistiques d'une distribution cible tout en évitant la mémorisation et la fuite de données privées ? L'application en aval principale est le fine-tuning RL : les mineurs de **Data Fabrication** génèrent des paires (prompt, réponse) de haute qualité qui alimentent directement l'apprentissage par renforcement du modèle de base produit par le **Défi d'entraînement**. Ce défi adresse le problème de la « **barrière des données** » (Muennighoff et al., 2023) en incitant la production décentralisée d'ensembles de données synthétiques de haute qualité.

La conception multi-défis garantit qu'aucune dimension de capacité unique ne peut capturer la totalité de l'émission TAO. Un mineur qui excelle dans la génération de correctifs mais ne peut rechercher d'architectures, entraîner de modèles ou générer des données capturera au maximum l'allocation Term. De manière cruciale, les **quatre défis** forment un **pipeline de production** : **PRISM** découvre l'architecture, le **Défi d'entraînement** entraîne le modèle de base, **Data Fabrication** fournit les données de fine-tuning RL, et le Défi Term évalue l'agent résultant. Le rendement marginal de la capacité complète dépasse le rendement de l'excellence étroite ; une propriété que nous nommons ***orthogonalité des incitations***.

1.4. Intégration de Yuma Consensus

Platform hérite du mécanisme de **Yuma Consensus** de Bittensor pour transformer les évaluations des validateurs en distributions de récompenses on-chain. Les propriétés clés de cette intégration sont :

Quorum pondéré par la mise. L'influence d'un validateur sur le résultat du consensus est proportionnelle à son TAO mis en jeu. Pour finaliser un score pour une soumission donnée d'un mineur, les validateurs contrôlant au moins la fraction κ (typiquement > 0.5, une majorité) de la mise totale doivent s'accorder sur un score avant sa finalisation. Ce seuil équilibre la latence (un κ plus bas permet une finalisation plus rapide) avec la sécurité (un κ plus élevé rend la collusion plus coûteuse). La gouvernance Platform peut ajuster les seuils de quorum en réponse au comportement observé des validateurs ; si l'accord des validateurs tombe en dessous d'un seuil de référence historique, l'exigence de quorum augmente, forçant une évaluation indépendante supplémentaire.

Auto-alignement des validateurs. Sous **Yuma Consensus**, les validateurs sont récompensés non pour la précision absolue de leurs scores mais pour l'*accord avec le consensus de leurs pairs*. Un validateur qui s'écarte systématiquement du consensus émergent reçoit une émission diminuée. Cela crée un équilibre auto-renforçant : l'évaluation honnête est la stratégie de maximisation du profit car elle maximise l'accord attendu avec les autres validateurs honnêtes. L'écart, qu'il soit par incompétence ou par collusion, est pénalisé automatiquement par une émission réduite (Bittensor Foundation, 2024).

Normalisation des scores et distribution des récompenses. Les scores bruts des validateurs sont normalisés par catégorie de défi avant l'agrégation du consensus. Au sein de chaque catégorie, les pondérations dépassant le seuil de consensus pondéré par la mise sont tronquées, et les émissions des mineurs sont calculées comme une somme pondérée par la mise des pondérations post-troncature. Cette normalisation garantit que les distributions de scores à travers des types de défis hétérogènes restent comparables, empêchant tout défi unique de dominer le calcul des récompenses en raison d'effets d'échelle.

1.5. Allocation des émissions

Les allocations d'émissions entre les défis sont déterminées de manière autonome par **Atlas 3.0**, le protocole de gestion automatisée des émissions de Bittensor, qui ajuste continuellement les pondérations des défis en fonction des taux de participation, des métriques de maturité et de l'impact démontré, sans nécessiter de votes de gouvernance manuels ni d'allocations en pourcentage fixe.

Au sein de chaque défi, la notation intègre deux mécanismes supplémentaires :

Notation uniforme. Les scores du Défi Term sont calculés comme tâches_réussies/total_tâches, normalisés sur le pool des mineurs. Il n'y a pas de multiplicateurs de difficulté ; chaque tâche contribue également au taux de résolution du mineur.

Le gagnant prend tout avec déclin. Le mineur au score le plus élevé dans chaque fenêtre d'évaluation reçoit la plus grande part des récompenses. Cependant, pour empêcher qu'une dominance établie n'étouffe la concurrence, Platform applique un mécanisme de **déclin du meilleur agent** : une fois qu'un mineur a occupé la première position pendant une **période de grâce** de **10 epochs**, sa part de récompense commence à décliner avec une demi-vie d'environ **14 epochs**. Formellement, si un mineur a été le meilleur scoreur pendant e epochs au-delà de la période de grâce, sa récompense est multipliée par $\left(\frac{1}{2}\right)^{e/14}$. Cela crée une incitation naturelle au renouvellement : les mineurs en place doivent continuer à s'améliorer pour maintenir leurs récompenses effectives, tandis que les challengers font face à une cible ajustée par le déclin qui devient progressivement plus facile à dépasser.

Le sous-réseau Platform décompose le problème ouvert de « construire une infrastructure IA utile » en **quatre défis structurellement dissemblables**, chacun ciblant une dimension de capacité distincte. Cette décomposition n'est pas arbitraire : elle découle de l'observation qu'aucun paradigme d'évaluation unique ne peut simultanément sonder la compétence en ingénierie, la qualité des données, l'innovation architecturale et l'entraînement décentralisé. Nous présentons chaque défi en détail, y compris le harnais d'évaluation complet, la mécanique de score, les défenses anti-manipulation et les arguments théoriques qui établissent leur nouveauté individuelle et collective au sein de l'écosystème Bittensor.

1.6. Term Challenge : Ingénierie logicielle à grande échelle

1.6.1 Motivation et la lignée SWE-bench

Le **Term Challenge** évalue la capacité d'ingénierie logicielle autonome, c'est-à-dire la capacité d'un agent à lire la description d'un problème réel, naviguer dans une base de code et produire un correctif qui résout le problème. Ce défi s'inscrit dans le paradigme SWE-bench (Jimenez et al., 2024), qui a construit un benchmark de 2 294 problèmes GitHub réels issus de 12 dépôts Python populaires, chacun associé au commit de fusion de référence qui le résout. L'idée clé de SWE-bench est que l'évaluation doit mesurer *l'accomplissement de bout en bout de la tâche*, et non des métriques intermédiaires de processus ; un agent résout soit le problème, soit il ne le résout pas.

La contribution de Platform est de transformer SWE-bench d'un classement statique en un *protocole d'évaluation live, cryptéoconomiquement incité*. Là où SWE-bench évalue un seul agent sur un ensemble de test fixe, le **Term Challenge** récompense continuellement les mineurs dont les agents atteignent les taux de résolution les plus élevés sur des instances *nouvelles*, *cachées* tirées de la même distribution. Le jeu de données est reconstitué à partir du GH Archive (Grigorik, 2024), une archive publique de tous les événements GitHub, garantissant que le défi évolue avec l'écosystème logiciel lui-même.

1.6.2 Le pipeline SWE-Forge

SWE-Forge est un générateur de jeux de données qui produit des instances d'évaluation nouvelles et résistantes à la manipulation pour le Term Challenge. Il met en œuvre un pipeline en **sept** étapes, depuis un problème GitHub brut jusqu'à une instance de benchmark empaquetée, que le Term Challenge utilise ensuite pour évaluer les agents des mineurs :

1. **Ingestion des problèmes** : Les problèmes candidats sont extraits du GH Archive, filtrés pour les dépôts Python avec une couverture de tests suffisante et des commits de fusion associés.

2. **Création d'instance** : Chaque problème est associé à son commit de résolution et à un script de notation des tests qui identifie les cas de test pertinents pour le problème. Deux catégories de tests sont distinguées : les tests *fail-to-pass* (qui échouent avant le correctif et doivent passer après), et les tests *pass-to-pass* (qui doivent passer dans les états avant et après le correctif).

3. **Empaquetage du benchmark** : L'état du dépôt est figé au commit pré-correctif, et le script de notation est empaqueté avec lui. Les cas de test sont rendus *en lecture seule* pour l'agent : visibles mais non modifiables.

4. **Exécution de l'agent** : Les mineurs soumettent le code source de leur agent (et non un correctif pré-calculé). Le validateur compile ce code en un binaire autonome via PyInstaller, puis l'exécute dans un conteneur Docker pour l'isolation. L'accès réseau est autorisé afin que l'agent puisse installer les paquets requis ; le conteneur restreint l'accès au système de fichiers de l'hôte et empêche la modification de la suite de tests.

5. **Extraction du correctif** : Le binaire de l'agent produit un diff par rapport au dépôt. Si aucun diff n'est produit ou si le diff est mal formé, la soumission est notée comme NON RÉSOLU.

6. **Vérification avant/après** : Le correctif est appliqué à l'état pré-correctif du dépôt. La suite de tests complète est exécutée dans les états *avant* (pré-correctif) et *après* (post-correctif). Une soumission est marquée RÉSOLUE si et seulement si :

- Chaque test *fail-to-pass* **ÉCHOUE** avant le correctif et **PASSE** après. - Chaque test *pass-to-pass* **PASSE** dans les deux états.

Cette vérification à deux états est l'innovation critique. Elle empêche les agents de « résoudre » un problème en supprimant le test défaillant, en insérant un `assert True` trivial, ou par tout autre correctif dégénéré qui fait passer le test défaillant spécifique tout en cassant les tests qui passaient auparavant.

1. **Notation et classement** : Les instances résolues sont comptabilisées par mineur, et les scores sont calculés par agrégation uniforme (voir §4.1.3).

1.6.3 Mécanique de notation

Le score du Term Challenge pour le mineur m est :

$S_{\text{term}}(m) = \frac{\text{tasks_resolved}(m)}{\text{total_tasks}}$

où le dénominateur est le nombre d'instances dans le lot d'évaluation courant. En v2, toutes les instances ont un poids uniforme ; aucun multiplicateur de difficulté n'est appliqué. Ce choix de conception privilégie la couverture à la profondeur : un agent qui résout de nombreux problèmes simples surpasse celui qui résout un seul problème difficile, reflétant

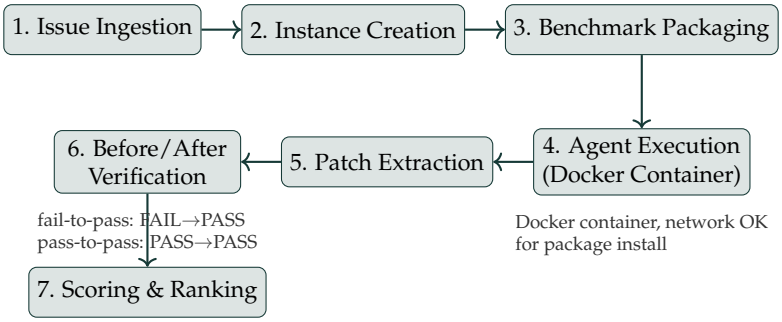

Figure 3 | Architecture diagram.

la réalité industrielle selon laquelle la fiabilité sur une large distribution de tâches est plus précieuse qu'une brillance occasionnelle.

La notation « winner-takes-all » (WTA) est appliquée avec un mécanisme de décroissance pour l'agent de tête afin d'empêcher les mineurs dominants de capturer durablement des récompenses disproportionnées. Le facteur de décroissance pour l'epoch e est :

$\alpha(e) = 2^{-e/14}$

Cela fournit une période de grâce de 10 epochs (le facteur reste proche de 1,0) et une demi-vie d'environ 14 epochs, après laquelle le score du mineur de tête est réduit de moitié, créant de la place pour les concurrents. La décroissance est appliquée à la différentielle de score entre le mineur de tête et le reste, et non au score brut.

1.6.4 La transition TB2.0 → SWE-Forge

Le prédécesseur du Term Challenge, Terminal-Bench 2.0, souffrait d'un défaut de conception fondamental : les seuils d'assertion dans les cas de test étaient *visibles par l'agent au moment de l'inférence*. Cela permettait des stratégies de tricherie basées sur l'oracle : les agents pouvaient inspecter la suite de tests, extraire la sortie attendue et produire un écho codé en dur plutôt qu'un correctif authentique. Comme l'ont confirmé des analyses ultérieures, le benchmark récompensait la lecture des tests, et non la correction de bogues.

La corrélation entre les scores TB2.0 et les scores SWE-bench Verified n'a pas été formellement mesurée dans l'article sur TB2.0, mais les preuves qualitatives sont sans équivoque : la conception exploitable par oracle de TB2.0 permettait aux agents d'atteindre des scores élevés sans capacité réelle de correction de bogues, produisant des classements qui n'avaient aucune relation significative avec la compétence réelle en ingénierie logicielle. La vérification avant/après et la conteneurisation Docker de SWE-Forge ferment ces vecteurs d'exploitation, et nous observons qualitativement que les mineurs qui performaient bien sous le régime d'assertions visibles de TB2.0 ne maintiennent pas leur avantage sous le régime de tests cachés et de vérification double de SWE-Forge, un constat cohérent avec le fait que les benchmarks mesurent des capacités fondamentalement différentes.

1.6.5 Défense anti-manipulation en couches

SWE-Forge met en œuvre **six** couches de défense contre les stratégies dégénérées, disposées de la couche externe (la moins coûteuse, la plus large) à la couche interne (la plus coûteuse, la plus ciblée) :

1. **Conception du benchmark** : Les instances de test sont tirées d'un pool privé et rotatif. Les mineurs ne peuvent pas mémoriser les réponses.

2. **Vérification avant/après** : Les correctifs doivent préserver tous les tests passants tout en corrigeant tous les tests défaillants, empêchant la suppression de tests et les assertions

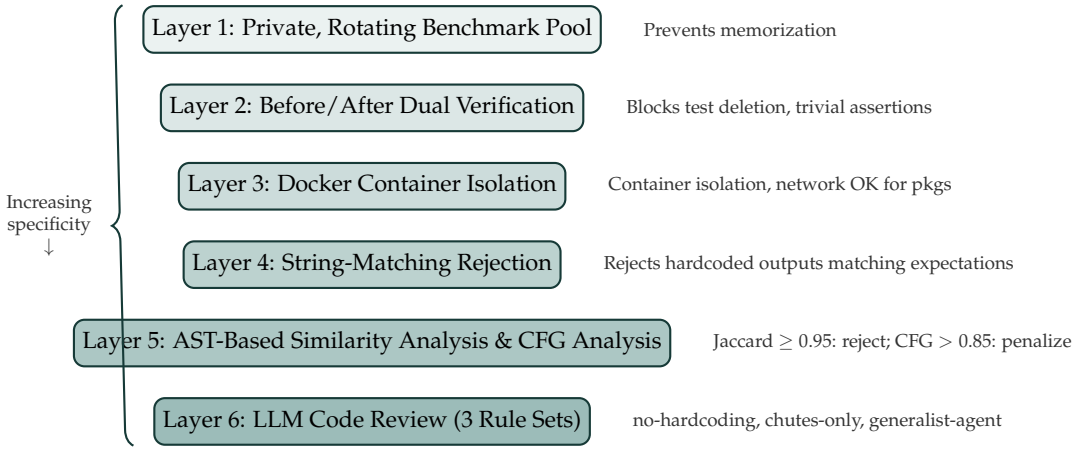

Figure 4 | Architecture diagram.

triviales.

3. **Isolation par conteneur Docker** : L'accès réseau est autorisé pour l'installation de paquets, mais l'accès au système de fichiers de l'hôte est restreint et la suite de tests est en lecture seule. L'agent opère sous des contraintes conteneurisées qui reflètent le déploiement en conditions réelles.

4. **Rejet par correspondance de chaînes** : Les correctifs contenant des sorties codées en dur correspondant aux attentes des tests sont signalés et rejetés.

5. **Analyse de similarité basée sur les AST** : Les correctifs soumis sont normalisés en leur arbre syntaxique abstrait et hachés. La similarité structurelle est mesurée via le coefficient de Jaccard sur les ensembles de nœuds AST :

- Jaccard ≥ 0.95 : le correctif est rejeté (quasi-identique à un modèle de triche connu). - Jaccard $\in [0.90, 0.95)$: le score est réduit de moitié (similarité suspecte). - Similarité CFG > 0.85 : pénalité supplémentaire appliquée pour mimétisme du flot de contrôle.

1. **Revue de code par LLM** : Un modèle de langage entraîné sur des règles spécifiques à SWE-Forge examine chaque correctif pour détecter les motifs de codage en dur. La revue applique trois ensembles de règles : *no-hardcoding* (rejeter l'injection de valeurs triviales), *chutes-only* (imposer la conformité au conteneur Docker), et *generalist-agent* (rejeter toute stratégie qui subvertit l'intention de l'évaluation).

SWE-Forge est entièrement open source à `CortexLM/swe-forge`, avec son jeu de données publié sur HuggingFace.

1.7. Data Fabrication Challenge : Génération synthétique de jeux de données

1.7.1 Motivation

Le problème des données d'entraînement est le goulot d'étranglement central dans le développement des LLM. Même les modèles de pointe sont contraints par la quantité et la qualité des signaux de supervision disponibles. La génération de données synthétiques, où un modèle fort produit des paires (prompt, réponse) dont un modèle plus faible peut apprendre, est devenue la stratégie de mise à l'échelle dominante (Grattafiori et al., 2024 ; Team et al., 2024). Cependant, la qualité des données synthétiques varie considérablement, et les approches existantes manquent de garanties rigoureuses anti-plagiat.

Le **Data Fabrication Challenge** incite les mineurs à produire des jeux de données d'entraînement synthétiques de haute qualité, évalués par un harnais multi-étapes qui combine analyse structurelle, détection de plagiat sémantique et vérification de correction. De manière cruciale, les résultats de ce défi alimentent directement le pipeline de réglage fin par apprentissage par renforcement qui transforme le modèle de base de Platform en un agent capable, un lien que nous rendons explicite dans §4.2.5.

1.7.2 Protocole de soumission

Les mineurs soumettent des harnais Python, des scripts exécutables qui, lorsqu'ils sont lancés par le validateur, produisent des jeux de données de conversation au format JSONL. Chaque ligne du fichier de sortie est un objet JSON contenant un prompt et une solution correspondante. L'approche par harnais, plutôt que par téléchargement direct de données, garantit que le validateur peut ré-exécuter le processus de génération, vérifier le déterminisme et inspecter la logique de génération.

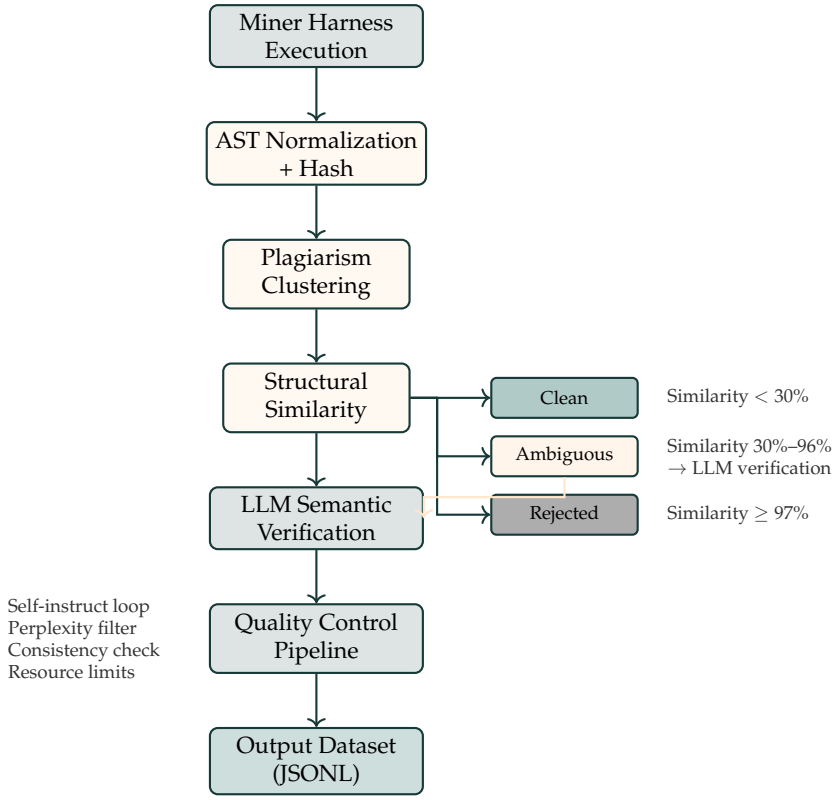

Figure 5 | Architecture diagram.

1.7.3 Pipeline anti-plagiat

Le harnais met en œuvre un système de détection de plagiat en deux passes :

Passe 1 : Vérification structurelle AST. Le code soumis est analysé en son arbre syntaxique abstrait. Tous les noms de variables sont normalisés en une forme canonique (`var_0`, `var_1`, `var_2`, ...) pour éliminer l'obfuscation cosmétique. L'AST normalisé est haché, et la similarité structurelle entre les soumissions est calculée via la plus longue sous-séquence commune (LCS) sur les séquences de nœuds AST.

Passe 2 : Vérification sémantique par LLM. Les soumissions dont la similarité structurelle se situe dans la plage ambiguë subissent une seconde passe où un modèle de langage les

Similarité Structurelle	Verdict	Action
$< 30\%$	Propre	Aucune vérification supplémentaire
30%–96%	Ambigu	Vérification sémantique par LLM déclenchée
$\geq 97\%$	Plagié	Soumission rejetée

compare pour équivalence sémantique, détectant les copies paraphrasées qui échappent à la comparaison structurelle.

Les seuils de plagiat sont :

Le regroupement par plagiat regroupe les soumissions par préfixe de hachage structurel, permettant une comparaison par paires efficace uniquement au sein des clusters plutôt que sur toutes les $O(n^2)$ paires.

1.7.4 Contrôle qualité

Au-delà du plagiat, le harnais impose plusieurs garanties de qualité :

- **Boucle self-instruct** : Un LLM génère de nouvelles paires (prompt, solution) à partir d'exemples amorces, puis un LLM validateur distinct vérifie la correction de chaque paire. Seules les paires passant à la fois la génération et la validation sont incluses.
- **Filtrage par perplexité** : Les sorties avec une perplexité au-dessus d'un seuil (relatif à un modèle de référence) sont rejetées comme probablement de faible qualité ou dénuées de sens.
- **Vérification de cohérence** : Environ **18%** des exemples générés sont rejetés par le filtre de cohérence, qui vérifie que la solution traite effectivement le prompt.
- **Limites de ressources** : L'exécution conteneurisée impose des contraintes sur le temps CPU, la mémoire et la taille du fichier de sortie pour empêcher les soumissions par déni de service.

1.7.5 Application : Pipeline de réglage fin par RL

L'application principale en aval du Data Fabrication Challenge est la production de paires (prompt, réponse) de haute qualité pour le réglage fin par apprentissage par renforcement. Ce lien est crucial : le défi n'existe pas de manière isolée mais sert de bras de production de données du pipeline d'entraînement complet de Platform.

Une fois que le Training Challenge (§4.4) produit un modèle de base (dont l'architecture a été déterminée par **PRISM** (§4.3)), les mineurs du Data Fabrication génèrent des données d'entraînement spécifiques au domaine ciblant les capacités que l'agent de Platform doit posséder : génération de code, analyse de bogues, raisonnement architectural et construction d'exploits. Une boucle d'entraînement RL distincte consomme ces paires (prompt, réponse), appliquant des méthodes de gradient de politique (par ex., **GRPO** ; Team et al., 2024) pour régler finement le modèle de base en un agent capable.

Cela crée un **pipeline en trois étapes** : PRISM (architecture) $\rightarrow$ Training (modèle de base) $\rightarrow$ Data Fabrication + réglage fin RL (agent capable). Le **Term Challenge** évalue ensuite l'agent résultant, fermant la boucle en fournissant des signaux de performance qui informent la recherche d'architecture et les stratégies d'entraînement. Le Data Fabrication Challenge occupe ainsi une position pivot dans l'écosystème Platform : c'est le mécanisme par lequel un modèle de base générique est transformé en un système spécialisé capable de servir d'agent.

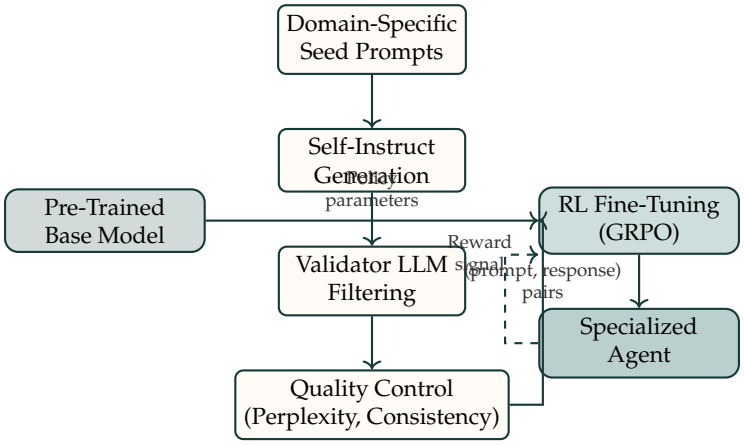

Figure 6 | Architecture diagram.

1.7.6 Échelle et adaptivité

L'échelle cible est de 10^7+ exemples par domaine, ce qui exige des mineurs qu'ils développent des pipelines de génération efficaces. Le harnais d'évaluation est conçu selon le ***principe d'entropie adaptative*** : le système d'évaluation s'adapte plus vite que la population de modèles ne s'améliore, maintenant le pouvoir discriminant à mesure que les capacités des mineurs augmentent. Cela est réalisé par la rotation des ensembles d'amorces, l'évolution des seuils de plagiat et le réétalonnage périodique des filtres de qualité.

Platform 3.0 est prévu pour mai 2026 et réactivera tous les challenges : Data Fabrication, Challenge Term et PRISM. Seuls ces trois challenges seront actifs sous Platform 3.0.

1.8. PRISM : Recherche d'architecture neuronale décentralisée

1.8.1 Une nouvelle catégorie de défi

PRISM (**P**latform **R**ecursive **I**nvestigation of **S**earch-space **M**orphologies) introduit une catégorie de défi qu'aucun autre sous-réseau Bittensor n'a tentée : *la recherche d'architecture neuronale avec des incitations cryptéoconomiques*.

Aucun sous-réseau Bittensor existant ne recherche dans l'espace des architectures. Les sous-réseaux existants évaluent soit la qualité de l'inférence, soit les contributions d'entraînement au sein d'une architecture prescrite, soit des métriques spécifiques à un domaine. **PRISM** est le premier protocole à traiter l'architecture elle-même comme l'objet d'une recherche décentralisée, et cette distinction a des conséquences théoriques et pratiques profondes.

La trajectoire de DeepSeek rend le cas pour la recherche d'architecture non ambigu. Chaque génération de modèles DeepSeek a introduit au moins un nouveau composant architectural, l'Attention Latente Multi-tête (DeepSeek-AI, 2024a), l'équilibrage de charge sans perte auxiliaire et la prédiction multi-token (DeepSeek-AI, 2024b), l'Attention Sparse Compressée et l'Attention Fortement Compressée (DeepSeek-AI, 2026), qui ont apporté des gains d'efficacité **d'un ordre de grandeur**. Ces découvertes sont issues d'une seule équipe de recherche opérant sur un cycle de **6** à **12** mois. La prémisse de **PRISM** est que le même processus de recherche, distribué sur des centaines de mineurs compétitivement incités, peut découvrir des innovations comparables ou supérieures à la granularité de l'epoch, continuellement plutôt que périodiquement.

1.8.2 L'espace de recherche d'architecture

PRISM définit un espace d'architecture combinatoire $\mathcal{F}$ couvrant **six** dimensions catégorielles et **quatre** paramètres continus, tel que conçu pour ce challenge :

Dimension	Choix	Nombre
Type d'attention	MHA, MQA, GQA, Linéaire, MLA	5
Type de FFN	Dense, GLU, MoE	3
Normalisation	LayerNorm, RMSNorm, DeepNorm	3
Activation	ReLU, GELU, SwiGLU	3
Encodage positionnel	RoPE, ALiBi, Aucun	3
Initialisation	Normal, Scaled, Fixup	3

PRISM définit un espace d'architecture combinatoire $\mathcal{F}$ couvrant **six** dimensions catégorielles : mécanisme d'attention, conception feed-forward, stratégie de normalisation, fonction d'activation, encodage positionnel et initialisation des poids, chacune avec **3** à **5** choix discrets, tel que conçu pour ce challenge, produisant des milliers de configurations catégorielles distinctes. Après suppression d'un petit nombre de combinaisons connues comme infaisables (par ex., l'initialisation Fixup avec LayerNorm est structurellement invalide), l'espace catégoriel viable reste grand. **Quatre** paramètres continus (dimension d'embedding, profondeur, têtes d'attention, ratio d'expansion FFN) subdivisent davantage chaque configuration catégorielle en un sous-espace continu, rendant l'espace de recherche total considérablement plus grand que le seul nombre de configurations catégorielles.

1.8.3 Le théorème de supériorité de la recherche d'architecture

Théorème 1 (Supériorité de la recherche d'architecture). *Soit $\mathcal{F}$ une famille d'architectures avec $|\mathcal{F}| \geq 2$. Un sous-réseau qui recherche dans $\mathcal{F}$ atteint une mise à l'échelle attendue strictement supérieure par rapport au budget de calcul total C comparé à tout sous-réseau qui évalue une architecture fixe $f \in \mathcal{F}$.*

Esquisse de preuve. Considérons un budget de calcul C alloué à K mineurs. Sous un sous-réseau à architecture fixe, tous les K mineurs entraînent la même architecture f^*, produisant une seule estimation de performance $\hat{L}(f^*)$. Sous un sous-réseau de recherche, les mineurs explorent des architectures distinctes $f_1, \ldots, f_K \in \mathcal{F}$, produisant les estimations $\hat{L}(f_1), \ldots, \hat{L}(f_K)$. La meilleure architecture découverte par le sous-réseau de recherche satisfait $\min_k \hat{L}(f_k) \leq \hat{L}(f^*)$ presque sûrement, avec inégalité stricte chaque fois que f^* n'est pas l'optimum global dans $\mathcal{F}$, ce qui est le cas générique pour tout espace de recherche non trivial avec $|\mathcal{F}| \geq 2$. Puisque le sous-réseau de recherche peut toujours adopter le choix du sous-réseau à architecture fixe comme l'un de ses K candidats, il domine au sens faible ; et comme la probabilité que le choix fixe soit globalement optimal diminue quand $|\mathcal{F}|$ croît, la domination est stricte pour tout espace de recherche non trivial. □

Le théorème établit que la taille de l'espace de recherche $|\mathcal{F}|$ *est* l'avantage, et non un coût à minimiser. Avec des milliers de configurations viables, l'espace de recherche de PRISM confère une supériorité structurelle sur tout laboratoire centralisé évaluant une poignée d'architectures par cycle d'entraînement.

1.8.4 L'entonnoir d'évaluation à quatre niveaux

Le pipeline d'évaluation multi-niveaux pour PRISM est actuellement en cours de développement et de recherche active. Ce qui suit décrit la direction actuelle explorée ; la conception finale pourra différer au fur et à mesure de l'avancée de la recherche.

Évaluer l'espace d'architecture complet à fidélité maximale est computationnellement infaisable dans le cycle d'émission du sous-réseau. PRISM met donc en œuvre un entonnoir à **quatre** niveaux qui filtre progressivement les candidats, concentrant le calcul sur les architectures les plus prometteuses :

L1 : Validation syntaxique. Chaque spécification d'architecture soumise est vérifiée pour sa validité structurelle : choix de dimensions compatibles, comptes de couches non négatifs, divisibilité valide des têtes d'attention. Ce niveau ne requiert aucun calcul et élimine les soumissions manifestement mal formées.

L2 : Notation multi-proxy. Les architectures validées sont évaluées à l'aide de métriques proxy légères : nombre de paramètres, FLOPs théoriques, empreinte mémoire d'activation et un estimateur de qualité proxy (par ex., indicateurs NAS à coût zéro). L2 consomme environ 0,001 heures de calcul par candidat et produit un classement préliminaire. De manière critique, la recette d'entraînement (taux d'apprentissage, taille de lot, programme) est **fixée par le protocole** au niveau L2 ; les mineurs ne peuvent pas gonfler leur score L2 en surajustant les hyperparamètres aux métriques proxy.

L3 : Proxy d'entraînement à une epoch. Les meilleurs candidats de L2 sont entraînés pendant une seule epoch sur un sous-ensemble de données représentatif. Le paysage de perte résultant fournit un critère de filtrage basé sur sigma : les architectures avec une perte au-dessus de la médiane sont éliminées. De plus, la corrélation de rang de Kendall τ est calculée entre le classement proxy L2 et le classement L3 à une epoch sur plusieurs suites de benchmarks. Si $\tau < 0.4$, le score de l'architecture est mis à zéro. Cette règle d'*élimination dure* empêche l'optimisation sur un seul benchmark, car une architecture qui surajuste un proxy montrera une incohérence de rang entre benchmarks.

L4 : Benchmark complet. Les top-K survivants de L3 reçoivent un cycle d'entraînement multi-epoch complet avec ajustement de loi d'échelle **VARPRO**. **VARPRO** (projection variable ; Golub & Pereyra, 1973) ajuste une relation en loi de puissance $L(C) = AC^{-\alpha} + L_\infty$ à la perte observée à plusieurs budgets de calcul, permettant la validation croisée d'échelle. Si une inversion de rang est détectée (c'est-à-dire qu'une architecture qui apparaît supérieure à un budget de calcul inférieur est dépassée à un budget supérieur), l'architecture est pénalisée via la détection d'effondrement d'échelle. Aucun autre système NAS n'implémente cette vérification de cohérence inter-budget.

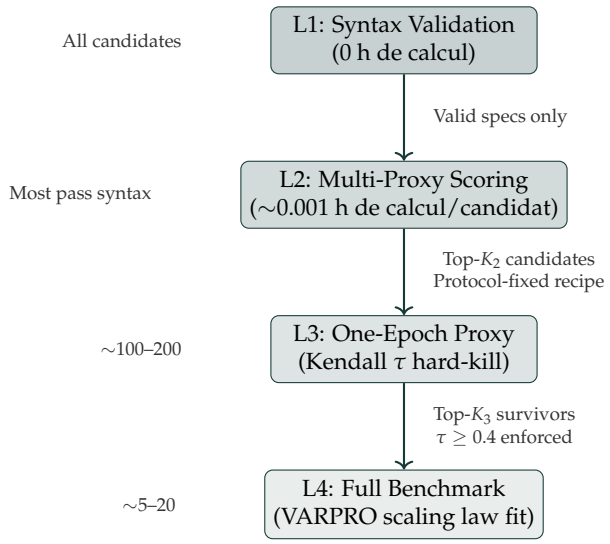

Figure 7 | Architecture diagram.

1.8.5 Notation en double voie et diversité

PRISM emploie un système de notation en double voie :

$S_{\text{PRISM}}(m) = 0.7 \times Q_{\text{arch}}(m) + 0.3 \times Q_{\text{recipe}}(m)$

où Q_{arch} mesure la qualité intrinsèque de l'architecture découverte (issu de l'évaluation L4) et Q_{recipe} mesure la qualité de la recette d'entraînement soumise avec l'architecture. La réparti-

tion **0.7/0.3** garantit que l'innovation architecturale est le principal moteur de récompense tout en incitant toujours aux bonnes pratiques d'entraînement.

Un bonus de diversité est appliqué pour empêcher le minage par copier-coller, la stratégie économiquement rationnelle consistant à soumettre des variations légères de l'architecture actuellement la mieux notée. Le bonus est calculé en fonction de la distance de Jaccard entre la soumission d'un mineur et le mode de la distribution des soumissions, récompensant les mineurs qui explorent les régions sous-représentées de $\mathcal{F}$.

1.8.6 Pourquoi PRISM est révolutionnaire

PRISM introduit six innovations qui, prises ensemble, constituent une avancée qualitative par rapport à tous les systèmes NAS antérieurs, tant au sein qu'en dehors de Bittensor :

1. **Premier NAS avec incitations cryptéoconomiques.** Dans PRISM, la recherche honnête est l'équilibre de Nash. Les mineurs qui soumettent des architectures véritablement novatrices passant l'entonnoir complet gagnent des récompenses ; les mineurs qui copient ou trichent sont détectés par empreinte AST, revue par LLM et élimination dure de Kendall τ. Aucun système NAS antérieur n'aligne le comportement de recherche avec des incitations financières.

2. **Le Théorème de Recherche d'Architecture prouve que la taille de l'espace de recherche EST l'avantage.** Avec des milliers de configurations viables, la recherche décentralisée est *prouvablement* supérieure à toute évaluation par agent unique. Ce n'est pas une affirmation empirique ; cela découle de la structure même du problème de recherche.

3. **Détection d'effondrement d'échelle en L4.** Aucun autre système NAS ne vérifie l'inversion de rang entre budgets de calcul. Un laboratoire centralisé entraînant une architecture à une seule échelle n'a aucun mécanisme pour détecter que l'avantage de son architecture disparaît à une échelle supérieure. L'ajustement VARPRO de PRISM en L4 rend cette détection automatique.

4. **Élimination dure par τ de Kendall en L3.** Aucun autre système NAS ne prévient l'optimisation sur un seul benchmark en imposant la cohérence de rang inter-benchmarks. La règle $\tau < 0.4 \rightarrow \text{score} = 0$ est une garantie structurelle que les survivants doivent être globalement compétents, et non étroitement surajustés.

5. **Recettes fixées par le protocole en L2.** En fixant la recette d'entraînement au niveau d'évaluation proxy, PRISM empêche les mineurs de gonfler les scores L2 par surajustement des hyperparamètres. La recette est une variable contrôlée, et non un degré de liberté.

6. **Recherche d'architecture complète vs. recherche partielle.** Les sous-réseaux existants qui touchent à l'espace d'architecture ne recherchent que sur une seule dimension (par exemple, les configurations de mécanismes d'attention pour l'optimisation de l'inférence). PRISM recherche simultanément sur les **six** dimensions, ce qui en fait le seul sous-réseau traitant la recherche d'architecture comme un problème de premier plan.

7. **DeepSeek prouve la thèse ; PRISM la systématise.** L'équipe de recherche de DeepSeek découvre un nouveau composant architectural tous les **6** à **12** mois : MLA en mai 2024, l'équilibrage de charge sans perte auxiliaire en décembre 2024, l'Attention Sparse Compressée en avril 2026. Chaque découverte nécessite des mois de recherche interne, du calcul significatif pour le prototypage et un cycle complet de publication. PRISM comprimera cette chronologie de mois en epochs : des centaines de mineurs exploreront

simultanément différentes régions de l'espace d'architecture, le pipeline de filtrage multi-niveaux identifiant automatiquement les candidats prometteurs, et le réseau récompensant les innovations authentiques par des émissions de TAO, sans nécessiter d'équipe de recherche, de publication ou de campagne de recherche coordonnée centralement. Ce que DeepSeek accomplit par l'effort concentré d'une des meilleures équipes de recherche au monde, PRISM l'accomplira par la recherche compétitive décentralisée à l'échelle du réseau. Le **Théorème de Recherche d'Architecture** (§4.3.3) prouve que ce n'est pas simplement plus rapide ; c'est structurellement supérieur, car la recherche décentralisée dans un espace combinatoire domine prouvablement toute recherche par agent unique lorsque l'espace dépasse un seuil de taille modeste.

Table 1 | Comparaison de PRISM avec les approches existantes. PRISM combine de manière unique la recherche d'architecture complète, les incitations cryptéoconomiques et l'anti-manipulation multi-niveaux.

Caractéristique	PRISM	Sous-réseau arch. fixe	NAS centr.	Aléatoire
Espace de recherche	Complet (6 dim.)	Fixe	Variable	Variable
Incitations	Oui	Oui	Non	Non
Cross-budget	Oui	Non	Rare	Non
Cohérence rang	Oui	Non	Non	Non
Recette fixée	Oui	Non	Non	Non
Anti-manipulation	Oui	Non	Non	N/A

L'équipe de recherche de DeepSeek effectue une recherche d'architecture manuelle sur un cycle de **6** à **12** mois, correspondant à une entrée « NAS centr. » avec une couverture de recherche partielle (limitée aux composés que leur équipe R&D priorise) et sans évaluation inter-budget, application de la cohérence de rang, contrôle par recette fixée ou mécanismes anti-manipulation.

PRISM existe en tant que dépôt privé à `PlatformNetwork/prism` (créé en avril 2026) et devrait entrer en évaluation active début mai 2026.

1.9. Training Challenge : Pré-entraînement décentralisé

1.9.1 Motivation

Une fois que **PRISM** détermine l'architecture optimale, le réseau a besoin d'un mécanisme pour entraîner le modèle résultant. Le **Training Challenge** aborde la phase la plus intensive en calcul du développement de l'IA : le pré-entraînement d'un grand modèle de langage à partir de zéro. Ce défi est le successeur direct de l'entraînement décentralisé démontré par **Covenant-72B** sur le sous-réseau 3, mais intégré au cadre multi-défis de Platform.

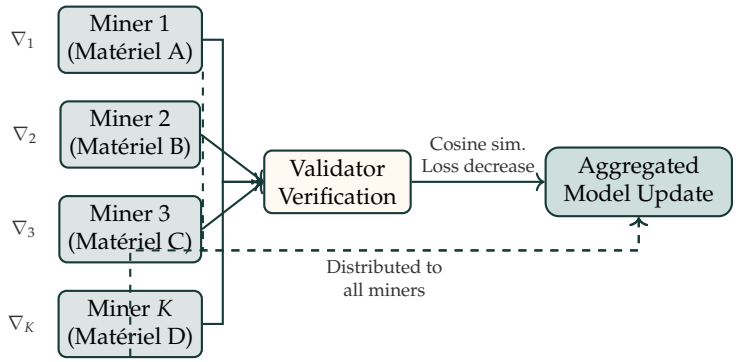

Figure 8 | Architecture diagram.

1.9.2 Principe de conception : Décentralisation complète

Le Training Challenge a une contrainte de conception non négociable : l'entraînement DOIT être entièrement décentralisé. Contrairement aux approches hybrides qui permettent une orchestration centralisée, où une entité unique coordonne l'exécution de l'entraînement, assigne des fragments de données et gère les points de contrôle, le Training Challenge de Platform exige qu'aucune entité unique ne contrôle le processus d'entraînement. Ce principe est axiomatique, et non pragmatique : le but même de Bittensor est de créer des systèmes qu'aucune autorité centrale ne peut capturer, et un cycle d'entraînement orchestré centralement violerait ce principe au niveau le plus fondamental.

La décentralisation complète signifie :

- **Pas de coordinateur central** : Les mineurs s'auto-organisent en cohortes d'entraînement. Le protocole spécifie comment les mineurs découvrent leurs pairs, négocient les assignations d'entraînement et synchronisent les points de contrôle, le tout sans planificateur central.
- **Pas d'agrégateur de confiance** : L'agrégation des gradients doit être vérifiable. Tout mineur ou validateur doit pouvoir vérifier indépendamment que la mise à jour agrégée est une combinaison fidèle des contributions individuelles.
- **Pas de point de défaillance unique** : Le cycle d'entraînement doit continuer même si des mineurs individuels abandonnent, soumettent des gradients mal formés ou tentent d'empoisonner la mise à jour. Le protocole doit être résilient aux défaillances byzantines.

1.9.3 Questions de recherche ouvertes

Le Training Challenge est en phase de recherche et de conception actives. Des agents autonomes mènent des recherches pour déterminer les approches architecturales optimales pour l'entraînement décentralisé, explorant comment maintenir l'efficacité de l'entraînement tout en préservant la décentralisation complète. Les questions ouvertes clés incluent :

- **Agrégation des gradients sous matériel hétérogène** : Les mineurs contribuent différents types de matériel avec des capacités de mémoire et de calcul variables. Comment le protocole devrait-il normaliser et pondérer les contributions de gradient de sources hétérogènes tout en maintenant des garanties de convergence ?
- **Atténuation des retardataires sans orchestration centrale** : Dans l'entraînement centralisé, un serveur de paramètres peut détecter et exclure les travailleurs lents. Dans un contexte décentralisé, il n'existe pas de tel coordinateur. Comment le protocole peut-il détecter les retardataires et adapter le calendrier d'entraînement sans horloge centrale ?
- **Vérification par les validateurs des contributions de gradient honnêtes** : Un validateur recevant une mise à jour de gradient d'un mineur doit vérifier que la mise à jour a été calculée honnêtement (c'est-à-dire sur le fragment de données correct, avec le bon état du modèle, et sans modification adversariale). La vérification naïve nécessite de recalculer le gradient, ce qui annule le but du calcul distribué. Quel est le protocole de vérification à coût minimal qui fournit des garanties cryptéoconomiques d'honnêteté ?
- **Cohérence des points de contrôle dans un environnement byzantin** : Lorsque les mineurs sont en désaccord sur l'état du modèle (en raison de mises à jour perdues, de partitions réseau ou de comportement adversarial), comment le protocole résout-il les incohérences et garantit que tous les mineurs honnêtes convergent vers le même modèle ?

Ces questions représentent la frontière de la recherche sur les systèmes ML décentralisés. Des agents autonomes explorent ces problèmes en parallèle, testant des protocoles candidats et itérant sur les conceptions à un rythme qu'une seule équipe de recherche ne peut égaler. Le Training Challenge devrait être le défi le plus complexe techniquement dans l'écosystème Platform, et sa conception évoluera probablement à travers de multiples itérations de recherche pilotées par des agents avant son activation.

1.9.4 Relation avec les autres défis

Le Training Challenge occupe une position centrale dans le pipeline de Platform :

- **En amont** : Il reçoit l'architecture optimale découverte par PRISM (§4.3). Sans la recherche de PRISM, le Training Challenge entraînerait une architecture sous-optimale, gaspillant des ressources de calcul substantielles.
- **En aval** : Sa sortie (le modèle de base pré-entraîné) sert de fondation au pipeline de réglage fin RL du Data Fabrication (§4.2.5). Le modèle de base fournit la compréhension langagière générale que le réglage fin RL spécialise en capacités d'agent.
- **Évaluation** : L'agent entraîné résultant est évalué sur le Term Challenge, fournissant des signaux de performance qui alimentent en retour la recherche d'architecture et la sélection de stratégie d'entraînement.

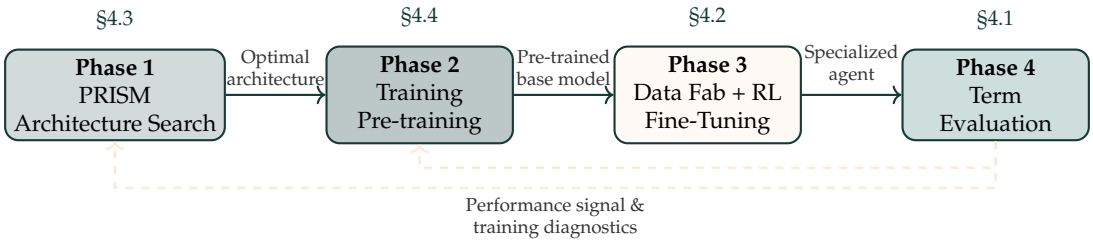

Figure 9 | Architecture diagram.

1.9.5 État actuel et calendrier

Le Training Challenge est en phase de recherche et de conception actives. Il s'agit du défi le plus ambitieux techniquement dans l'écosystème Platform. Des agents autonomes dirigent l'effort de recherche, enquêtant indépendamment sur des conceptions de protocole, testant des architectures candidates et itérant vers un protocole d'entraînement décentralisé robuste. Sur la base de la trajectoire de recherche actuelle pilotée par les agents, le Training Challenge devrait entrer en phase de tests préliminaires fin mai 2026.

1.10. Orthogonalité des défis et Orthogonalité des incitations

1.10.1 Dissemblance structurelle

Les quatre défis sondent des dimensions de capacité fondamentalement différentes :

Le Term Challenge récompense l'***exploitation***, la résolution efficace de problèmes connus. Le Data Fabrication Challenge récompense la ***génération***, la production de données d'entraînement nouvelles et de haute qualité. PRISM récompense la ***recherche***, l'exploration systématique d'un espace combinatoire exponentiellement grand. Le Training Challenge récompense la ***coordination***, la capacité à contribuer des mises à jour de gradient utiles à un cycle d'entraînement globalement distribué sans orchestration centrale. Ces **quatre stratégies**

Table 2 | Dissemblance structurelle entre les quatre catégories de défis de Platform

Défi	Dimension de capacité	Connaissance requise	Type de stratégie	Phase
Term	Exécution en ingénierie	Bogue connu + espace de correctifs	Exploitation	4
Data Fabrication	Qualité synthétique	Schéma de données connu	Génération	3
PRISM	Recherche d'architecture	Espace d'architecture inconnu	Recherche	1
Training	Pré-entraînement décentralisé	Architecture connue, partition de données inconnue	Coordination	2

Défi	Statut	Activation prévue
Term	Inactif (Platform 3.0)	Mai 2026
Data Fabrication	À venir 3.0	Mai 2026
PRISM	À venir 3.0	Mai 2026
Training	Recherche	Fin mai 2026

sont structurellement dissemblables : la compétence dans l'une ne prédit pas la compétence dans une autre, et l'approche optimale pour chacune est algorithmiquement distincte.

1.10.2 Orthogonalité des incitations

L'orthogonalité des défis crée un rendement non linéaire à la capacité complète. Un mineur qui se spécialise dans un seul défi fait face à des rendements marginaux décroissants à mesure que le harnais d'évaluation s'adapte (le **principe d'entropie adaptative**). Un mineur qui concourt sur plusieurs défis peut faire de l'arbitrage entre eux, allouant le calcul au défi offrant actuellement la plus forte récompense marginale par FLOP. Cela crée un avantage structurel pour les mineurs généralistes sur les spécialistes, la ***prime de capacité complète***.

Formellement, soit $R_i(m)$ la récompense du mineur m provenant du défi i. Sous notation indépendante, la récompense totale est $R(m) = \sum_i R_i(m)$. Pour un mineur spécialiste maximisant R_{i^*} sur un seul défi i^* et gagnant zéro sur les autres, le rendement marginal du calcul supplémentaire sur i^* diminue avec l'investissement en raison de la décroissance WTA. Pour un mineur généraliste distribuant le calcul sur tous les défis, chaque R_i reçoit un investissement sous-saturant et opère dans le régime de rendement marginal élevé. Lorsque les défis sont orthogonaux (c'est-à-dire $\mathrm{Cov}(R_i, R_j) \approx 0$ pour $i \neq j$), la récompense totale attendue du généraliste dépasse strictement celle du spécialiste.

1.10.3 Allocation des émissions

Les allocations d'émissions entre les défis sont déterminées de manière autonome par **Atlas 3.0**, le système d'orchestration automatisé des émissions du sous-réseau, qui ajuste continuellement les pondérations des défis en fonction des taux de participation, des métriques de maturité et de l'impact démontré, sans nécessiter de votes de gouvernance manuels ni d'allocations en pourcentage fixe. Le Data Fabrication Challenge, PRISM et le Training Challenge sont à venir avec les calendriers prévus suivants :

Lors de l'activation des quatre défis, Atlas 3.0 rééquilibrera de manière autonome les émissions pour refléter l'impact marginal démontré de chaque défi sur la mission du sous-réseau.

1.10.4 Défense anti-manipulation combinatoire

La conception multi-défis est la défense *principale* contre le piratage des récompenses. Chaque défi individuel possède ses propres mesures anti-manipulation (conteneurisation Docker, empreinte AST, détection de plagiat, élimination dure de Kendall τ, vérification des gradients), mais ce sont des défenses de couche 1 : elles peuvent être percées par un attaquant suffisamment sophistiqué. L'architecture multi-défis fournit une défense de couche 2 : pour capturer

une part dominante des émissions du sous-réseau, un mineur doit simultanément manipuler **quatre** pipelines d'évaluation en évolution, chacun avec des vulnérabilités différentes, des cadences de mise à jour différentes et des mécanismes de détection différents. Le coût combinatoire de maintien de quatre exploitations indépendantes dépasse de loin le coût d'une compétence multi-défis authentique, rendant la participation honnête la stratégie d'équilibre.

Ce principe, selon lequel l'*intersection* de défis orthogonaux est plus difficile à manipuler qu'un seul défi, est une contribution de conception qui se généralise au-delà de Platform à tout réseau d'incitations multi-objectifs.

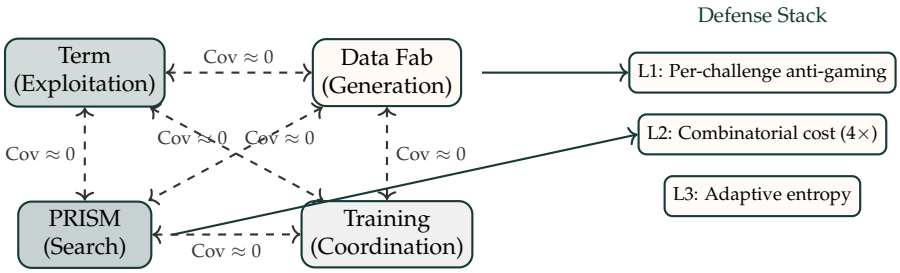

Figure 10 | Architecture diagram.

1.10.5 Le pipeline de production de bout en bout

Les quatre défis ne fonctionnent pas indépendamment ; ils forment un **pipeline de production en boucle fermée** pour construire et évaluer des agents IA. Cette structure de bout en bout est la contribution architecturale centrale de Platform, et nous la décrivons ici en détail pour rendre explicite la relation entre les défis.

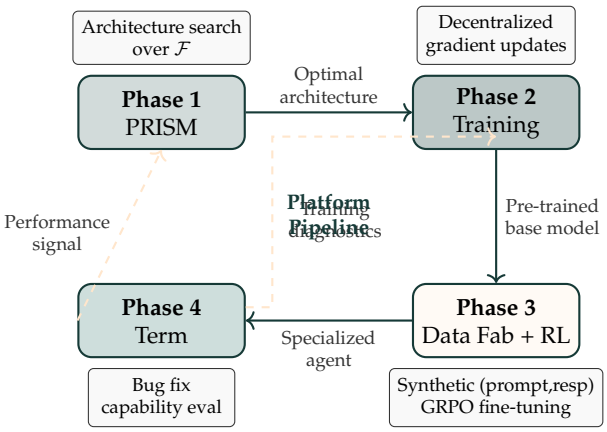

Figure 11 | Architecture diagram.

Le pipeline opère en **quatre phases** :

Phase 1 : Recherche d'architecture (PRISM, §4.3) : Les mineurs recherchent dans l'espace d'architecture $\mathcal{F}$ pour découvrir la configuration de modèle optimale. Le résultat est une définition d'architecture entièrement spécifiée qui détermine les biais inductifs, la capacité et les exigences de calcul du modèle.

Phase 2 : Pré-entraînement décentralisé (Training Challenge, §4.4) : Les mineurs entraînent collectivement le modèle de base en utilisant l'architecture de la Phase 1. Chaque mineur contribue des mises à jour de gradient calculées sur des fragments de données locaux, qui sont vérifiées par les validateurs et agrégées en une mise à jour globale du modèle. Le processus d'entraînement est entièrement décentralisé : aucune entité unique ne contrôle les données, l'agrégation des gradients ou le calendrier des points de contrôle.

Phase 3 : Réglage fin par RL (Data Fabrication + RL, §4.2) : Les mineurs du Data Fabrication génèrent des paires (prompt, réponse) spécifiques au domaine ciblant les capacités que l'agent de Platform doit posséder. Une boucle d'entraînement RL distincte règle finement le modèle de base pré-entraîné en utilisant ces paires, appliquant des méthodes de gradient de politique pour produire un agent spécialisé capable de synthèse de code, découverte de bogues et raisonnement architectural.

Phase 4 : Évaluation de l'agent (Term, §4.1) : L'agent entraîné est évalué sur le Term Challenge (résolution de bogues connus). Ces défis mesurent la capacité d'exploitation de l'agent, la dimension la plus pertinente pour l'ingénierie logicielle en production.

Rétroaction en boucle fermée : Les résultats de l'évaluation alimentent en retour la recherche d'architecture (Phase 1) et la stratégie d'entraînement (Phase 2). Un agent dont la performance au Term Challenge est inférieure aux attentes signale que l'architecture ou les données d'entraînement peuvent nécessiter un ajustement, créant un cycle auto-améliorant où le réseau optimise continuellement son propre pipeline de production.

2. L'Argument Économique : Pourquoi le TAO Surpasse les Salaires

2.1. Le Problème des Talents dans l'IA Centralisée

La concentration des talents en recherche en IA au sein d'un petit nombre de laboratoires corporatifs a produit un marché du travail qui est, selon toute mesure économique raisonnable, dysfonctionnel. Le vivier mondial de chercheurs capables de faire avancer la frontière de l'apprentissage automatique à grande échelle est estimé à plusieurs dizaines de milliers (Maslej et al., 2024), la sous-partie répondant aux critères d'embauche typiques (expertise de niveau doctorat, volonté de déménager, éligibilité aux visas) étant considérablement plus restreinte. Cette rareté, combinée à l'importance stratégique des capacités en IA, a déclenché une escalade salariale qui ressemble aux dynamiques de fin de cycle d'une bulle plutôt qu'à l'équilibre en régime permanent d'un marché concurrentiel.

Au moment où nous écrivons ces lignes, les chercheurs seniors en IA chez OpenAI, Anthropic et Google DeepMind obtiennent, selon des rapports, des packages de rémunération totale allant de **$500,000** à plus de **$2,000,000** par an (Metz, 2024; Hao, 2023). Cette escalade suit un schéma prévisible : lorsqu'un laboratoire augmente son offre pour attirer des talents, les concurrents s'alignent ou la dépassent, établissant un nouveau plancher qui devient la référence pour le prochain cycle de recrutement. Le résultat est une course aux armements en coûts de main-d'œuvre qui évolue linéairement avec les effectifs tout en produisant des rendements marginaux décroissants en capacité : une dynamique classique de reine rouge (Van Valen, 1973) appliquée au capital humain.

La rémunération en actions aggrave ce problème plutôt que de le résoudre. Les unités d'actions restreintes et les attributions d'actions créent ce que les observateurs de l'industrie appellent des **"menottes dorées"** : les chercheurs sont financièrement incités à rester dans leur institution actuelle indépendamment du fait qu'elle reste ou non le meilleur environnement pour leur travail. Plus critiques encore, les structures d'actions créent des incitations mal alignées : un chercheur dont la rémunération est liée au succès commercial des produits d'une seule entreprise a une incitation rationnelle à optimiser l'avantage propriétaire plutôt que le progrès scientifique ouvert. Les chercheurs qui souhaitent construire en ouvert (publier des méthodes, partager des jeux de données et contribuer à l'infrastructure publique) font face à un choix brutal entre sécurité financière et liberté intellectuelle. L'écosystème actuel ne propose aucune alternative viable qui réconcilie ces objectifs.

Ce goulet d'étranglement des talents a des conséquences structurelles au-delà de la rémunération individuelle. Lorsque les chercheurs les plus capables sont concentrés au sein de moins d'une douzaine d'institutions, la probabilité que la prochaine idée révolutionnaire

émerge de l'extérieur de ce cercle tend vers zéro, non pas parce que les outsiders manquent de capacité, mais parce qu'ils manquent des ressources, des données et de l'accès au calcul qui rendent possible l'expérimentation à l'échelle de la frontière. Le modèle centralisé crée ainsi une prophétie autoréalisatrice : il contraint le vivier de talents en restreignant l'accès, puis invoque l'absence de percées externes comme preuve que le vivier de talents était correctement délimité.

2.2. Le Modèle Économique de Platform

Le mécanisme d'incitation de Platform inverse le modèle de travail centralisé sur chaque axe de contrainte. Là où les laboratoires centralisés restreignent la participation par des processus de recrutement, des exigences de visa, des relocalisations géographiques et des politiques organisationnelles, Platform permet à quiconque dispose d'une connexion internet de contribuer et de gagner des récompenses en TAO uniquement sur la base de sa capacité démontrée.

La nature **sans permission** des émissions de **TAO** n'est pas simplement un choix de conception mais un axiome structurel. Un mineur à Lagos qui développe un agent de génération de code supérieur gagne exactement le même TAO par unité de capacité démontrée qu'un mineur à San Francisco titulaire d'un doctorat de Stanford. Le mécanisme d'évaluation (la couche d'évaluation adverse décrite à la Section 4), fonctionne sans connaissance de l'identité du mineur, de ses références ou de sa localisation géographique. Ce n'est pas une aspiration ; c'est une propriété architecturale du système. Les validateurs notent les mineurs sur la base de leurs performances aux benchmarks, et les émissions coulent proportionnellement à ces notes. Il n'y a pas de comité de recrutement, pas d'exigence de parrainage de visa, pas d'ajustement au coût de la vie qui privilégie les géographies à loyer élevé.

Les implications économiques de ce modèle sans permission sont substantielles. Le vivier de talents adressable pour les laboratoires d'IA centralisés est approximativement délimité par l'intersection de trois ensembles : les individus ayant une expertise en ML de niveau doctorat (estimés à **30,000–50,000** dans le monde ; Maslej et al., 2024), ceux disposés à déménager dans une poignée de villes (50% des précédents), et ceux éligibles aux visas de travail aux États-Unis, au Royaume-Uni ou dans l'Union européenne (30% des précédents). Cela donne un vivier effectif d'environ **15,000–20,000** candidats. Le vivier adressable de Platform, en revanche, est limité uniquement par l'accès à internet et la capacité technique : environ **45 millions** d'individus dans le monde possèdent des compétences en programmation suffisantes pour participer en tant que mineurs (SlashData, 2024), un chiffre qui inclut les amateurs et les étudiants, pas seulement les professionnels. Même en tenant compte de la sous-partie bien plus petite capable de contribuer à la frontière, le vivier de talents effectif de Platform est au minimum deux à trois ordres de grandeur plus important que l'alternative centralisée.

Les récompenses sur Platform évoluent avec la capacité démontrée, non avec l'ancienneté, le prestige institutionnel ou le capital politique. Un mineur qui améliore les scores SWE-bench Verified de 5 points de pourcentage reçoit une augmentation proportionnelle des émissions de TAO indépendamment de son palmarès de publications, de son affiliation académique ou de ses années d'expérience. Cette structure **méritocratique** élimine les jeux de signalisation qui dominent la recherche en IA académique et corporative : des jeux dans lesquels les chercheurs optimisent l'acceptation dans les revues, le nombre de citations ou les évaluations internes de performance plutôt que de véritables avancées de capacité (Bergstrom & West, 2021).

2.3. Comparaison Quantitative

Pour rendre la comparaison économique concrète, le Tableau 2 présente une comparaison systématique selon les principales métriques économiques et structurelles. Les données pour OpenAI et Anthropic sont tirées de rapports publics et de divulgations d'investisseurs ; les

chiffres de Platform sont calculés à partir des données d'émission on-chain et des tableaux de bord des validateurs.

Table 3 | Laboratoires Centralisés vs Platform : Comparaison Économique

Métrique	OpenAI	Anthropic	Platform
Dépense annuelle en calcul d'entraînement	$~3B	$~4B+	**Émission TAO[a]**
Effectifs (R&D)	~4,000+	~1,500+	**256 slots UID max par sous-réseau[b]**
Taille du vivier de talents	~15K	~15K	**~45M[c]**
Couverture géographique	3–5 villes	2–3 villes	**Mondiale (sans permission)**
Incitation à l'innovation	Salaire + actions	Salaire + actions	**Émission TAO (liée à la performance)**
Mécanisme d'évaluation	Benchmarks internes	Benchmarks internes	**Adversarial (anti-manipulation multi-niveaux ; Section 4)**
Temps pour déployer une nouvelle évaluation	Mois	Mois	**Heures (gouvernance Platform)**

[a]Le budget R&D de Platform est libellé en émissions de TAO, non en USD ; sa valeur équivalente en USD fluctue avec les prix du marché et ne peut être comparée de manière significative aux budgets des laboratoires en dollars fixes.

[b]Chaque sous-réseau Bittensor supporte jusqu'à 256 slots UID totaux partagés entre mineurs et validateurs, avec un maximum par défaut de 64 permis de validateur par sous-réseau ; les mineurs actifs fluctuent car les participants s'inscrivent et se désinscrivent en continu, de sorte qu'un décompte ponctuel n'est pas représentatif.

[c]Population développeurs mondiale approximative selon SlashData 2024.

La divergence la plus frappante réside dans la taille du vivier de talents. Les laboratoires centralisés puisent dans un vivier effectif d'environ **15,000** candidats qualifiés, contraints par les exigences de formation, la disponibilité des visas et l'immobilité géographique. Platform puise dans un vivier d'environ **45 millions** d'individus possédant les compétences techniques pertinentes, limités uniquement par l'accès à internet (ce chiffre inclut les amateurs et les étudiants, pas seulement les professionnels). Cela représente une expansion d'environ **2,900**× du vivier de talents adressable, une différence qui se compose au fil du temps à mesure que la structure d'incitation de Platform attire des contributeurs qui n'apparaîtraient jamais sur le radar de recrutement d'un laboratoire.

La comparaison des dépenses annuelles de R&D nécessite une interprétation prudente. OpenAI et Anthropic dépensent chacune des ordres de grandeur supplémentaires en termes absolus en USD. Cependant, les dépenses de Platform sont libellées en TAO (un actif liquide coté sur le marché), ce qui rend la comparaison directe en USD trompeuse. Les émissions de TAO de Platform sont presque entièrement dirigées vers la production de capacités (récompenses des mineurs pour les performances aux benchmarks), tandis que les dépenses des laboratoires centralisés englobent les installations, les frais administratifs, les coûts de recrutement et des projets qui peuvent ne jamais atteindre le déploiement. Le ratio entre les dépenses et la production directe de capacités est considérablement plus favorable pour Platform que ne le suggèrent les chiffres bruts.

La ligne du mécanisme d'évaluation souligne davantage l'avantage structurel de Platform. Les benchmarks internes des laboratoires centralisés sont développés, maintenus et interprétés par la même organisation dont ils mesurent les performances, un conflit d'intérêts qui a produit des cas bien documentés de manipulation de benchmarks et de signalement sélectif (Birhane et al., 2023). L'**évaluation adverse** de Platform, avec son cadre anti-manipulation multi-niveaux (Section 4) et ses incitations financières pour les validateurs qui détectent les manipulations, crée un environnement d'évaluation qui est structurellement plus digne de confiance que tout processus interne.

2.4. L'Effet Volant

Le modèle économique décrit ci-dessus n'est pas statique. Il fonctionne selon une boucle de rétroaction positive, ce que nous appelons le **volant d'incitation**, qui reflète et étend les dynamiques observées dans les écosystèmes open source à succès.

Dans le logiciel open source, le volant fonctionne par des incitations réputationnelles : les contributeurs construisent des logiciels, les logiciels gagnent en adoption, les contributeurs acquièrent de la réputation et du capital professionnel, ce qui attire davantage de contributeurs (Raymond, 1999 ; Lerner & Tirole, 2002). Ce mécanisme a produit Linux (qui alimente pratiquement toute l'infrastructure cloud), Python (qui domine le ML) et PyTorch (qui a supplanté le TensorFlow soutenu par des entreprises dans les contextes de recherche). Cependant, les incitations réputationnelles sont indirectes, à action lente et peu fiables ; elles ne peuvent pas soutenir le type de contribution soutenue et de fort effort que l'IA de frontière exige.

Platform ajoute l'élément manquant : des incitations financières directes et mesurables alignées sur la production de capacités. Le volant fonctionne comme suit : les mineurs concourent sur les benchmarks, produisant des améliorations de capacité mesurables ; ces améliorations augmentent la valeur perçue de la production du sous-réseau ; la valeur croissante de la production augmente la demande et le prix du TAO ; un prix du TAO plus élevé augmente la valeur en dollars des récompenses d'émission ; des récompenses plus importantes attirent davantage de mineurs ; un vivier de mineurs plus important intensifie la concurrence, stimulant de nouvelles améliorations de capacité. Le cycle est auto-renforçant et, crucialement, ne dépend d'aucun coordinateur central ni décision de financement ; il émerge de l'interaction entre les règles d'émission au niveau du protocole et la découverte de prix par le marché.

La Figure 9 illustre ce volant. Chaque flèche représente un mécanisme causal qui fonctionne sans direction centralisée, piloté plutôt par l'auto-intérêt rationnel des mineurs et validateurs individuels répondant aux incitations du protocole.

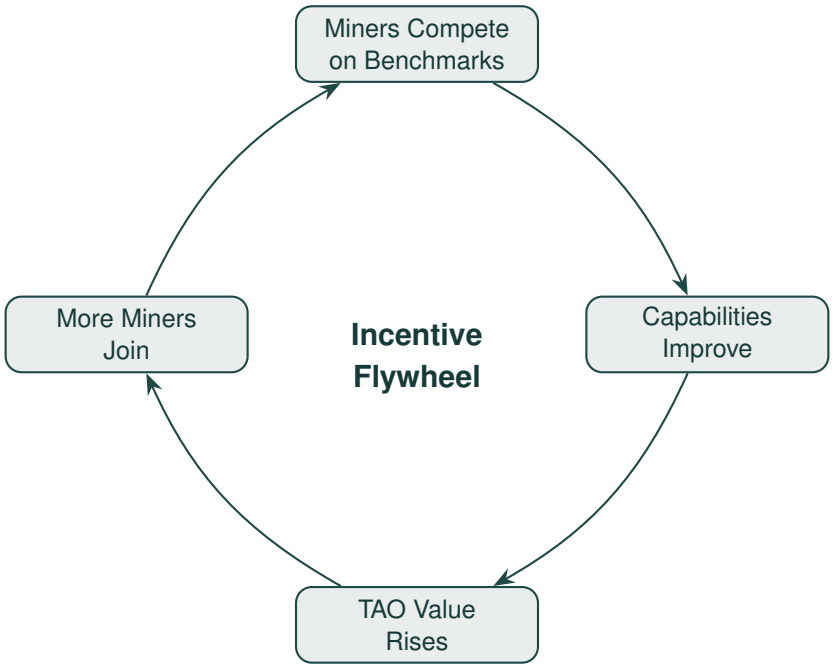

Figure 12 | Architecture diagram.

Le précédent historique est instructif. Linux a commencé comme un projet étudiant sans structure d'incitation financière ; il a fallu une décennie pour atteindre l'adoption en entreprise. Le volant de Platform comprime cette chronologie en substituant des récompenses financières directes à la lente accumulation de capital réputationnel. Là où un contributeur Linux pourrait attendre des années que son travail soit reconnu et récompensé (si jamais il l'est), un mineur Platform reçoit des émissions de TAO dans les heures qui suivent la démonstration d'une amélioration des performances aux benchmarks. Le résultat est une structure d'incitation qui préserve l'ouverture et la contribution sans permission de l'open source tout en ajoutant l'urgence et l'échelle des récompenses pilotées par le marché.

3. L'IA Décentralisée Peut-Elle Concurrenter avec les Laboratoires Centralisés ?

3.1. La Vue Sceptique (et Pourquoi Elle Est Erronée)

L'affirmation selon laquelle un réseau décentralisé de mineurs sans permission peut produire des capacités en IA concurrentielles face à des laboratoires centralisés dépensant des milliards de dollars est, en apparence, extraordinaire. Le scepticisme est justifié. Nous traitons les quatre objections les plus courantes à tour de rôle.

Objection 1 : "Les laboratoires ont plus de calcul." Cela est vrai au sens étroit où OpenAI et Google DeepMind contrôlent chacun des clusters de calcul plus importants que ce qu'un seul mineur Platform peut assembler. Mais ce cadrage confond la *concentration* de calcul avec la *capacité* de calcul. Platform ne nécessite pas une seule exécution d'entraînement monolithique ; il distribue le calcul à travers des milliers de nœuds indépendants, chacun contribuant une fraction du total. Le modèle **Covenant-72B** a démontré précisément cette architecture : entraîné sur des nœuds Bittensor sans permission (au moins 70 pairs uniques cumulativement, plafonnés à 20 contributeurs par tour, avec une moyenne de 16.9) sans orchestration centralisée, il a atteint un score MMLU de **67.1**, concurrentiel avec le LLaMA-2-70B de Meta à **65.6** MMLU (0-shot). L'implication est claire : l'entraînement distribué à l'échelle de la frontière n'est pas une possibilité théorique mais une réalité empirique, et l'écart de performance entre l'entraînement distribué et centralisé se réduit à mesure que les techniques d'orchestration s'améliorent.

De plus, le calcul total disponible pour Platform n'est pas borné par le budget d'une seule entité. Il est borné uniquement par la volonté agrégée d'opérateurs indépendants de déployer du matériel en poursuite de récompenses en TAO, une somme qui croît avec le prix du TAO et n'a pas de plafond théorique. Au moment où nous écrivons ces lignes, la capacité de calcul agrégée du réseau Bittensor à travers tous les sous-réseaux peut être substantielle, bien que cette affirmation n'ait pas été vérifiée de manière indépendante et soit vraisemblablement dépassée par les plus grands clusters centralisés.

Objection 2 : "Les laboratoires ont de meilleures données." Cette objection porte historiquement plus de poids mais s'affaiblit rapidement. Le paysage des données d'entraînement a subi un changement structurel vers la marchandisation. Common Crawl fournit **250 milliards** de pages web ; The Pile offre **825 Go** de texte organisé ; RedPajama réplique le mélange d'entraînement de LLaMA à **1,2 billion** de tokens (Weber et al., 2023). Ces jeux de données sont librement disponibles pour tout mineur sur Platform. En outre, le Défi de Fabrication de Données de Platform fournit un mécanisme permettant aux mineurs de contribuer et d'être récompensés pour la production de données synthétiques et organisées de haute qualité, l'atout même que les laboratoires traitent comme un avantage propriétaire. L'économie de la production de données s'inverse sous le modèle d'incitation de Platform : là où les laboratoires thésaurisent les données comme un fossé concurrentiel ; Platform récompense la contribution de données comme un bien commun, créant un avantage structurel qui se compose à mesure que le réseau croît.

Objection 3 : "Les laboratoires ont de meilleurs chercheurs." C'est l'objection à laquelle la Section 5 a été conçue pour répondre. L'affirmation repose sur l'hypothèse que les quelques dizaines de milliers de chercheurs employés par les meilleurs laboratoires (Maslej et al., 2024) représentent un échantillonnage raisonnablement complet de la distribution mondiale des talents. Ce n'est pas le cas. Le pipeline de recrutement centralisé (doctorat d'un programme top-5, suivi d'un travail postdoctoral, suivi d'une relocalisation à San Francisco ou Londres) exclut systématiquement la vaste majorité des individus capables : ceux sans accès aux institutions d'élite, ceux dans l'incapacité d'immigrer, ceux qui ont quitté le monde académique pour l'industrie, et ceux qui ne sont jamais entrés dans le pipeline de recherche formel. Le modèle sans permission de Platform échantillonne à partir d'un vivier de talents qui est, selon une estimation prudente, **100–500**$\times$ plus grand. La prochaine insight architecturale à l'échelle de

Transformer n'a pas nécessairement à venir d'un laboratoire à San Francisco. Elle peut venir d'un mineur n'importe où dans le monde, et sous la structure d'incitation de Platform, elle sera récompensée de manière identique indépendamment de son origine.

Objection 4 : "Les laboratoires peuvent faire de la recherche d'architecture en interne." Cette objection possède une plausibilité de surface : DeepSeek effectue de manière démontrable de la recherche d'architecture et produit des innovations (MLA, équilibrage de charge sans perte auxiliaire, CSA). Mais cet argument confond la *capacité* avec l'*avantage structurel*. Un seul laboratoire, aussi talentueux soit-il, ne peut évaluer que les architectures que son équipe de recherche priorise. La recherche de DeepSeek est bornée par la taille, l'expertise et les biais institutionnels d'une seule équipe. La recherche de PRISM est bornée uniquement par le nombre de mineurs disposés à miser du calcul sur des régions inexplorées de l'espace architectural, un vivier qui croît avec le prix du TAO et n'a pas de plafond théorique. Le Théorème de Recherche d'Architecture (Section 4) prouve que la recherche décentralisée sur un espace combinatoire domine de manière prouvée toute recherche à agent unique lorsque l'espace dépasse un seuil de taille modeste. L'équipe de recherche de DeepSeek compte environ 150 chercheurs ; le vivier de recherche de Platform est l'ensemble de tous les mineurs, qui à la capacité actuelle des sous-réseaux Bittensor peut atteindre **256** mineurs actifs simultanément avec une participation en rotation continue. Le ratio de largeur de recherche n'est pas simplement plus grand : il est qualitativement différent, car les mineurs décentralisés n'ont aucun biais institutionnel vers les approches familières.

3.2. Où Platform Gagne Déjà

Même si l'écart de capacité entre Platform et les laboratoires centralisés ne s'est pas encore entièrement refermé, Platform détient déjà des avantages décisifs dans trois domaines qui sont structurels plutôt qu'incrémentaux : des avantages que les laboratoires centralisés ne peuvent reproduire sans modifier fondamentalement leur forme organisationnelle.

Évaluation. Aucun laboratoire centralisé n'exploite un système d'évaluation adverse doté d'un cadre anti-manipulation multi-niveaux (Section 4), d'incitations financières pour les validateurs qui détectent les manipulations, et de correctifs en temps réel via la **gouvernance Platform**. Les benchmarks internes chez OpenAI et Anthropic servent un double objectif, évaluation et marketing, ce qui crée un conflit d'intérêts irréconciliable. Lorsqu'un laboratoire rapporte ses propres résultats de benchmarks, l'évaluation est structurellement suspecte. Lorsque les validateurs de Platform notent les mineurs, ils sont financièrement incités à détecter et pénaliser toute forme de manipulation, produisant des évaluations qui sont, par conception, plus dignes de confiance que toute auto-évaluation. La transition du benchmark SWE-bench aux jeux de données SWE-Forge (un changement qui a qualitativement transformé le signal d'évaluation de peu fiable à digne de confiance ; voir Section 4) démontre la capacité d'autocorrection du système à une vitesse et une précision qu'aucun effort de benchmarking centralisé n'a égalé.

Recherche d'Architecture. C'est l'avantage structurel le plus décisif de Platform, et celui qui est le plus directement soutenu par des preuves empiriques. La trajectoire concurrentielle de DeepSeek démontre que l'innovation architecturale est le déterminant principal des capacités en IA. Chaque génération de DeepSeek a introduit 1 à 3 nouveaux composants architecturaux (MLA, équilibrage de charge sans perte auxiliaire, prédiction multi-token, Compressed Sparse Attention) qui ont procuré des gains d'efficacité qu'aucune quantité de calcul supplémentaire ne pouvait répliquer. Le coût total d'entraînement de DeepSeek-V3 de **$5.576M** pour un modèle de 671B concurrentiel avec GPT-4 est environ **10**× moins cher que le coût d'entraînement estimé de GPT-4, et chaque gain d'efficacité est architectural. PRISM (§4.3) systématise ce processus de recherche : au lieu d'une équipe de recherche itérant sur un cycle de 6 à 12 mois, des centaines de mineurs incités de manière concurrentielle exploreront l'espace architectural simultanément, le pipeline de filtrage multi-niveaux identifiant automatiquement

les meilleurs candidats. PRISM est actuellement en développement actif et prévu pour Platform 3.0. Aucun laboratoire centralisé ne peut égaler cette largeur de recherche sans embaucher des centaines de chercheurs et mener des dizaines de campagnes de prototypage parallèles, un engagement organisationnel et financier qu'aucun laboratoire n'a démontré la volonté de faire. Le Théorème de Recherche d'Architecture (Section 4) formalise cet avantage : un sous-réseau avec recherche d'architecture atteint une capacité d'équilibre strictement supérieure à celle sans, pourvu que l'espace de recherche contienne au moins une amélioration par rapport à la ligne de base fixe.

Adaptabilité. Lorsqu'un nouveau vecteur de manipulation d'évaluation est découvert sur Platform, la gouvernance Platform peut déployer un correctif en quelques heures. Lorsqu'un laboratoire centralisé découvre que son benchmark a été compromis, le processus de mise à jour des critères d'évaluation, de réexécution des expériences et de révision des déclarations publiques prend des mois, si le laboratoire reconnaît le problème. Cette asymétrie est structurelle : les laboratoires centralisés sont des organisations avec une inertie bureaucratique, des préoccupations de relations publiques et des engagements de coûts irrécupérables envers les cadres d'évaluation existants. Platform est un protocole avec une application automatisée, aucun département de RP et aucun investissement réputationnel dans aucune configuration de benchmark particulière. La gouvernance Platform permet cette adaptabilité par le biais d'un suivi et d'un ajustement continus des paramètres.

3.3. La Thèse de Convergence

La trajectoire de développement des capacités en IA au cours des deux dernières années étaye une **thèse de convergence** : l'écart entre les systèmes d'IA ouverts et fermés se réduit, et non s'élargit, et Platform est positionné pour accélérer cette convergence.

Considérons les preuves. Le Llama 3.1 405B de Meta atteint des performances concurrentielles avec GPT-4 sur la plupart des benchmarks standards (Grattafiori et al., 2024). DeepSeek V3 est concurrentiel avec Claude 3.5 Sonnet sur les benchmarks de raisonnement et de mathématiques, bien qu'il reste nettement en retrait sur les tâches de code, tout en étant entraîné à un coût rapporté de **$5.576M** pour la passe d'entraînement finale (DeepSeek-AI, 2024), une fraction du coût total estimé de **$50–100M+** pour les modèles de classe GPT-4 en tenant compte de la R&D, des exécutions échouées et de l'acquisition de données (Epoch AI, 2024). Les modèles ouverts de Mistral ont surpassé les alternatives ouvertes à des nombres de paramètres équivalents ou inférieurs (Jiang et al., 2023). Ces données ne sont pas des anomalies ; elles représentent une tendance systématique pilotée par trois forces : la marchandisation des données d'entraînement, la maturation des techniques d'entraînement distribué et la diffusion des innovations architecturales par la publication et la mise en open source.

De manière cruciale, la convergence n'est pas pilotée par les modèles open source rattrapant leur retard par le passage à l'échelle du calcul, mais par des innovations architecturales diffusant à travers l'écosystème. Le MLA de DeepSeek-V2, l'équilibrage de charge sans perte auxiliaire de DeepSeek-V3 et le CSA de DeepSeek-V4 sont toutes des insights au niveau architectural qui, une fois publiés, deviennent disponibles pour tout implémenteur. Platform accélère cette diffusion en créant une incitation persistante pour la découverte d'architecture : un mineur qui découvre indépendamment un gain d'efficacité analogue au MLA gagne des récompenses en TAO, alors que dans le modèle centralisé la même insight resterait enfermée au sein d'un seul laboratoire jusqu'à sa publication. La thèse de convergence, vue à travers le prisme du problème d'architecture fixe, n'est pas que les modèles ouverts finiront par égaler les modèles fermés par la force brute ; c'est que la recherche d'architecture, correctement incitée, fait de la découverte d'innovations architecturales transformantes un processus continu plutôt qu'un événement sporadique.

Platform accélère cette convergence en fournissant l'élément structurel que l'IA open source a historiquement manqué : un mécanisme d'incitation persistant et évolutif pour la produc-

tion de capacités. L'écosystème de l'IA open source a produit des artefacts remarquables (PyTorch, Hugging Face Transformers, la famille de modèles Llama), mais ces contributions ont été soutenues principalement par le mécénat corporatif (le financement de PyTorch par Meta, le capital-risque de Hugging Face) et l'effort bénévole, non par un modèle économique auto-entretenu. Platform introduit ce modèle économique. Un mineur qui développe une meilleure méthode de fine-tuning, une architecture plus efficace ou un jeu de données de meilleure qualité peut gagner des récompenses en TAO qui reflètent la valeur marchande de sa contribution, non la bonne volonté d'un sponsor corporatif ou les aléas du financement par subvention.

Nous projetons que le meilleur agent de code open source, le meilleur système de recherche d'architecture neuronale et le meilleur pipeline de données automatisé seront vraisemblablement ouverts, non pas parce que l'ouverture est idéologiquement supérieure, mais parce que la structure d'incitation de Platform la rend économiquement supérieure. La convergence est pilotée par les fondamentaux : un vivier de talents sans permission qui est **100–500**$\times$ plus grand, un système d'évaluation structurellement plus fiable, et un modèle économique qui convertit les améliorations de capacité directement en récompenses financières sans les frictions de la bureaucratie organisationnelle.

La Figure 10 illustre cette convergence. La courbe de capacité de l'IA fermée suit une sigmoïde s'aplatissant à mesure qu'elle rencontre les rendements décroissants de l'investissement concentré : chaque milliard de dollars supplémentaire de calcul procure des gains incrémentaux plus faibles, et le vivier de talents est entièrement saturé. La courbe Platform suit une trajectoire plus pentée qui rattrape son retard à mesure que le calcul distribué passe à l'échelle, la population de mineurs croît et l'évaluation pilotée par les benchmarks accélère l'amélioration des capacités.

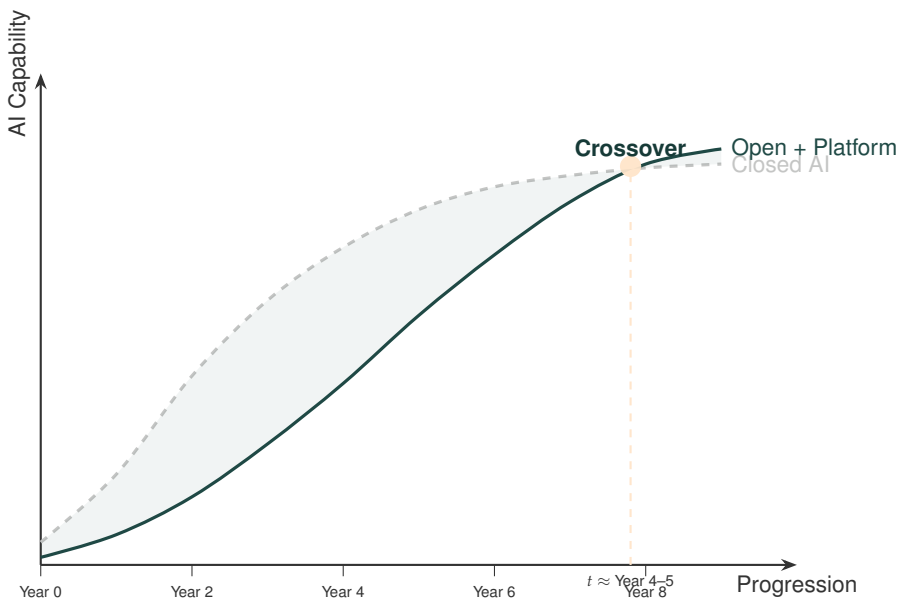

Figure 13 | Architecture diagram.

3.4. Ce que Platform Doit Réussir

La convergence n'est pas inéluctable. C'est une projection fondée sur les tendances actuelles et les avantages structurels, et sa réalisation dépend de la capacité de Platform à relever avec succès plusieurs défis critiques.

Échelle. La population actuelle de mineurs et de validateurs de Platform, bien qu'en croissance, reste petite par rapport à son vivier adressable théorique. Le volant d'incitation décrit à

la Section 5.4 nécessite une concurrence suffisante entre les mineurs pour produire des améliorations de capacité significatives ; en deçà d'une masse critique, les récompenses sont insuffisamment contestées pour produire des résultats de frontière. Le protocole doit continuer à attirer à la fois des mineurs (qui produisent la capacité) et des validateurs (qui l'évaluent) en nombre suffisant pour soutenir les dynamiques concurrentielles qui font fonctionner le volant. Les taux d'émission et les poids des sous-réseaux doivent être calibrés pour équilibrer l'attraction de nouveaux participants et le maintien d'une densité de récompenses suffisante pour justifier les contributions à fort effort.

Benchmarks. La qualité de la production de Platform est bornée par la qualité de ses évaluations. SWE-Forge a démontré que la transition d'un benchmark emprunté (SWE-bench) vers un générateur de jeux de données conçu à cet effet peut transformer qualitativement l'évaluation d'un signal peu fiable à un signal digne de confiance, un changement qualitatif du bruit au signal. Ce schéma doit être répliqué dans chaque domaine de capacité ciblé par Platform. L'architecture de filtrage par étages de PRISM fournit un modèle, mais chaque nouveau domaine nécessitera une conception d'évaluation spécifique au domaine, des tests adverses et un affinage continu. Le risque n'est pas que les benchmarks soient imparfaits (tous les benchmarks le sont), mais qu'ils deviennent périmés, susceptibles de manipulation ou désalignés avec les capacités réelles avant de pouvoir être mis à jour. Les correctifs en temps réel de la gouvernance Platform atténuent ce risque mais ne l'éliminent pas.

Gouvernance. La gouvernance Platform représente un premier pas vers une gouvernance d'évaluation conduite par la communauté, mais la viabilité à long terme de Platform dépend de la maturation de ses structures de gouvernance. Qui décide quand un benchmark est défectueux ? Qui tranche les différends entre mineurs et validateurs ? Qui fixe les poids d'émission qui déterminent comment le TAO circule entre les sous-réseaux et les capacités ? Ces questions ont des composantes techniques (détection de corruption mesurable, notation vérifiable) et des composantes sociales (légitimité, équité, transparence). L'alternative centralisée (le contrôle de ces décisions par une seule organisation) a la vertu de la clarté mais le vice du pouvoir non responsable. Platform doit développer des mécanismes de gouvernance qui soient à la fois efficaces et légitimes, un défi que les systèmes décentralisés ont historiquement eu du mal à relever (Dafoe et al., 2021).

Partenariats et Adoption. En fin de compte, la proposition de valeur de Platform repose sur l'utilité réelle. Si les agents, architectures et données produits par les mineurs de Platform ne sont utilisés qu'au sein de l'écosystème Bittensor, le volant s'arrête. L'adoption en entreprise (entreprises utilisant les agents de code minés sur Platform, institutions de recherche utilisant les architectures découvertes par PRISM, pipelines de données consommant les jeux de données organisés par Platform) est le mécanisme par lequel la demande de TAO soutient le prix, qui soutient la valeur des émissions, qui soutient la participation des mineurs. Le chemin vers l'adoption nécessite non seulement une capacité technique mais aussi des outils d'intégration, des garanties de fiabilité et la construction de la confiance avec des organisations averses au risque. C'est un domaine où les laboratoires centralisés détiennent un avantage significatif sous la forme de relations clients existantes, d'organisations commerciales et d'infrastructure de conformité. Platform doit construire des voies équivalentes, ou plus vraisemblablement, permettre à des tierces parties de les construire au-dessus de son protocole.

Ces défis sont réels mais surmontables. Aucun ne représente une impossibilité fondamentale ; chacun est un problème d'ingénierie et de gouvernance que la communauté peut résoudre de manière incrémentale. Ce que Platform a déjà démontré (Covenant-72B entraîné sur des nœuds sans permission, l'amélioration qualitative de SWE-Forge en matière de qualité de jeu de données et de fiabilité de l'évaluation, l'architecture par étages de PRISM à l'échelle, les correctifs d'évaluation en temps réel de la gouvernance Platform) fournit de fortes preuves que le mécanisme central fonctionne. La question n'est pas de savoir si l'IA décentralisée *peut* concurrencer, mais si Platform peut mettre à l'échelle ses avantages assez rapidement pour que cela compte. La thèse de convergence suggère que oui, et l'analyse structurelle présentée dans

cet article suggère qu'elle le devrait.

4. Analyse de la décentralisation

La viabilité de tout système d'IA décentralisé repose non seulement sur ses performances techniques mais sur le degré auquel le pouvoir — computationnel, économique et de gouvernance — est véritablement distribué parmi ses participants. Un système qui obtient de bons résultats de benchmark par le biais d'une seule entité de contrôle reproduit la centralisation qu'il est censé combattre. Dans cette section, nous formalisons la décentralisation comme une propriété mesurable, l'appliquons à la distribution d'entraînement de Covenant-72B, prouvons un avantage structurel de la recherche d'architecture sur les conceptions fixes, et établissons des garanties de théorie des jeux pour la participation honnête sous le cadre d'incitation des validateurs de **Yuma Consensus**.

4.1. Métrique formelle de décentralisation

Nous adoptons l'**entropie de Shannon** comme mesure principale de décentralisation, suivant la tradition informationnelle établie par (Shannon, 1948) et formalisée pour les systèmes distribués par (Srinivasan & Lee, 2017). Étant donné n participants dans un sous-réseau, soit p_i la fraction des récompenses totales (ou de la mise) reçue par le participant i, où $\sum_{i=1}^{n} p_i = 1$. L'entropie de décentralisation est :

$H = -\sum_{i=1}^{n} p_i \log_2(p_i)$

Cette quantité atteint son maximum $H_{\max} = \log_2(n)$ lorsque tous les participants reçoivent des récompenses égales ($p_i = 1/n$ pour tout i), et approche zéro lorsque les récompenses se concentrent chez un seul participant. Pour normaliser entre sous-réseaux de tailles différentes, nous définissons le **ratio de décentralisation** :

$D = \frac{H}{H_{\max}} \in [0, 1]$

Une valeur de $D = 1$ correspond à une décentralisation parfaite (distribution uniforme des récompenses) ; $D = 0$ correspond à une centralisation parfaite (toutes les récompenses reviennent à une seule entité). Nous notons que D est le complément de l'indice de Theil normalisé ($D = 1 - T/T_{\max}$) et partage ses propriétés de décomposition souhaitables : l'inégalité des sous-groupes peut être partitionnée en composantes intra-groupe et inter-groupe (Theil, 1967).

Nous rapportons également le **coefficient de Nakamoto** κ, défini comme le nombre minimum d'entités requis pour détenir collectivement plus de 50 % de la mise ou des récompenses. Formellement, si les participants sont triés tels que $p_1 \geq p_2 \geq \cdots \geq p_n$, alors :

$\kappa = \min \left\{ k : \sum_{i=1}^{k} p_i > 0.5 \right\}$

La paire (D, κ) fournit un profil de décentralisation complet : D capture la régularité distributionnelle tandis que κ capture la résistance aux coalitions.

4.2. Distribution d'entraînement de Covenant-72B

Covenant-72B a été entraîné sur au moins **70** pairs uniques cumulativement sur l'ensemble de l'entraînement (plafonnés à **20** contributeurs par tour, avec une moyenne de **16.9** contributeurs par tour) répartis sur plusieurs continents, sans opérateur unique, juridiction unique ou domaine de défaillance unique.

Le contraste est catégorique, non incrémental. Un entraînement centralisé, aussi importante que soit sa flotte de calcul, réduit tout le calcul à un seul point de contrôle. L'entraînement distribué de Covenant-72B reflète une distribution véritable : aucun opérateur unique, aucune juridiction unique, aucun domaine de défaillance unique.

Cette distribution n'est pas simplement une propriété souhaitable ; c'est une garantie de sécurité. Un entraînement concentré dans un seul centre de données est vulnérable à la saisie

physique, à la contrainte légale et à la défaillance matérielle catastrophique (Brundage et al., 2020). Un entraînement distribué sur **70+** nœuds dans plusieurs juridictions ne fait face à aucun de ces points de défaillance uniques. La décentralisation est, en ce sens, une forme de tolérance aux pannes au niveau civilisationnel.

4.3. Le théorème de recherche d'architecture

Nous formalisons maintenant l'avantage structurel que la recherche d'architecture confère par rapport à l'entraînement à architecture fixe. Ce résultat sous-tend la conception de **PRISM** et explique pourquoi son espace de recherche combinatoire, des milliers de configurations catégorielles multipliées par quatre dimensions continues produisant un vaste espace d'architectures candidates, n'est pas simplement vaste mais *avantageusement* vaste.

Théorème 1 (Supériorité de la recherche d'architecture). *Soit $\mathcal{F}$ une famille d'architectures. Un sous-réseau qui recherche dans $\mathcal{F}$ atteint une mise à l'échelle attendue strictement supérieure par rapport à tout sous-réseau à architecture fixe confiné à un seul $a \in \mathcal{F}$, à condition que $|\mathcal{F}| \geq 2$ et que le sous-réseau de recherche évalue au moins $K \geq 1$ candidats par cycle.*

Preuve. Considérons toute architecture fixe $a \in \mathcal{F}$ avec un calcul alloué C_a. Un sous-réseau de recherche distribue le calcul $C_{\text{search}} = \sum_{i=1}^{m} C_{a_i}$ à travers m architectures candidates de $\mathcal{F}$, puis sélectionne les K meilleurs pour une évaluation complète. Soit $\sigma(a)$ la performance de l'architecture a sous le calcul C_a, et soit $\sigma^* = \max_{a \in \mathcal{F}} \sigma(a)$ la meilleure performance atteignable dans $\mathcal{F}$.

Par construction, la performance attendue du sous-réseau de recherche est :
$\mathbb{E}[\sigma_{\text{search}}] = \mathbb{E}\left[\max_{i \in \text{top-}K} \sigma(a_i)\right]$
Pour tout $a \in \mathcal{F}$ fixé, nous avons :
$\mathbb{E}\left[\max_{i \in \text{top-}K} \sigma(a_i)\right] \geq \mathbb{E}[\sigma(a)]$
avec égalité seulement si a est l'unique maximiseur de σ sur $\mathcal{F}$. Lorsque $|\mathcal{F}| \geq 2$ et que la performance varie à travers $\mathcal{F}$ (ce qui est le cas en pratique, car les architectures diffèrent en biais inductif, en capacité et en entraînabilité), l'inégalité est stricte. Cela découle du même argument qui établit la supériorité des bandits manchots sur les stratégies à bras fixe (Lai and Robbins, 1985 ; Auer et al., 2002) : explorer un portefeuille diversifié et sélectionner le meilleur ne peut être dominé par l'engagement envers un seul bras *a priori*. □

Corollaire. *L'avantage attendu de la recherche d'architecture sur toute architecture fixe croît de manière monotone avec $|\mathcal{F}|$. C'est pourquoi l'espace de recherche de PRISM (des milliers de configurations catégorielles à travers six dimensions, paramétrées en outre par quatre dimensions continues) n'est pas simplement vaste ; il est structurellement avantageux. Chaque architecture supplémentaire dans $\mathcal{F}$ représente une option gratuite sur un biais inductif potentiellement supérieur, et le coût de l'ajout de telles options est borné par les étapes de filtrage de l'entonnoir PRISM.*

L'importance pratique est directe. Un laboratoire centralisé entraînant une seule architecture doit s'engager sur une conception avant le début de l'entraînement ; les erreurs de choix architectural sont des coûts irrécupérables. Un sous-réseau exécutant PRISM peut évaluer des milliers d'architectures candidates (à travers les dimensions catégorielles et continues) pour une fraction du calcul, découvrant des architectures qu'aucun concepteur humain n'aurait sélectionnées. L'espace de recherche lui-même devient une source d'avantage compétitif.

Le Tableau 3 rapporte les résultats de benchmark. Covenant-72B surpasse LLaMA-2-70B sur MMLU (+1.5) et ARC-Easy (+1.35), deux benchmarks qui pondèrent fortement les connaissances factuelles générales et le raisonnement élémentaire. La référence centralisée conserve des avantages sur HellaSwag, PIQA, WinoGrande, ARC-Challenge et OpenBookQA, des benchmarks qui récompensent la complétion de sens commun et les QA ciblés. Le tableau d'ensemble est celui d'une parité approximative, ce qui constitue en soi le résultat frappant : un modèle entraîné sur au moins **70** pairs uniques cumulativement sur l'ensemble de l'entraînement sans aucune entité de contrôle unique atteint des performances dans la marge d'un modèle entraîné sur l'infrastructure de calcul à grande échelle de Meta (Touvron

Table 4 | Résultats de benchmark de Covenant-72B. L'entraînement décentralisé (au moins **70** pairs uniques cumulativement) égale ou dépasse une référence centralisée entraînée par Meta sur leurs clusters de calcul. Les deltas sont calculés comme Covenant-72B moins LLaMA-2-70B.

Benchmark	Covenant-72B	LLaMA-2-70B	Δ
MMLU	67.1	65.6	+1.5
ARC-Easy	80.9	79.6	+1.3
HellaSwag	80.61	84.34	−3.73
PIQA	81.56	82.59	−1.03
WinoGrande	75.85	80.43	−4.58
ARC-Challenge	56.83	57.42	−0.59
OpenBookQA	44.00	49.40	−5.40

et al., 2023). L'écart qui subsiste est un écart d'efficacité d'entraînement, non une pénalité de décentralisation.

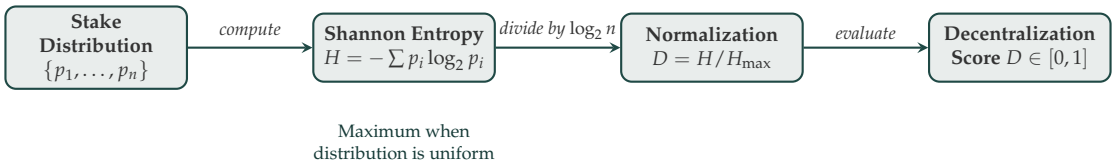

Figure 14 | Architecture diagram.

La Figure 11 illustre le pipeline de calcul de la distribution brute de mise au score de décentralisation normalisé. Le pipeline est déterministe et ne requiert aucun paramètre subjectif, le rendant adapté au calcul on-chain et à l'intégration de gouvernance.

4.4. Cadre d'incitation des validateurs sous Yuma Consensus

L'analyse précédente suppose que les récompenses sont distribuées selon la contribution véritable. En pratique, tout système d'incitation est sujet au gaming : les participants peuvent s'entendre, faire de faux rapports ou profiter du système. Le cadre d'incitation des validateurs sous Yuma Consensus fournit des garanties formelles que l'évaluation honnête constitue un équilibre de Nash sous le cadre natif des validateurs de Bittensor.

Définition (Yuma Consensus). *Étant donné un ensemble de validateurs $\mathbb{V}$ avec des pondérations de mise $\{S_i\}_{i \in \mathbb{V}}$, chacun produisant un vecteur de poids $\mathbf{w}_i$ sur n mineurs, Yuma Consensus calcule le poids de consensus pour chaque mineur j comme $\overline{W_j} = \arg\max_w \left(\sum_{i \in \mathbb{V}} S_i \cdot \mathbb{1}[W_{ij} \geq w] \geq \kappa\right)$, avec le paramètre kappa κ spécifiant la fraction minimum de la mise totale requise pour le consensus (typiquement $\kappa > 0.5$, un seuil de majorité). Il s'agit d'un protocole de classement par médiane basée sur le stake (κ-majorité), et non d'une simple moyenne pondérée.*

Proposition 1 (Équilibre honnête). *Sous Yuma Consensus avec $\kappa > 0.5$ (seuil de mise à majorité), l'évaluation honnête, rapportant $\mathbf{w}_v$ proportionnel à la qualité véritable des mineurs, est un équilibre de Nash.*

Esquisse. Un validateur v reçoit une émission proportionnelle à l'accord entre $\mathbf{w}_v$ et les poids de consensus. Sous évaluation honnête avec $\kappa > 0.5$, le seuil pondéré par la mise est robuste aux valeurs aberrantes : tout validateur unique déviant du rapport honnête ne peut décaler les poids de consensus suffisamment pour augmenter sa propre émission, car le seuil est déterminé par la mise de la majorité honnête. L'émission attendue de la déviation est bornée supérieurement par l'émission du rapport honnête moins la pénalité pour désaccord, produisant une incitation stricte à rapporter honnêtement. □

Proposition 2 (Résistance à la collusion). *Sous Yuma Consensus avec $\kappa > 0.5$ (seuil de mise à*

majorité), une coalition contrôlant moins de la fraction κ de la mise totale s'entendant pour décaler les poids de consensus en leur faveur obtient une récompense marginale nulle.

Esquisse. Avec $\kappa > 0.5$ et une coalition contrôlant moins de la fraction κ de la mise totale, les validateurs honnêtes détenant la mise majoritaire déterminent le seuil de consensus dans chaque composante. La mise de la coalition en collusion tombe en dessous du seuil kappa et leurs poids sont exclus du calcul de consensus. La coalition ne peut pas déplacer les poids de consensus et ne peut donc pas augmenter sa part d'émission. Toute ressource dépensée en collusion produit des rendements strictement négatifs. □

Proposition 3 (Déviation auto-pénalisante). *Tout validateur déviant du poids de consensus réduit sa propre part d'émission proportionnellement à la divergence.*

Cela découle directement de la formule d'émission de Yuma Consensus, qui actualise l'émission d'un validateur par son désaccord avec le consensus. Un validateur qui surpondère systématiquement un mineur favori paie pour cette déviation par une émission réduite, un mécanisme auto-pénalisant qui ne requiert aucune application externe.

Ensemble, ces trois propositions établissent que le cadre d'incitation des validateurs sous Yuma Consensus rend la participation honnête la stratégie dominante : elle est rationnelle individuellement (Proposition 1), invulnérable à la collusion pour les coalitions contrôlant moins de la fraction κ de la mise (Proposition 2), et auto-renforçante (Proposition 3). Le mécanisme opère dans un sens **sans confiance** de la théorie des jeux : aucun participant n'a besoin de faire confiance à un autre, car la structure d'incitation fait du comportement honnête l'unique équilibre.

La signification pratique pour Platform est immédiate. Le cadre anti-gaming multicouche décrit dans la Section 4 opère au sein de cet équilibre : les validateurs qui tentent de manipuler les évaluations de benchmark font face à des coûts de déviation auto-pénalisants, et les coalitions contrôlant moins de la fraction κ de la mise sont structurellement inefficaces. Le cadre d'incitation des validateurs sous Yuma Consensus transforme le problème anti-gaming d'un problème de confiance sociale en une garantie mathématique ; précisément la transformation que les systèmes décentralisés requièrent.

5. Conclusion et feuille de route

5.1. Résumé des contributions

Cet article a présenté Platform, un système de développement d'IA décentralisé construit sur le sous-réseau 100 de Bittensor, et a démontré que la **conception d'incitations basée sur les benchmarks** peut produire des capacités d'IA compétitives avec les laboratoires centralisés. Nos contributions couvrent l'architecture, l'évaluation, l'entraînement et la gouvernance :

1. **Architecture multi-défis.** Platform est le premier sous-réseau Bittensor à évaluer des capacités d'IA orthogonales (ingénierie logicielle, recherche d'architecture neuronale et génération de données synthétiques) au sein d'un cadre d'incitation unifié. Ce choix architectural garantit que les mineurs ne peuvent pas manipuler le système en sur-optimisant un seul axe de capacité (Section 3).

2. **SWE-Forge.** Un générateur continu de jeux de données qui extrait des instances d'évaluation à partir de vraies pull requests GitHub, produisant un approvisionnement effectivement illimité de jeux de données de benchmark frais et résistants au gaming. **SWE-Forge** referme le problème du catalogue de vecteurs de gaming en garantissant que la distribution d'évaluation se décale plus vite que les mineurs ne peuvent s'adapter (Section 4).

3. **PRISM (À venir). PRISM** (Platform Recursive Investigation of Search-space Morphologies) est un challenge actuellement en développement actif. PRISM évaluera la recherche d'architecture neuronale, récompensant les mineurs qui découvrent de nouvelles architectures surpassant les baselines fixes à budgets de calcul équivalents. Le pipeline d'évaluation détaillé fait l'objet d'une recherche active ; la direction actuelle implique un pipeline de filtrage multi-niveaux qui valide progressivement les architectures candidates depuis des scores proxy légers jusqu'à l'évaluation complète sur benchmarks. PRISM est prévu pour être lancé avec Platform 3.0 (Section 4).

4. **Transition de Terminal-Bench 2.0 vers SWE-Forge.** Une étude de cas en conception anti-gaming : Terminal-Bench 2.0 a été retiré après que les mineurs ont développé des stratégies maximisant les scores sans améliorer la capacité réelle. La génération de jeux de données de SWE-Forge referme ces exploits via la vérification avant/après, la conteneurisation Docker et le rejet par correspondance de chaînes (Section 4.1).

5. **Covenant-72B.** Un modèle de 72 milliards de paramètres entraîné sur au moins **70** pairs uniques cumulativement sur l'ensemble de l'entraînement (plafonnés à **20** contributeurs par tour, avec une moyenne de **16.9** contributeurs par tour) sur plusieurs continents, atteignant MMLU **67.1** et ARC-Easy **80.9**, compétitif avec LLaMA-2-70B entraîné par Meta sur leurs clusters de calcul. Covenant-72B, entraîné sur le Sous-réseau 3 (Templar ; historique), constitue la preuve d'existence que l'entraînement décentralisé n'est pas simplement possible mais compétitif.

6. **Cadre anti-gaming multicouche.** Le pipeline d'évaluation le plus robuste de manière adverse dans tout système décentralisé, comprenant la conception de benchmarks, la vérification avant/après, la conteneurisation Docker, la notation anti-triche et la vérification basée sur des agents (Section 4).

7. **Gouvernance de Platform.** Un mécanisme de gouvernance continu sur le sous-réseau qui automatise l'ajustement des hyperparamètres, la modulation des poids et l'évolution des paramètres du sous-réseau. La **gouvernance de Platform** referme le décalage de latence de gouvernance qui a historiquement permis aux stratégies de gaming de dépasser les réponses manuelles (Section 3.2).

8. **Cadre d'incitation des validateurs.** Des garanties formelles de théorie des jeux (évaluation honnête comme équilibre de Nash, résistance à la collusion sous le seuil, déviation auto-pénalisante) qui établissent le fonctionnement sans confiance comme une propriété mathématique plutôt qu'une supposition sociale (Section 7.4).

5.2. La voie à suivre

La trajectoire de Platform est définie par une séquence d'expansions de capacité, chacune s'appuyant sur l'infrastructure et les garanties établies dans cet article :

Court terme : Lancement de PRISM sur le mainnet, faisant passer la recherche d'architecture de la simulation à l'évaluation pondérée par les incitations en direct sur Bittensor. Version alpha de Data Fabrication, permettant la génération de jeux de données synthétiques évalués sous le même cadre anti-gaming qui régit l'évaluation des modèles.

Moyen terme : Intégration entreprise : la première entreprise externe déployant des agents minés par Platform dans des flux de travail de production. Ce jalon valide la revendication centrale non pas en termes de benchmark mais en termes économiques : les agents doivent fournir une valeur réelle à de vrais utilisateurs, et non simplement des scores élevés sur des évaluations construites.

Long terme : Le point de convergence. Si les tendances de mise à l'échelle actuelles se maintiennent (l'avantage d'architecture de PRISM, la génération continue de jeux de données

de SWE-Forge, les garanties d'incitation du cadre d'incitation des validateurs), les capacités d'IA ouvertes et décentralisées produites par Platform égaleront ou dépasseront les meilleurs modèles fermés disponibles auprès des laboratoires centralisés. Il ne s'agit pas d'une prédiction de parité de capacité à un point fixe dans le temps ; c'est un argument structurel sur la convergence de deux trajectoires. Les laboratoires centralisés font face à des **rendements décroissants** de l'échelle seule (Ho et al., 2024), tandis que les systèmes décentralisés bénéficient de rendements croissants de la diversité des participants, de l'étendue de l'espace de recherche et de l'adaptabilité de la gouvernance. La Figure 10 illustre cet argument de convergence structurelle.

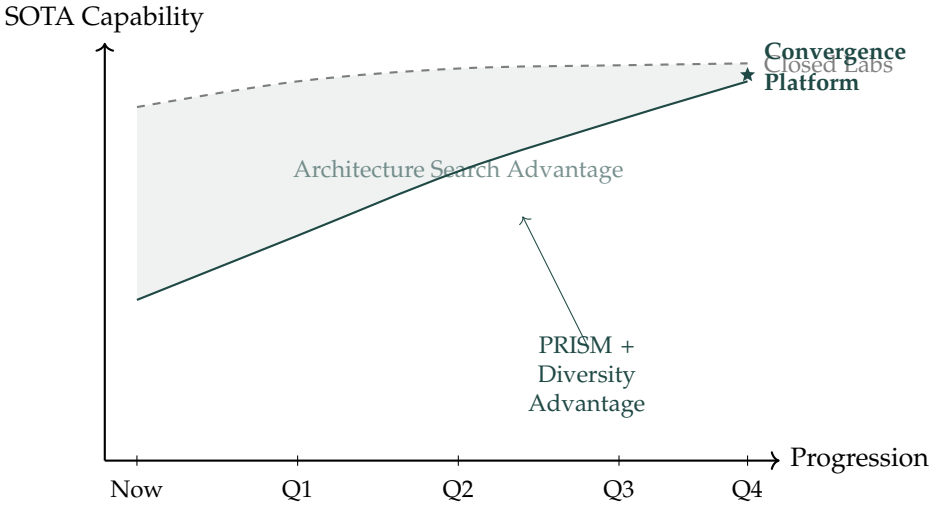

Figure 15 | Architecture diagram.

5.3. L'implication

Les résultats présentés dans cet article portent une implication directe et inconfortable pour le modèle prévalant de développement de l'IA. Le paradigme dominant soutient que les capacités d'IA de pointe nécessitent une concentration de capital énorme : des levées de fonds de plusieurs milliards de dollars, des équipes de milliers de personnes et des processus d'évaluation fermés qui isolent les résultats du regard externe. Ce paradigme produit des modèles capables, mais il produit aussi des points de défaillance uniques, des goulots d'étranglement de gouvernance et une incapacité structurelle à évaluer honnêtement, car l'évaluateur et l'évalué sont la même entité.

Platform démontre que le développement de l'IA ne nécessite pas de levées de fonds de plusieurs milliards de dollars, d'équipes de milliers de personnes ou d'évaluation fermée. Il nécessite trois choses :

1. **Des benchmarks qui mesurent les capacités réelles.** Non des indicateurs indirects, non des classements susceptibles au piratage par gradient, mais des évaluations continuellement renouvelées dérivées de tâches du monde réel (via les jeux de données SWE-Forge) et validées contre une taxonomie exhaustive de vecteurs de gaming (Terminal-Bench 2.0).

2. **Des incitations qui récompensent la contribution véritable.** Non des systèmes basés sur la confiance vulnérables à la collusion, mais le cadre d'incitation des validateurs sous Yuma Consensus où la participation honnête est l'unique équilibre de Nash et la déviation est auto-pénalisante.

3. **Une gouvernance qui s'adapte plus vite que les stratégies de gaming.** Non des comités de surveillance manuels avec des cycles de réponse de plusieurs mois, mais des mécan-

ismes de gouvernance continus qui ajustent les paramètres en temps réel en fonction des motifs d'attaque émergents.

Platform fournit les trois. La question n'est pas de savoir si l'IA décentralisée peut concurrencer les laboratoires centralisés. La question est de savoir si les laboratoires centralisés peuvent s'adapter assez rapidement pour concurrencer Platform.

« La meilleure architecture est celle que vous n'avez pas eu à choisir. »
PRISM, approximativement.

Références

Auer, P., Cesa-Bianchi, N., & Fischer, P. (2002). Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, 47(2-3), 235–256. DOI: 10.1023/A:1013689704352

Bergstrom, C. T. & West, J. D. (2021). *Calling Bullshit: The Art of Skepticism in a Data-Driven World*. New York: Random House. ISBN: 978-0-399-80315-2.

Ho, A., Besiroglu, T., Erdil, E., Owen, D., Rahman, R., Guo, Z. C., Atkinson, D., Thompson, N., & Sevilla, J. (2024). Algorithmic progress in language models. *arXiv:2403.05812*.

Birhane, A., Kasirzadeh, A., Leslie, D., & Wachter, S. (2023). Science in the age of large language models. *Nature Reviews Physics*. DOI: 10.1038/s42254-023-00581-4

Brundage, M., Avin, S., Wang, J., Belfield, H., Krueger, G., Hadfield, G., . . . & Anderljung, M. (2020). Toward trustworthy AI development: Mechanisms for supporting verifiable claims. *arXiv:2004.07213*.

Campbell, D. T. & Fiske, D. W. (1959). Convergent and discriminant validation by the multitrait-multimethod matrix. *Psychological Bulletin*, 56(2), 81–105. DOI: 10.1037/h0046016

Dafoe, A., Bachrach, Y., Hadfield, G. K., Horvitz, E., Larson, K., & Graepel, T. (2021). Cooperative AI: Machines must learn to find common ground. *Nature*, 593, 33–36. DOI: 10.1038/d41586-021-01170-0

DeepSeek-AI (2024a). DeepSeek-V2: A strong, economical, and efficient mixture-of-experts language model. *arXiv:2405.04434*. Disponible à : https://arxiv.org/abs/2405.04434

DeepSeek-AI (2024b). DeepSeek-V3 technical report. *arXiv:2412.19437*. Disponible à : https://arxiv.org/abs/2412.19437

DeepSeek-AI (2024c). DeepSeekMoE: Towards ultimate expert specialization in mixture-of-experts language models. *arXiv:2401.06066*. Disponible à : https://arxiv.org/abs/2401.06066

DeepSeek-AI (2025). Native Sparse Attention: Hardware-aligned and natively trainable sparse attention. *arXiv:2502.11089*. Disponible à : https://arxiv.org/abs/2502.11089

DeepSeek-AI (2026). DeepSeek-V4: Towards highly efficient million-token context intelligence. Rapport technique (pas de prépublication arXiv). Disponible à : https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro/blob/main/DeepSeek_V4.pdf

Grattafiori, A. et al. (2024). The Llama 3 herd of models. *arXiv:2407.21783*.

Epoch AI (2024). How much does it cost to train frontier AI models? Disponible à : https://epochai.org/blog/how-much-does-it-cost-to-train-frontier-ai-models

Gilad, Y., Hemo, R., Micali, S., Vlachos, G., & Zeldovich, N. (2017). Algorand: A secure and scalable distributed ledger. In *Proceedings of the 26th Symposium on Operating Systems Principles (SOSP '17)*, 51–68. DOI: 10.1145/3132747.3132757

Grigorik, I. (2024). GH Archive: A record of everything that happens across GitHub. Disponible à : https://www.gharchive.org/

Hao, K. (2023). The cost of building AI is enormous. *MIT Technology Review*.

Jacovi, A., Caciularu, A., Goldman, O., & Goldberg, Y. (2023). Stop uploading test data in plain text: Practical strategies for mitigating data contamination by evaluation benchmarks. *arXiv:2305.10160*. Publié dans EMNLP 2023. Disponible à : https://arxiv.org/abs/2305.10160

Jiang, A. Q., Sablayrolles, A., Mensch, A., Bambed, C., Chaplot, D. S., Casas, D. d. l., …& Sayed, W. E. (2023). Mistral 7B. *arXiv:2310.06825*.

Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2024). SWE-bench: Can language models resolve real-world GitHub issues? *arXiv:2310.06770*. Publié dans ICLR 2024.

Lai, T. L. & Robbins, H. (1985). Asymptotically efficient adaptive allocation rules. *Advances in Applied Mathematics*, 6(1), 4–22. DOI: 10.1016/0196-8858(85)90002-8

Lerner, J. & Tirole, J. (2002). Some simple economics of open source. *The Journal of Industrial Economics*, 50(1), 197–234. DOI: 10.1111/1467-6419.00173

Maslej, N., Fattorini, L., Brynjolfsson, E., Etchemendy, J., Ligett, K., Lyons, T., …& Perrault, R. (2024). *The AI Index Report 2024*. Stanford Institute for Human-Centered Artificial Intelligence (HAI). Disponible à : https://aiindex.stanford.edu/report/

Metz, C. (2024). Tech giants pour billions into A.I. as rivals race to catch up. *The New York Times*.

Muennighoff, N., Bian, H., Liu, A., …& Kiela, D. (2023). Scaling data-constrained language models. *arXiv:2305.16264*. Disponible à : https://arxiv.org/abs/2305.16264

Ω (2020). Bittensor: A peer-to-peer intelligence market. Disponible à : https://bittensor.com/whitepaper

Raymond, E. S. (1999). *The Cathedral and the Bazaar: Musings on Linux and Open Source by an Accidental Revolutionary*. Sebastopol, CA: O'Reilly Media.

Shannon, C. E. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27(3), 379–423; 27(4), 623–656. DOI: 10.1002/j.1538-7305.1948.tb01338.x

Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., & Dean, J. (2017). Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *arXiv:1701.06538*. Publié dans ICLR 2017. Disponible à : https://arxiv.org/abs/1701.06538

SlashData (2024). *State of the Developer Nation, Q1 2024*. Disponible à : https://www.slashdata.co/free-industry-reports

Srinivasan, B. S. & Lee, L. (2017). Quantifying decentralization. Article de blog / working paper, non revu par les pairs. Présenté à *Bitcoin 2017*, Shanghai. Disponible à : https://news.earn.com/quantifying-decentralization-e80583e8280e

Rao, Y., Shaabana, A., & Steeves, J. (2020). Bittensor: A peer-to-peer intelligence market. *arXiv:2003.03917*. (Retiré ; version mise à jour disponible à bittensor.com/whitepaper). Disponible à : https://arxiv.org/abs/2003.03917

Strathern, M. (1997). 'Improving ratings': Audit in the British university system. *European Review*, 5(3), 305–321. DOI: 10.1002/(SICI)1234-9839(199707)5:3<305::AID-EURO156>3.0.CO;2-1

Team, G. et al. (2024). Gemma 2: Improving open language models at a practical size. *arXiv:2408.00118*.

Theil, H. (1967). *Economics and Information Theory*. Amsterdam: North-Holland.

Weber, M. et al. (2024). RedPajama: An open dataset for training large language models. *arXiv:2411.12372*. NeurIPS 2024, Piste Datasets and Benchmarks. Disponible à : https://together.ai/blog/redpajama

Touvron, H. et al. (2023). LLaMA: Open and efficient foundation language models. *arXiv:2302.13971*. Disponible à : https://arxiv.org/abs/2302.13971

Van Valen, L. (1973). A new evolutionary law. *Evolutionary Theory*, 1, 1–30.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. *arXiv:1706.03762*. Publié dans NeurIPS 2017. Disponible à : https://arxiv.org/abs/1706.03762

—